CC7711

Inteligência Artificial e Robótica

Prof. Dr. Flavio Tonidandel

Algoritmos Genéticos

História da Teoria da Evolução

1859: Charles Darwin

- Existe uma diversidade de seres devido aos contingentes da natureza (comida, clima, ...) e é pela lei da **Seleção Natural** que os seres mais adaptados ao seus ambientes sobrevivem

  contra lei do uso de desuso

- Os caracteres adquiridos são herdados pelas gerações seguintes

"Quanto melhor um indivíduo se adaptar ao seu meio ambiente, maior será sua chance de sobreviver e gerar descendentes."

(DARWIN, 1859)

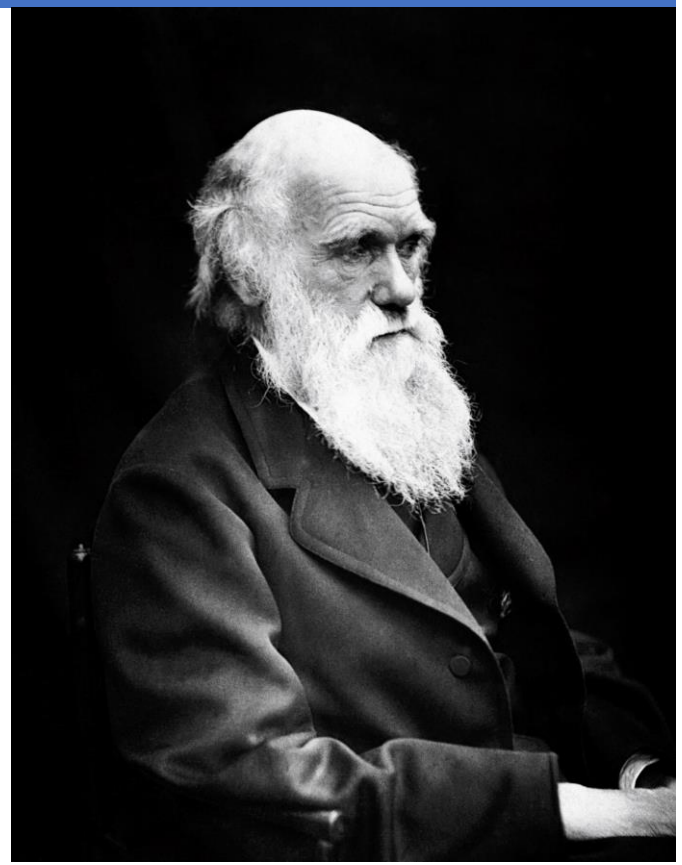

Imagem: Wikipedia Commons

História da Teoria da Evolução

1865: Gregor Mendel

- Formalizou a “herança de características”, com a teoria do DNA (ervilhas)

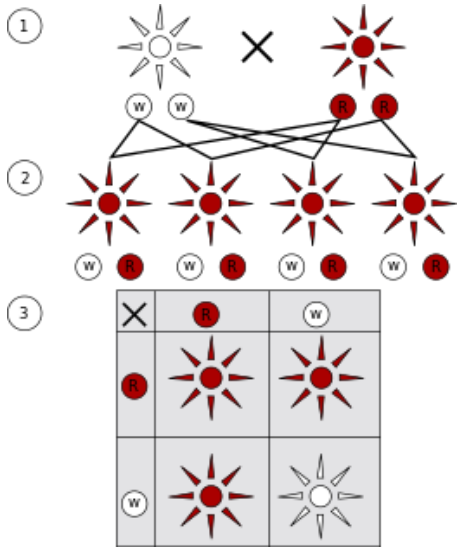

1901: Hugo De Vries

- Só a seleção natural não é responsável pela produção de novas (mais adaptadas) espécies. Tem de haver uma mudança genética!

- Formalizou o processo de geração de diversidade: **Teoria da Mutação**

Imagens: Wikipedia Commons

Surgimento dos Algoritmos Genéticos

1975: Jonh Holland: Idealizou os algoritmos genéticos

Por que a evolução ?

- Muitos problemas computacionais
  - envolvem busca através de um grande número de possíveis soluções
  - requerem que o programa seja adaptativo, apto a agir em um ambiente dinâmico

- A evolução biológica
  - uma busca paralela em um enorme espaço de problema
  - soluções desejadas = organismos mais adaptados

Imagem: Wikipedia Commons

Algoritmos Genéticos: introdução

Algoritmos Evolutivos

- Método para resolução de problemas (otimização) “inspirado” na teoria da evolução
- Algoritmos Genéticos são Algoritmos Evolutivos

Algoritmo Genético

- indivíduo = solução
- provoca mudança nos indivíduos por intermédio de *mutação* e *reprodução*
- *seleciona* indivíduos mais adaptados através de sucessivas gerações
- A aptidão de cada indivíduo é medida pela “função de aptidão” (*fitness function*)

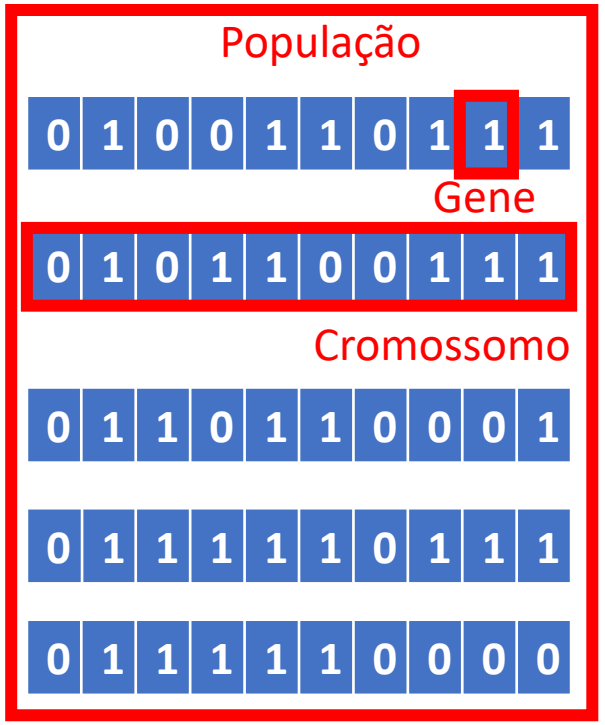

Ciclo do Algoritmo Genético

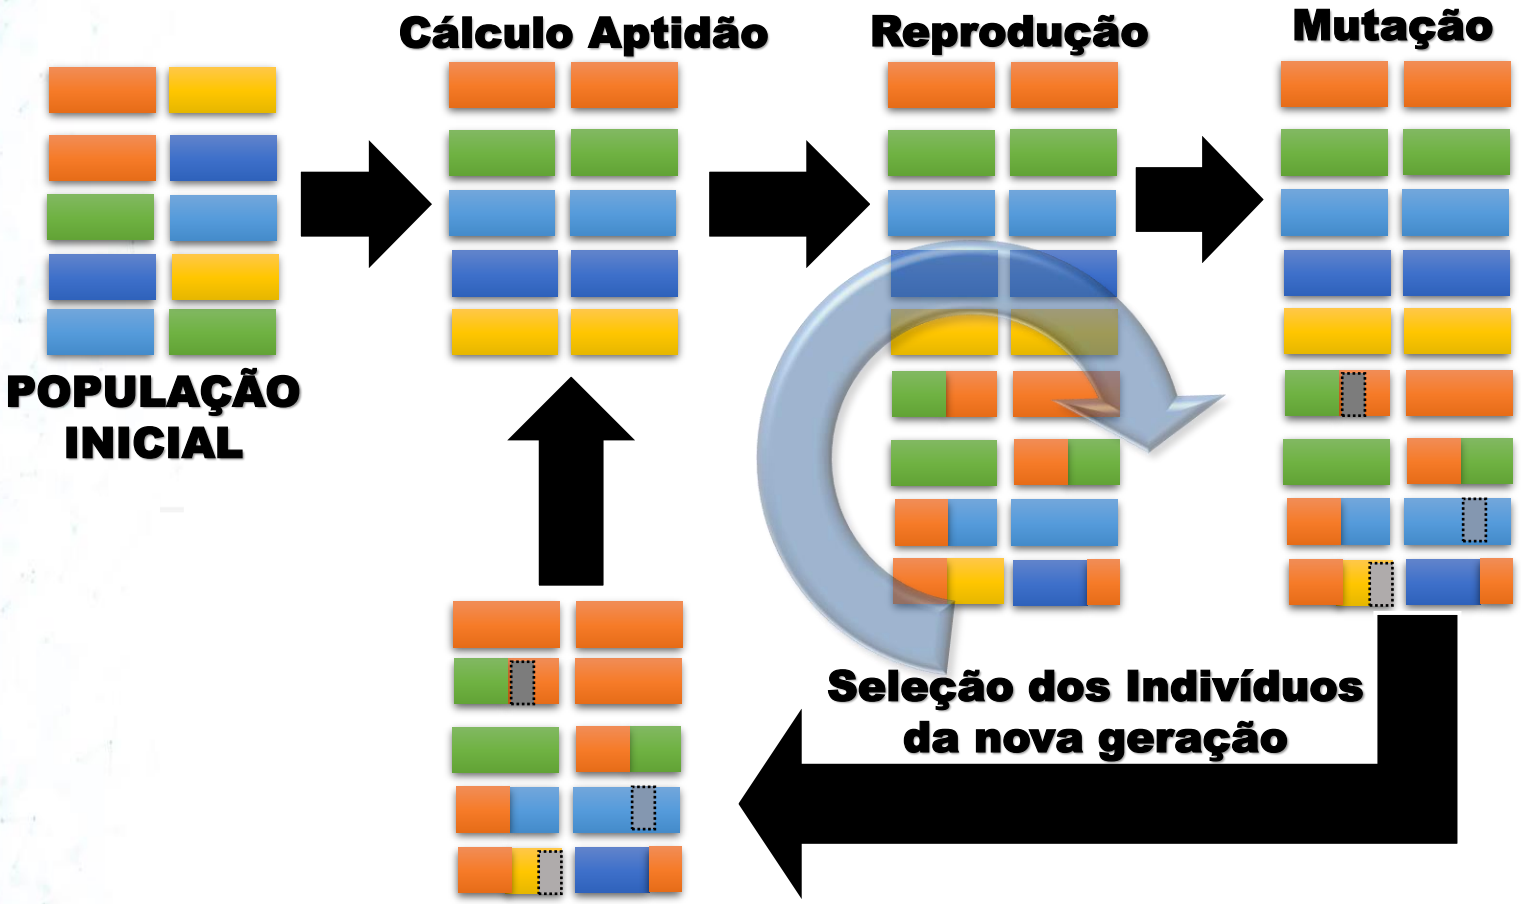

Convergência das gerações

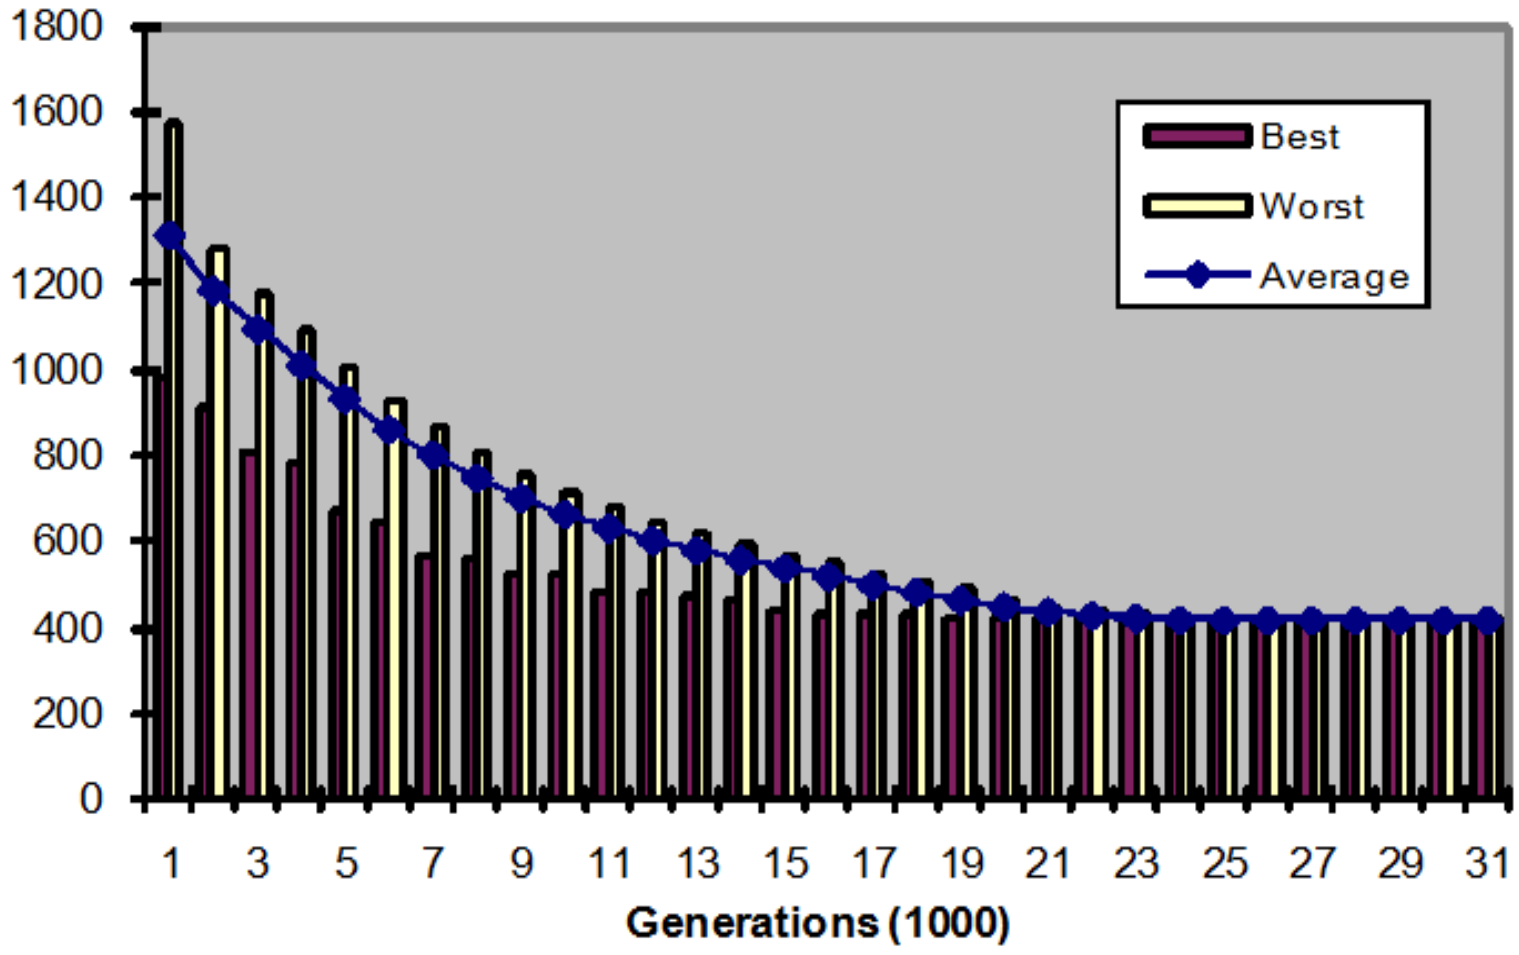

Wendy Willians. Genetic Algorithms: A tutorial.

Após Gerações.....

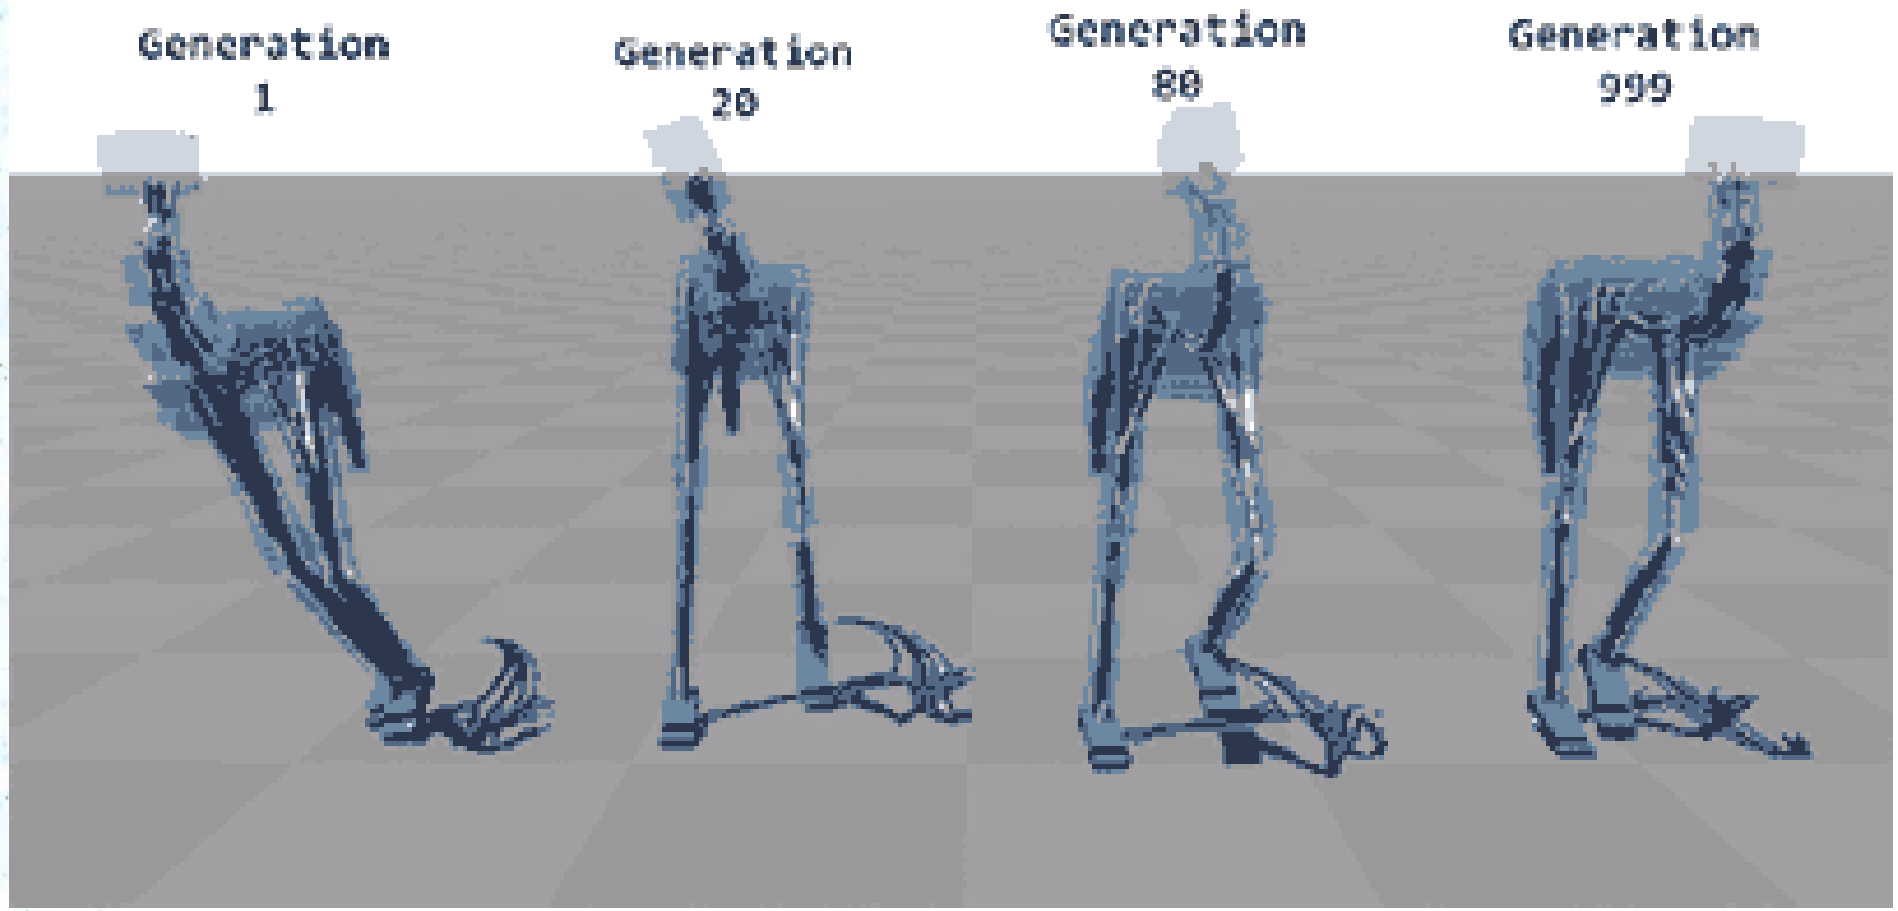

Imagem: Goatstream,J - Flexible Muscle-based Locomotion for Bipedal Creatures – SIGGRAPH 2013

Gerando População Inicial

Dado um problema, precisamos definir como será a representação dos individuos (soluções)

- Um individuo é um Cromossomo
  - Os parâmetros do problema de otimização são representados por cadeias de valores.
  - Exemplos:
    - Vetores de reais, (2.345, 4.3454, 5.1, 3.4)
    - Cadeias de bits, (111011011)
    - Vetores de inteiros, (1,4,2,5,2,8)
    - ou outra estrutura de dados (arvores, heaps, etc)

Todos os indivíduos devem ser soluções do problema

Gerando População Inicial

Qual deve ser a população Inicial ?

- Deve ser aleatoriamente escolhida

- *Precisamos garantir a variedade da população inicial:*
  - velocidade de convergência x variedade
  - Variedade x solução ótima
  - Quanto maior a variedade, menor a velocidade de convergência e vice-versa
  - Quanto maior a variedade, maior a chance de encontrar a solução ótima, porém, menor a velocidade de convergência

Função de Aptidão- Fitness

- Função de aptidão (avaliação / fitness):
  - É feita através de uma função que melhor representa o problema e tem por objetivo fornecer uma medida de aptidão de cada indivíduo na população corrente que irá dirigir o processo de busca.
  - Aptidão é uma nota associada ao indivíduo que avalia quão boa é a solução por ele representada
- Funções de avaliação são específicas de cada problema.

Cromossomo	Significado	valor
0011011	Binário p/ Inteiro	$x = 27$
ADBCE	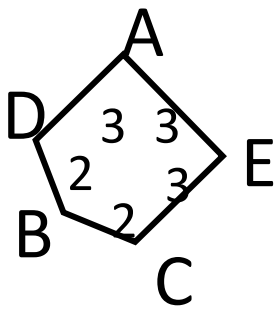	$A \rightarrow D \rightarrow B \rightarrow C \rightarrow E$ $\sum \text{dist} = 13$

Criando e Evoluindo Gerações

- **Quais são os métodos para criar novos individuos ?**
  - Reprodução sexuada (crossover)
  - Reprodução assexuada
  - Mutação
- **Como garantir encontrar a solução ?**
  - Os indivíduos devem ser selecionados (os mais aptos sobrevivem) para garantir a convergência
  - Deve-se evitar a convergência prematura
  - Deve-se estabelecer um critério de parada
- **Convergência**
  - nas últimas *k* gerações não houve melhora da aptidão

Reprodução/recombinação

- Função: combinar e/ou perpetuar material genético dos indivíduos mais adaptados
- Tipos:
  - assexuada (=duplicação) ou sexuada (crossover)
  - Observação: Existe uma “taxa de crossover” que controla a quantidade de reprodução que será feita

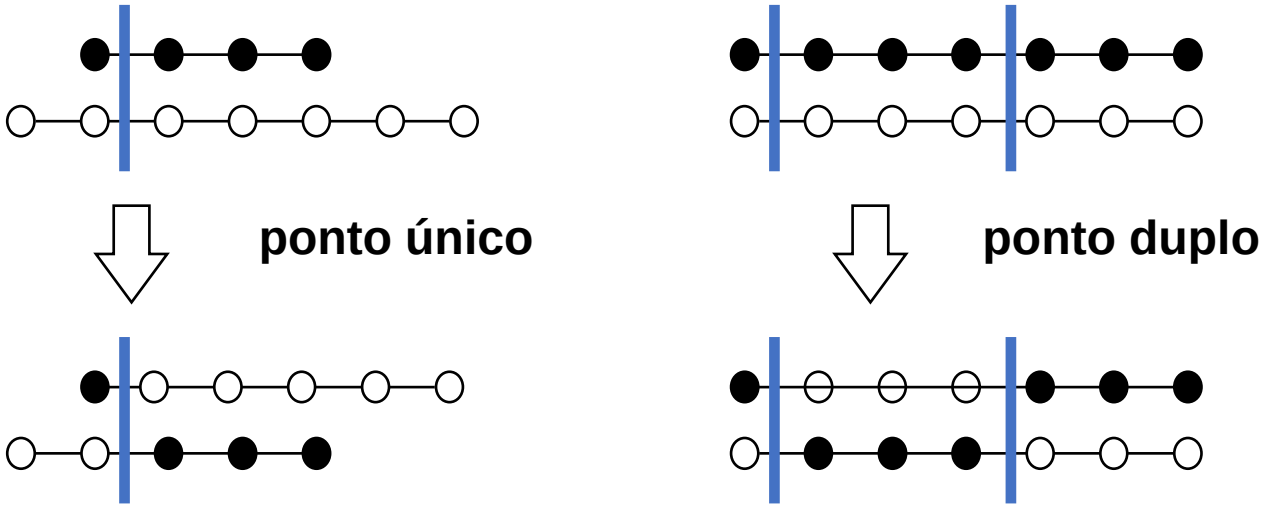

Reprodução

- Quanto mais “estruturada” a representação mais difícil de definir o cruzamento

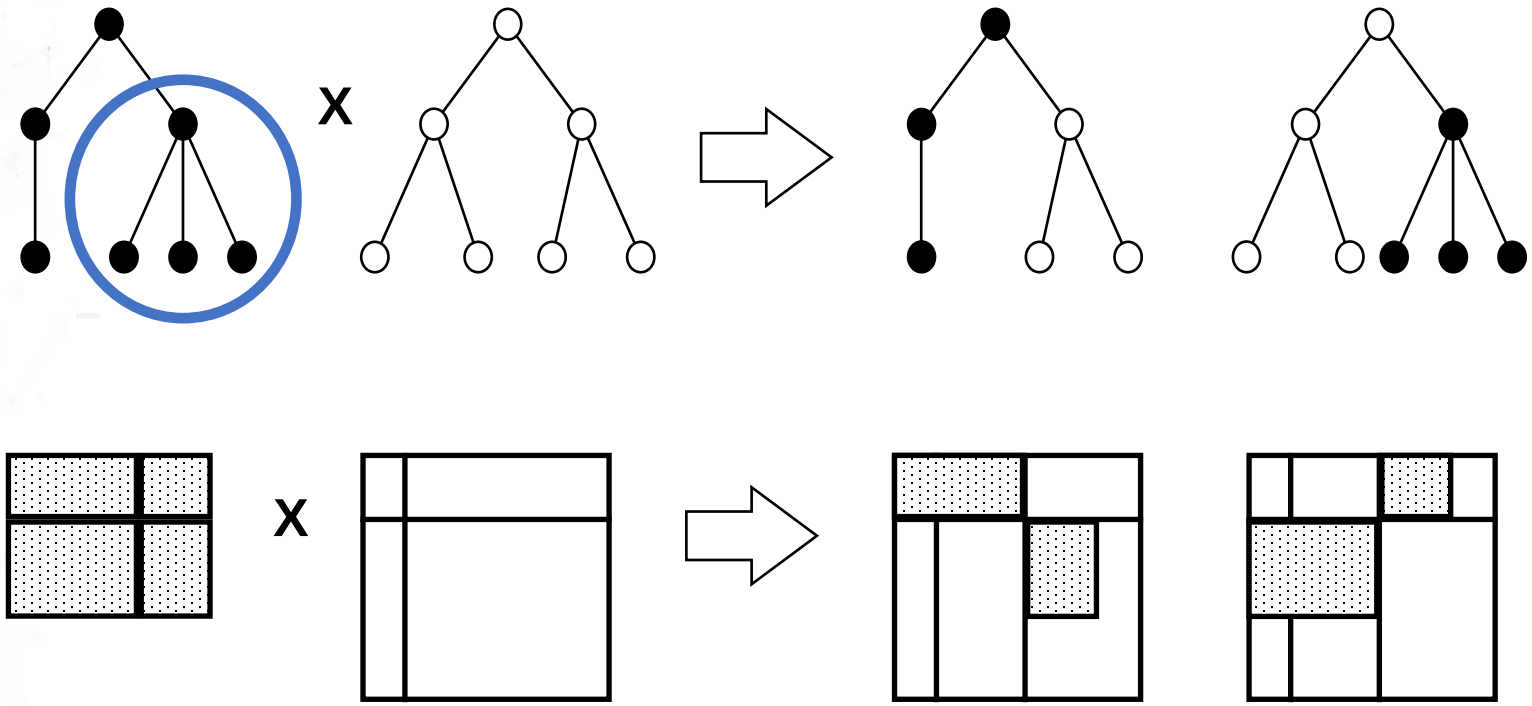

Mutação

- **Objetivo**: gerar diversidade (p/ escapar de ótimos locais)
- Tipos:
  - generativa
  - destrutiva
  - swap
  - swap de seqüência
- Observação: Existe uma “taxa de mutação” que diminui com o tempo (ex. % da população selecionada) para garantir convergência

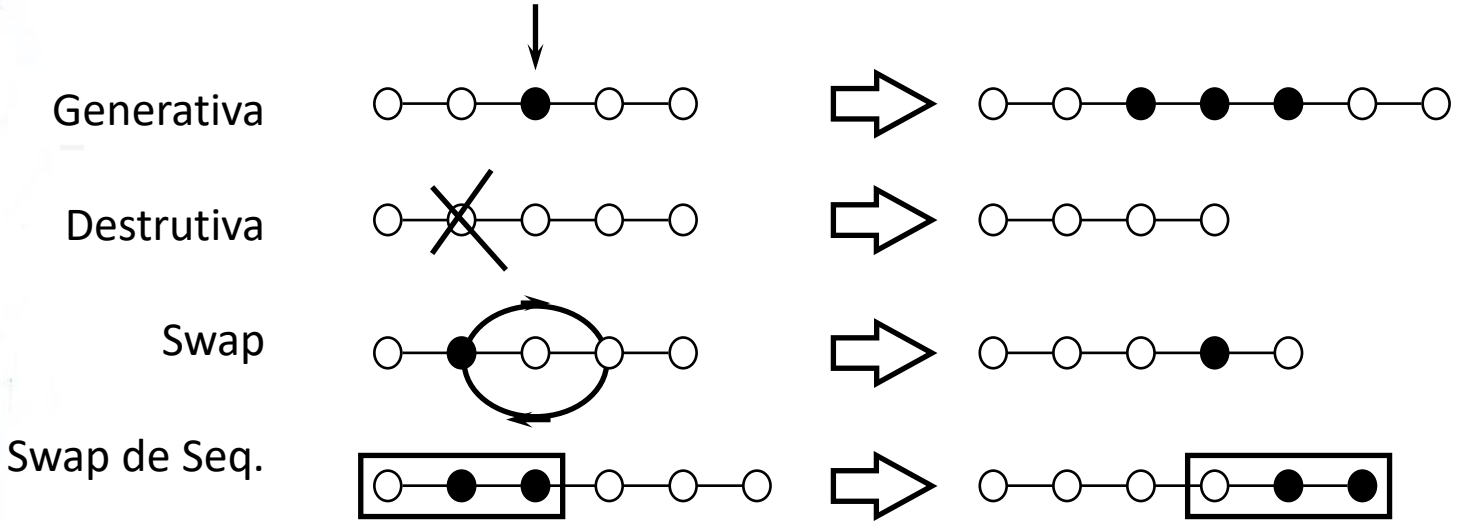

Reprodução e Mutação

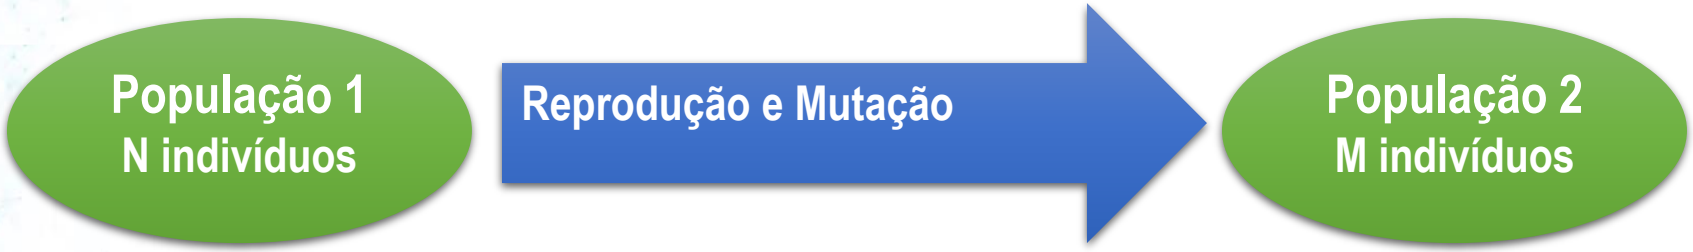

- **Composições possíveis para a População 2:**
  - Troca de toda população
    - **Isso significa que a população 2 substitui a população 1**
    - **A cada ciclo, *N*/2 pares são escolhidos gerando *M*=*N* descendentes**
  - Elitismo
    - **A população 2 substitui a população 1 (M= N-1)**
    - **Acrescenta-se o mais apto da população 1 na população 2**
  - Steady State
    - **Gera-se M<N indivíduos e esses M substituem os M piores do conjunto da população 1 – Existe também o Steady state sem duplicados**

Seleção de indivíduos para Reprodução

Como selecionar indivíduos para Reprodução ?

Método da Roleta

- Selecionar indivíduos aleatoriamente, proporcionando chances de reprodução aos mais aptos.
- *f* (cromossomo) = medida numérica de aptidão

Chances de seleção são proporcionais à aptidão

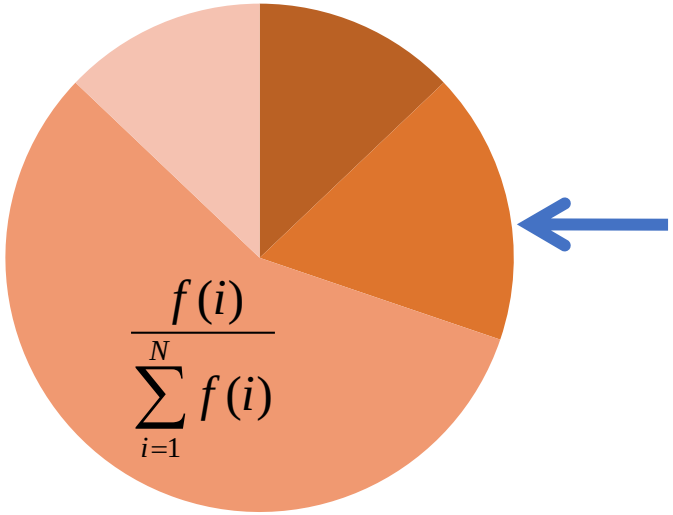

Método da Roleta

Encontre a soma da aptidão A_T de todos os indivíduos da população: $$A_T = \sum_{i=1}^{N} f(i)$$

- Gere um número aleatório *r* : $$\boxed{0 \le r \le A_T}$$
- Selecione o primeiro indivíduo da população cuja aptidão somada às aptidões dos indivíduos precedentes é >= *r*:

$$\boxed{\sum_{i=1}^{k \le N} f(i) \ge r}$$

Exemplo: r = 30

Cromossomo	1	2	3	4	5	6	7	8	9	10
Aptidão	8	2	17	7	2	12	11	7	3	7
$\sum_{i=1} f(i)$	8	10	27	34	36	48	59	66	69	76

Critérios de parada

- Definir um Número Máximo de gerações
- Parar quando o sistema encontrar a solução (quando esta é conhecida).
- Parar quando ocorrer a perda de diversidade (repetição individuos) → Convergir !!!

Processo Geral

População Geração X
10 indivíduos

Mais apto

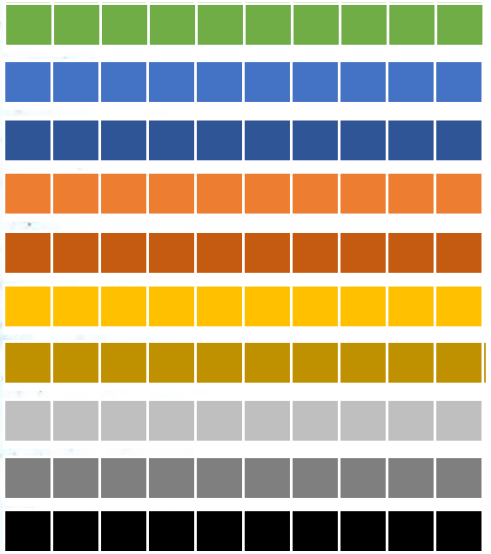

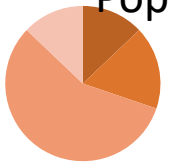

População Geração X+1
10 indivíduos

Método da Roleta

Crossover (Reprodução)

Processo se repete

mutação

mutação

9 novos indivíduos

Elitismo

Convergência Prematura

- O que é a Convergência Prematura ?
  - O sistema não apresenta mais nenhuma melhora e ainda está longe da situação ideal. Não apresenta mais diversidade da população

- O que pode causar a Convergência Prematura ?
  - Vários indivíduos iguais (pouca diversidade)
  - Um super-individuo que monopoliza o método da roleta
  - Uma baixa taxa de mutação e/ou reprodução

- O que podemos fazer para evitar ?
  - Mexer na função de aptidão (fitness) !!!!!
  - Existem técnicas que minimizam a criação de super-indivíduos e que aumentam a pressão seletiva sobre os melhores. São elas:

    - Transformação Exponencial
    - Normalização Linear (NL)

Evitando a Convergência Prematura

Transformação Exponencial:

- O novo valor da Aptidão f' de cada individuo será dado por:

$$f'(i) = \sqrt[2]{f(i) + 1}$$

- Reduz a influência do individuo mais forte

Normalização Linear:

- Ordene todos os *N* indivíduos em ordem decrescente de avaliação

  (*i* =1 menos apto)
- Crie aptidões partindo de um valor mínimo e crescendo linearmente até o valor máximo para cada um dos N indivíduos

$$A_i = \min + \frac{(\max - \min)}{N-1} \times (i-1)$$

Idéia: Quanto menor a constante de incremento maior a pressão seletiva sobre os melhores. O valor normalmente usado é (max-min/N-1).

Comparativo

Exemplo Comparativo:

Rank	6	5	4	3	2	1
Aptidão	**200**	**50**	**25**	**15**	**10**	**1**
Transf. Exponencial	14	7	5	4	3	1
NL (incremento 20)	101	81	61	41	21	1

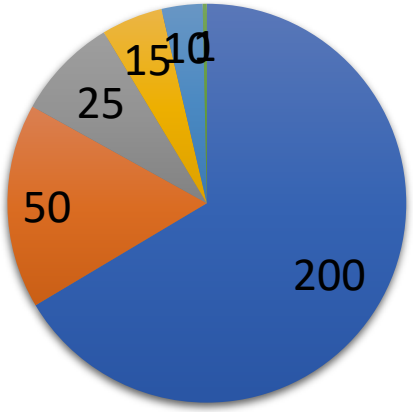

Aptidão

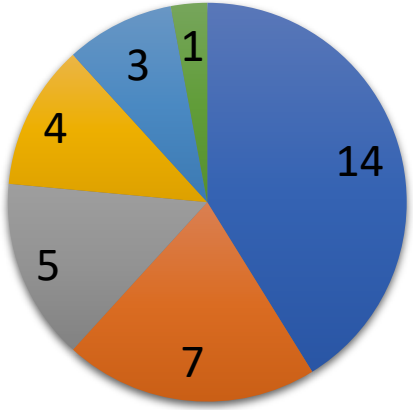

Transf. Exponencial

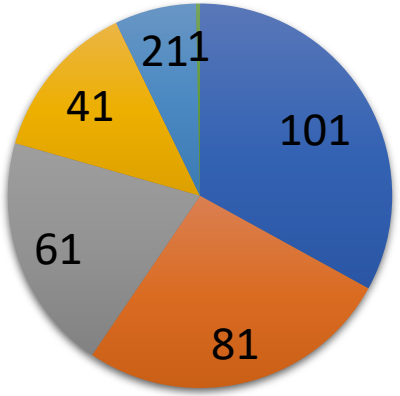

NL (incremento 20)

Algoritmos de AG mais usual

- Possui as seguintes características:
  - Cromossomo: Representação binária em um vetor
  - Reprodução: Crossover de 1 ponto
  - Nova geração: Reprodução (seleção) com substituição da população por Elitismo
  - Convergência Prematura: Normalização Linear
  - Outros detalhes: usa-se Mutação

Apresenta bom desempenho em diversas aplicações (é um bom algoritmo de partida).

Um exemplo simples

O problema do Caixeiro Viajante:

Encontre um caminho entre as cidades de modo que:

- Cada cidade seja visitada apenas uma vez
- A distância total de viagem seja minimizada

Para um problema com 30 cidades, teremos algo como 30! (fatorial) possibilidades de caminhos

$30! \approx 10^{32}$

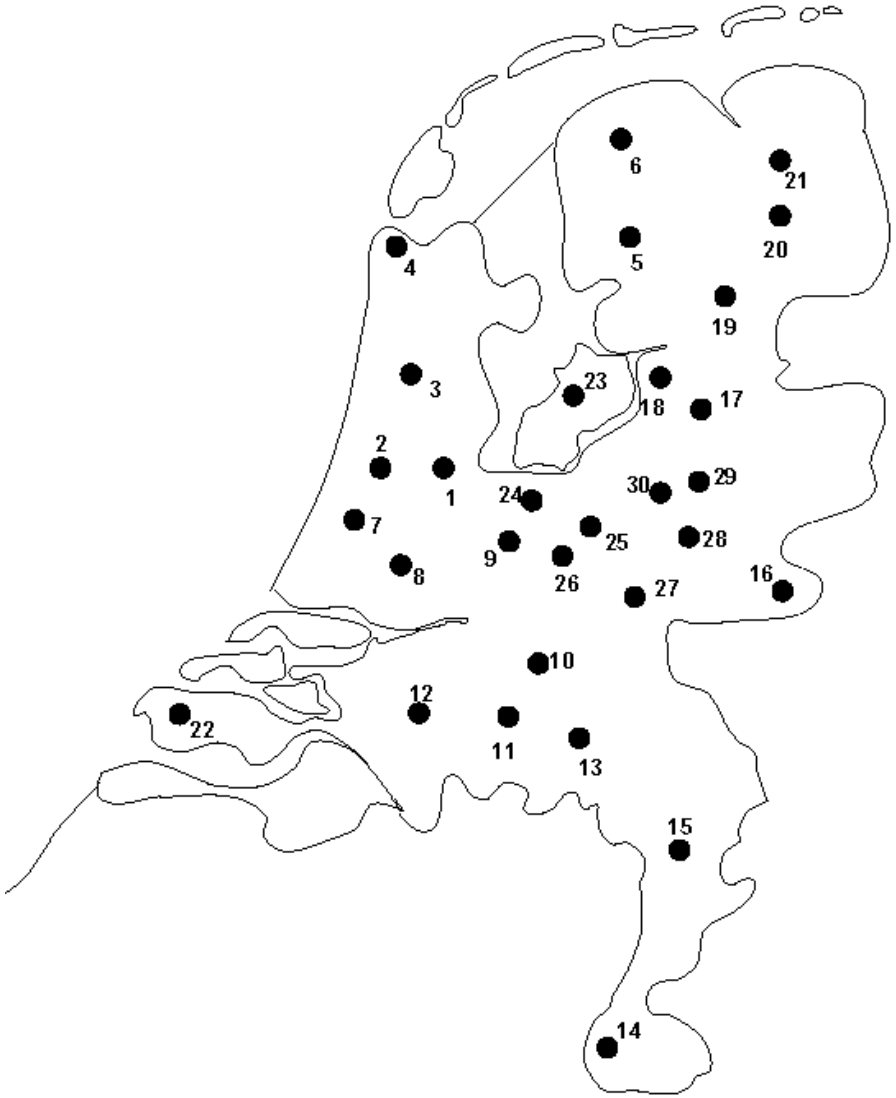

Representação

Iremos considerar um modo simples de representação:

- Lista ordenada de cidades visitadas
- Cada cidade será representada por um número

1) São Paulo	3) SBCampo	5) Diadema	7) Guarulhos
2) Campinas	4) Sto André	6) Osasco	8) SCSul

CityList1 (3 5 7 2 1 6 4 8)

CityList2 (2 5 7 6 8 1 3 4)

Definindo o Crossover

Iremos usar um Crossover de reprodução de ponto duplo

Pai1 (3 5 7 2 1 6 4 8)

Pai2 (2 5 7 6 8 1 3 4)

Filho (2 5 7 2 1 6 4 4)

Isto não é um individuo válido !

Ajustar!

Filho (2 5 7 **8** 1 6 **3** 4)

Individuo válido !

Definindo a Mutação

Mutação envolve reordenação de lista:

			*			*		
Antes:	(5	8	7	2	1	6	3	4)
Depois:	(5	8	6	2	1	7	3	4)

Exemplo: 30 Cidades

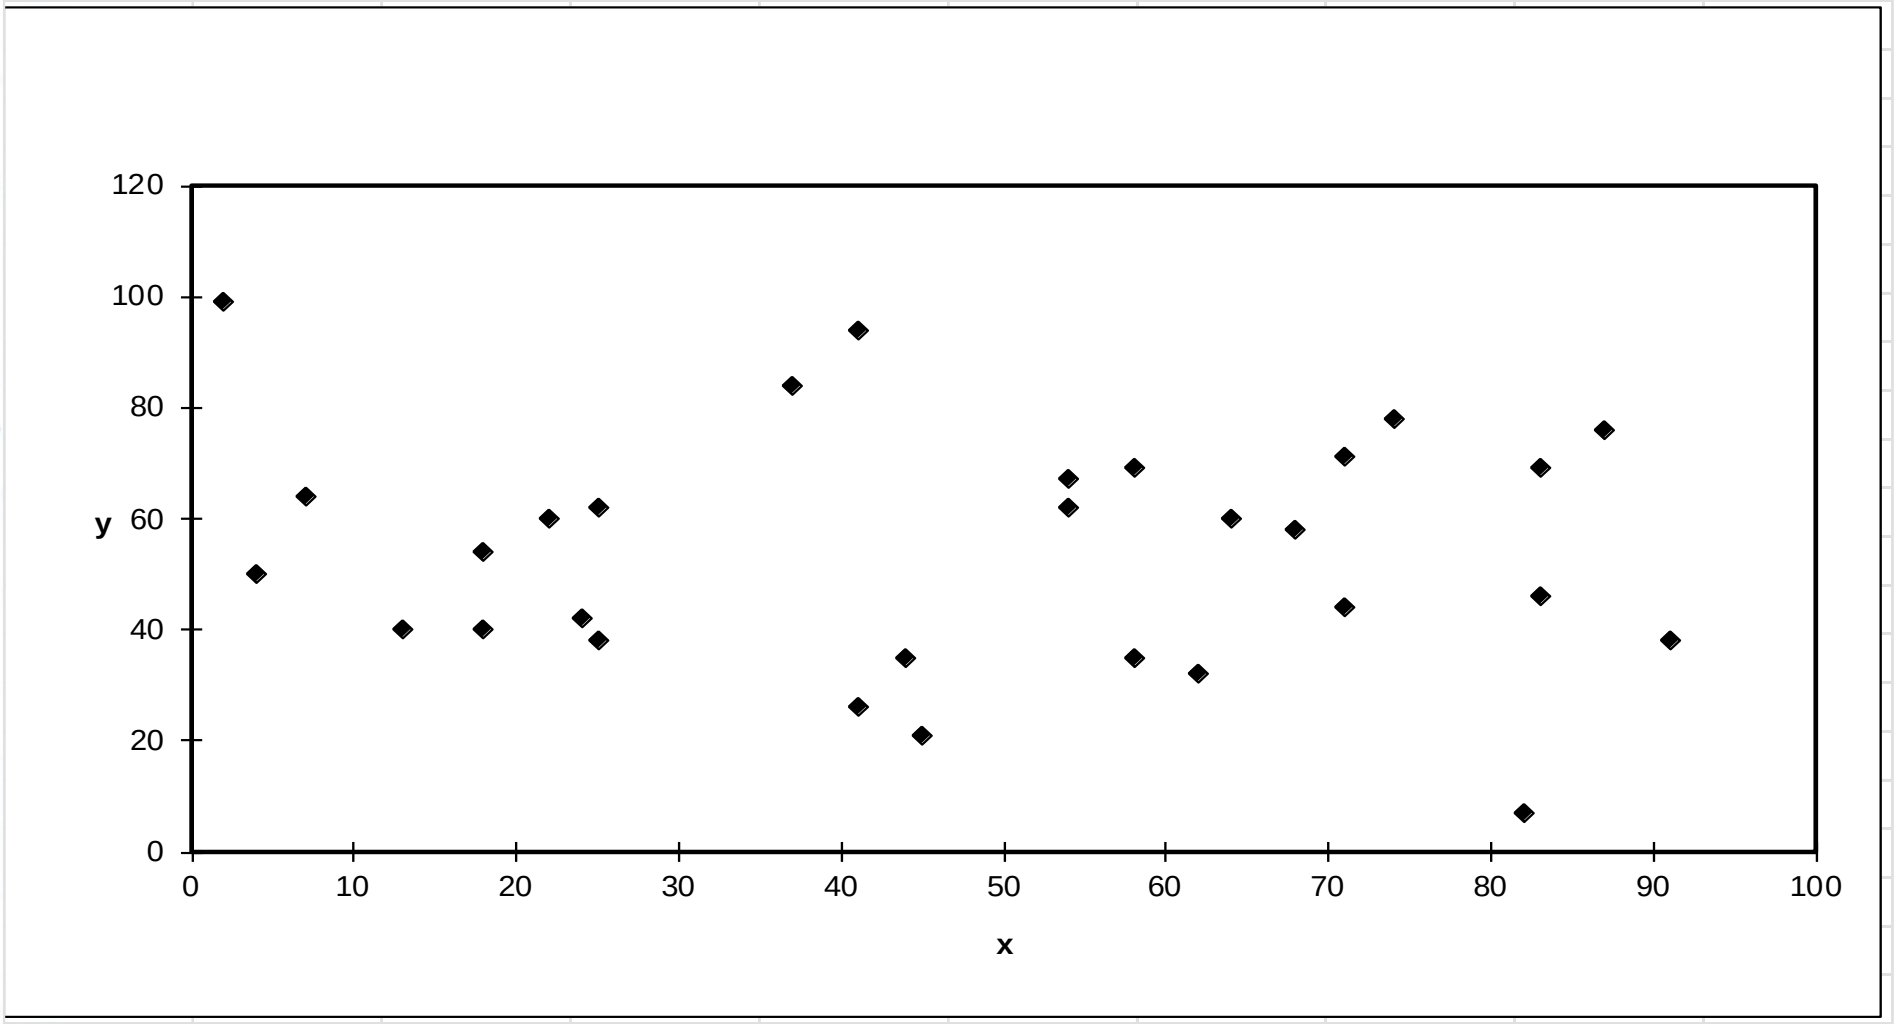

Wendy Willians. Genetic Algorithms: A tutorial.

Solução parcial (Distância = 941)

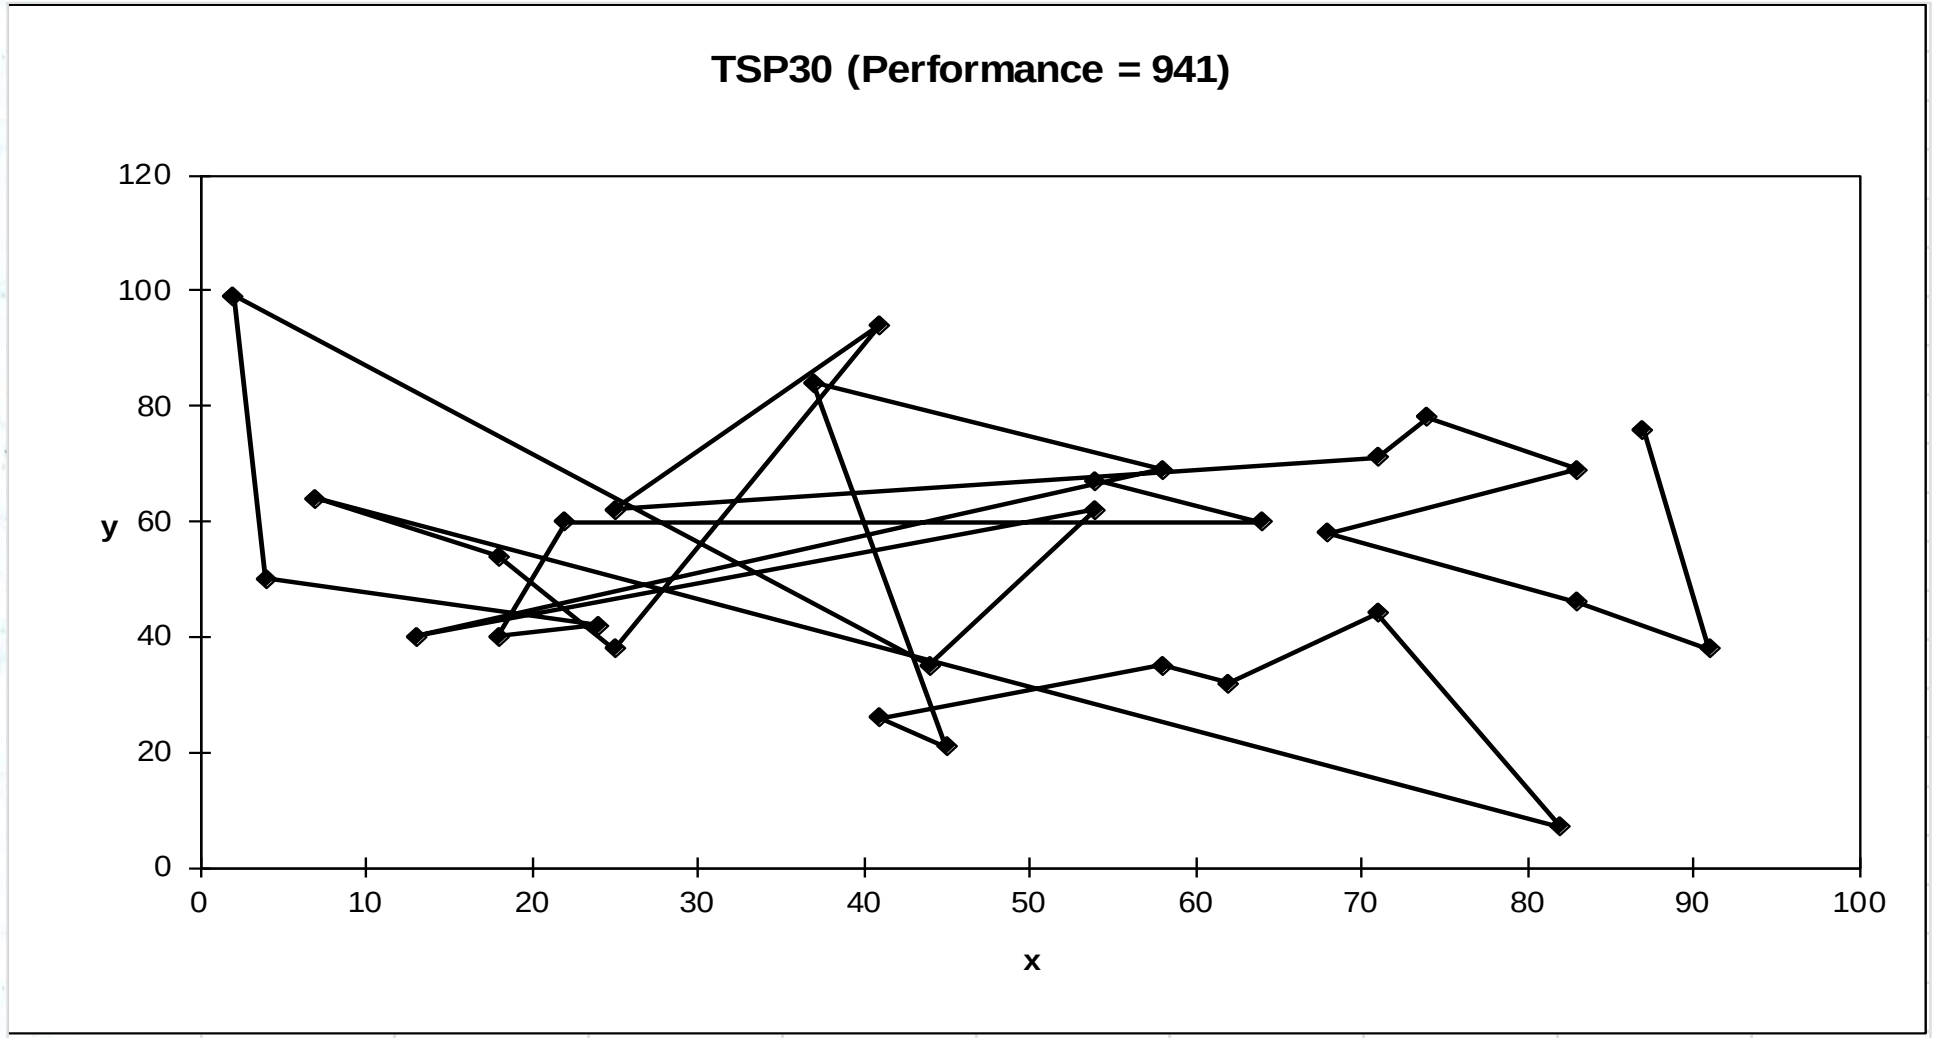

Wendy Willians. Genetic Algorithms: A tutorial.

Solução parcial (Distância = 800)

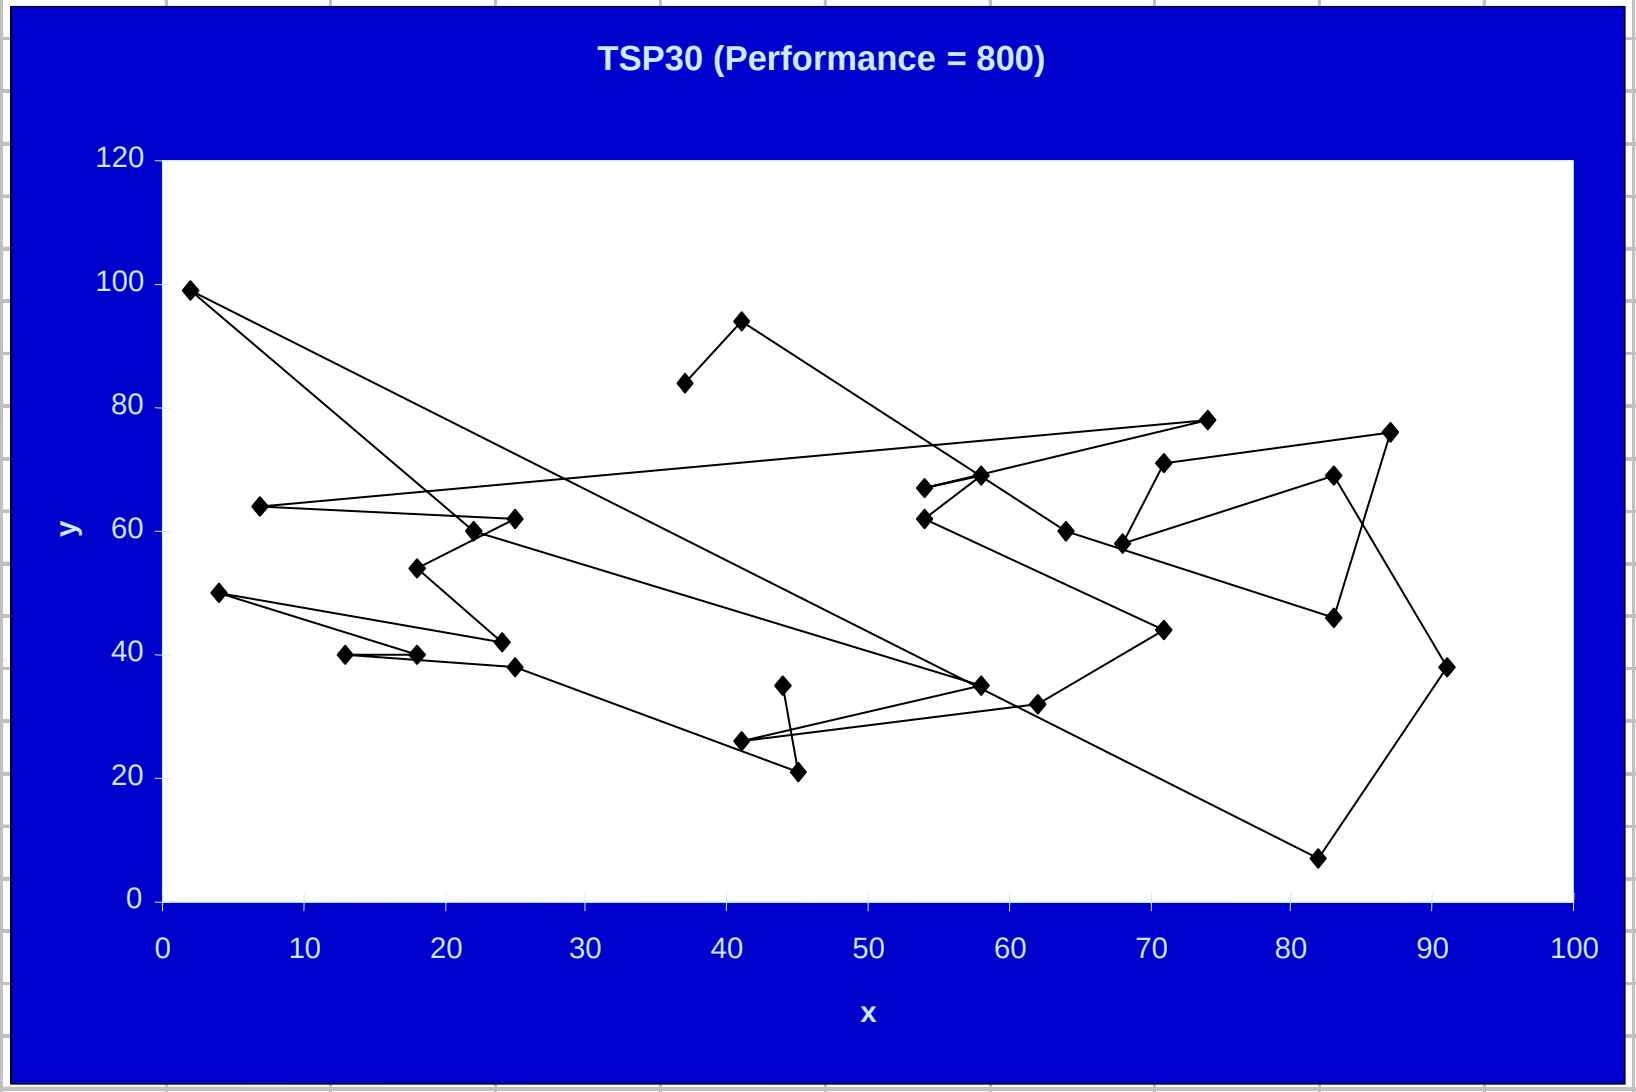

Wendy Willians. Genetic Algorithms: A tutorial.

Solução parcial (Distância = 652)

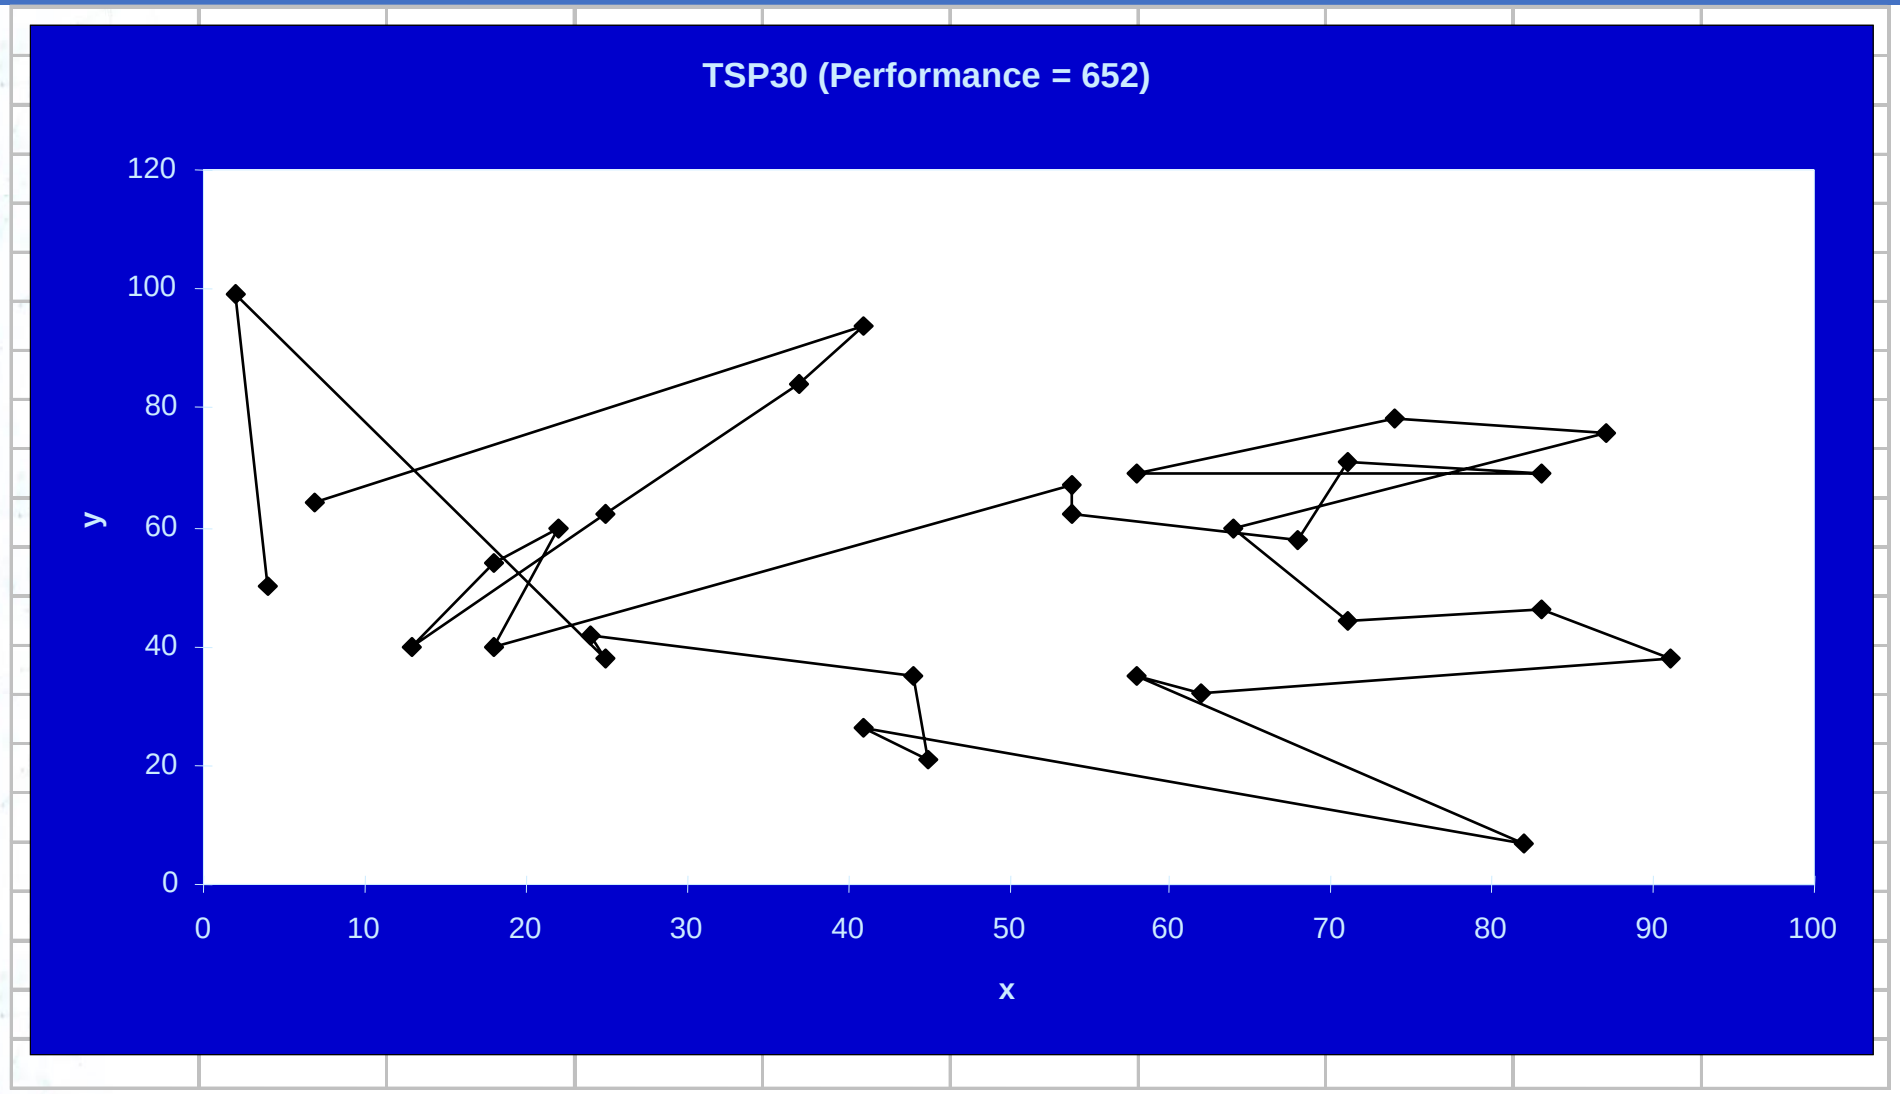

Wendy Willians. Genetic Algorithms: A tutorial.

Solução parcial (Distância = 420)

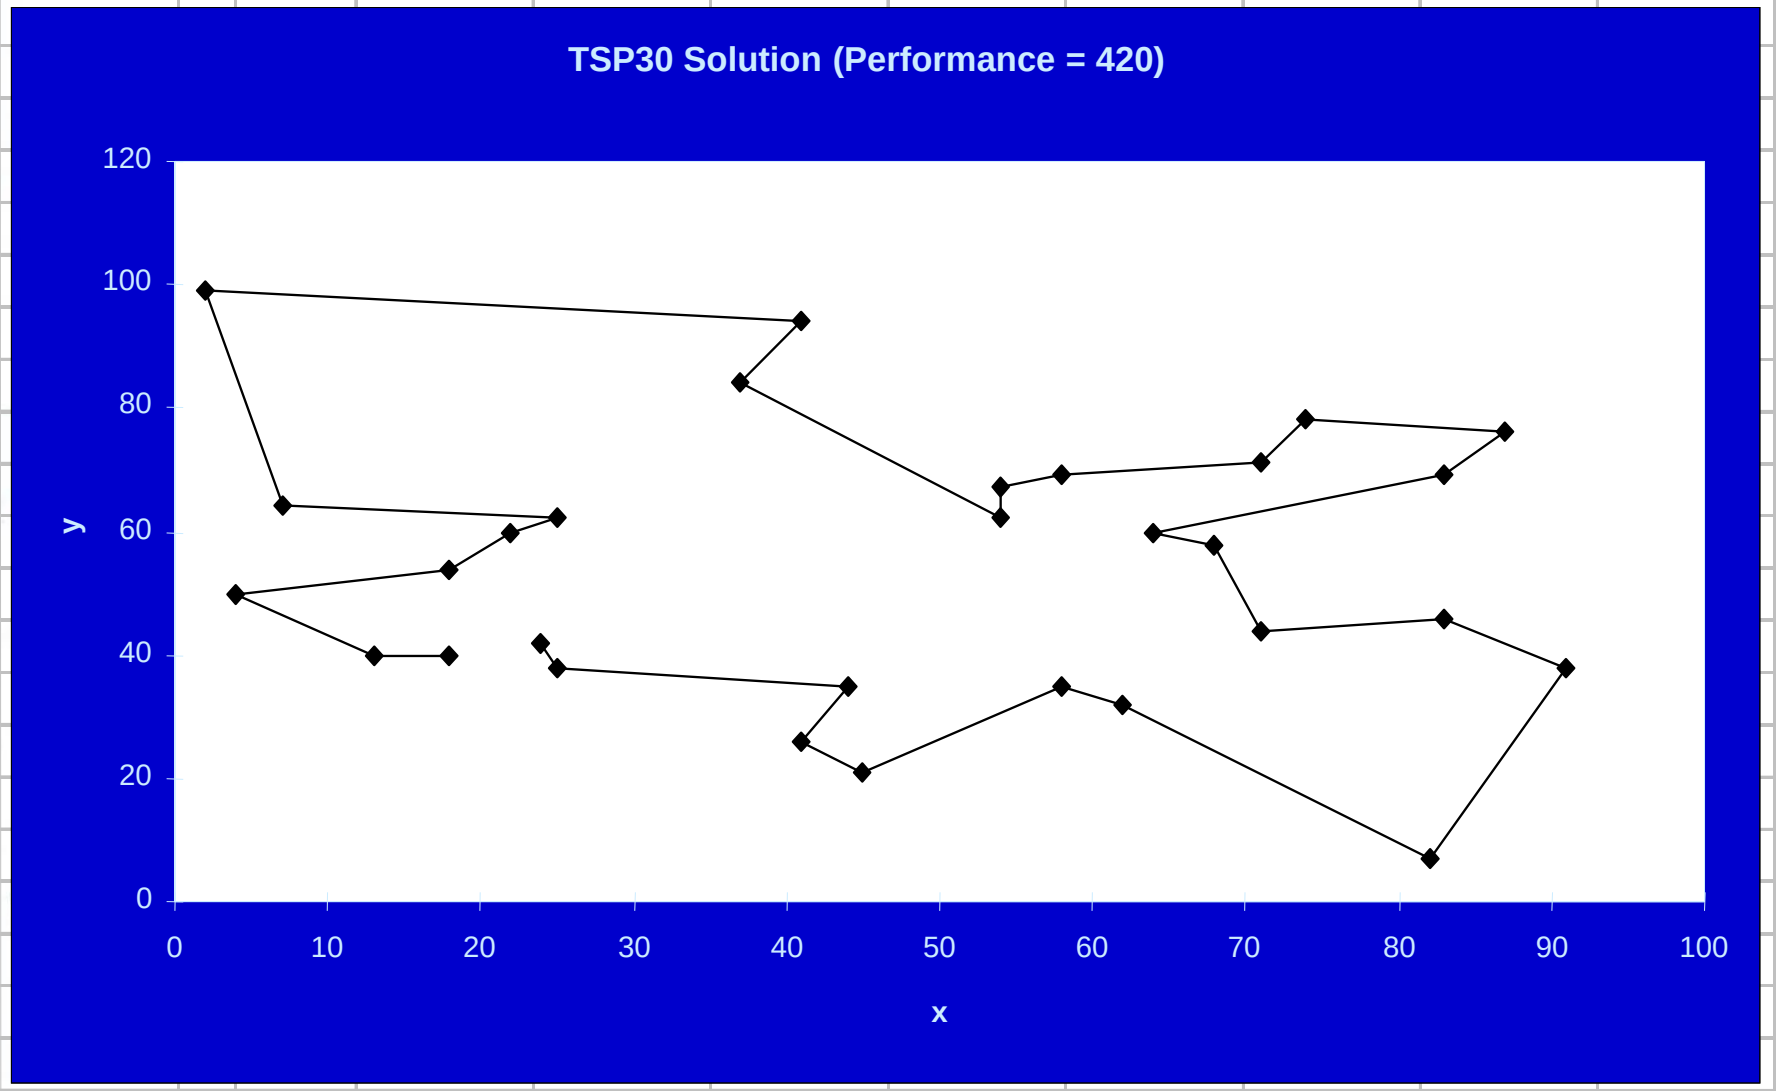

Gráfico da evolução do AG

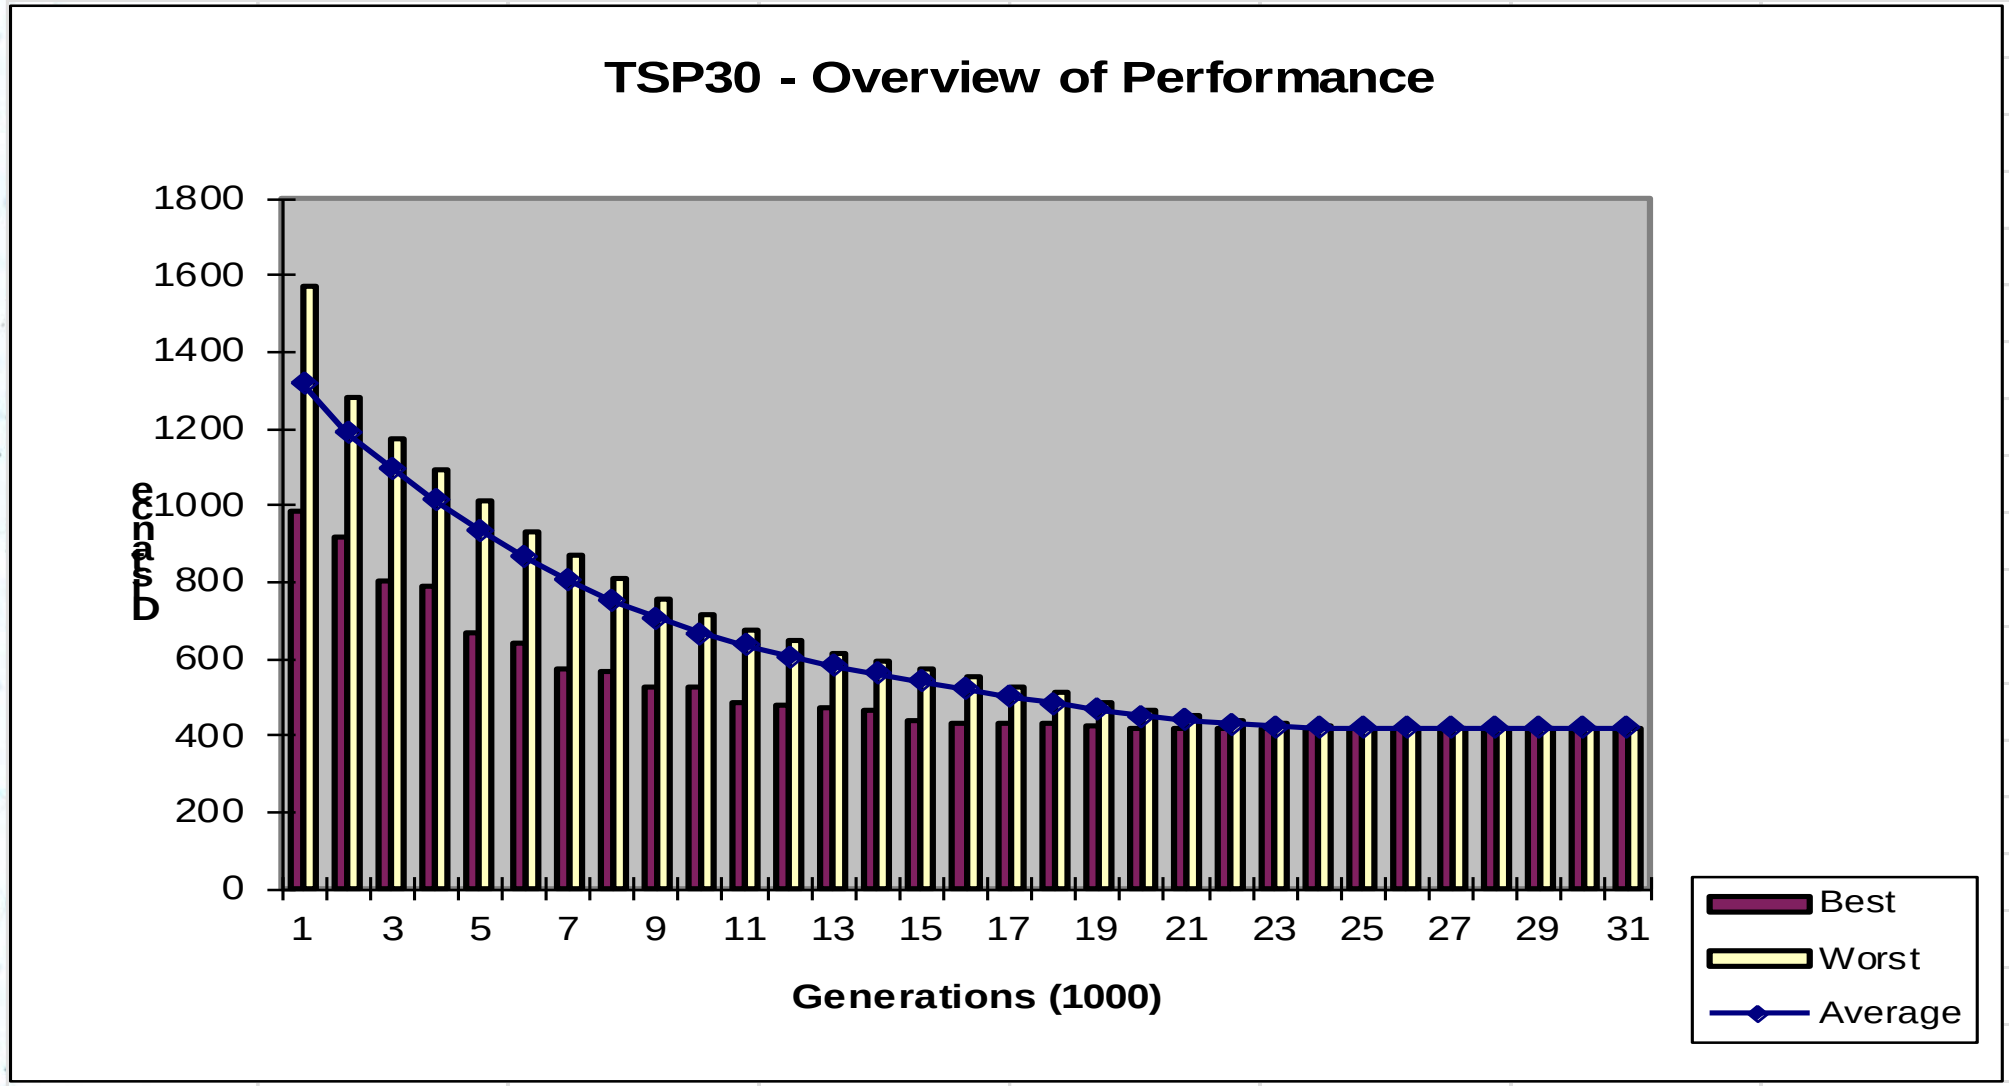

Wendy Willians. Genetic Algorithms: A tutorial.

Balanço

- Vantagens
  - Simples (várias representações, 1 algoritmo) e pouco sensível a pequenas variações
  - Vasto campo de aplicações
  - Ainda custa caro mas pode ser paralelizado facilmente

- Desvantagens
  - Como o método é basicamente numérico nem sempre é fácil introduzir conhecimento do domínio
  - Se não for paralelizado, pode demorar muito tempo para achar uma solução

Aplicação prática (CMU robots)

- Fazer o AIBO andar mais rápido
- Aprendeu com Algoritmos Genéticos
- Deixaram alguns AIBOs andando de um lado para outro por dias.
- Eles andavam por x segundos e avaliavam o quanto haviam andado por posicionamento em campo
- Ele se localizava por LANDMARKS nos extremos do campo

http://www-math.uni-paderborn.de/~junge/images/aibos.jpg

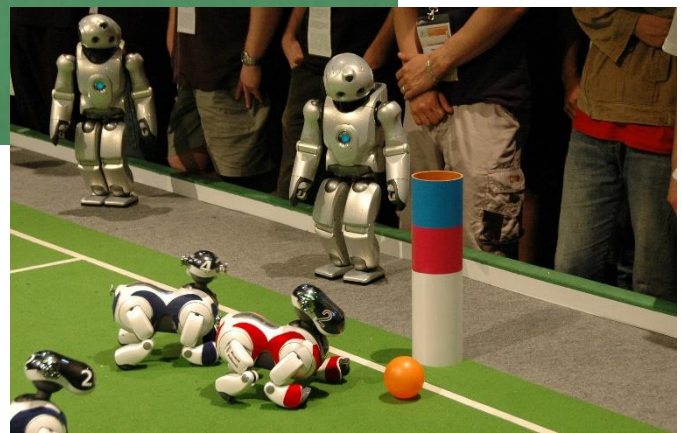

Make a Gif
Robocup Final 2005

Ensinando um quadrupede andar

Milton Heinen – Mestrado – 2007 - UNISINOS

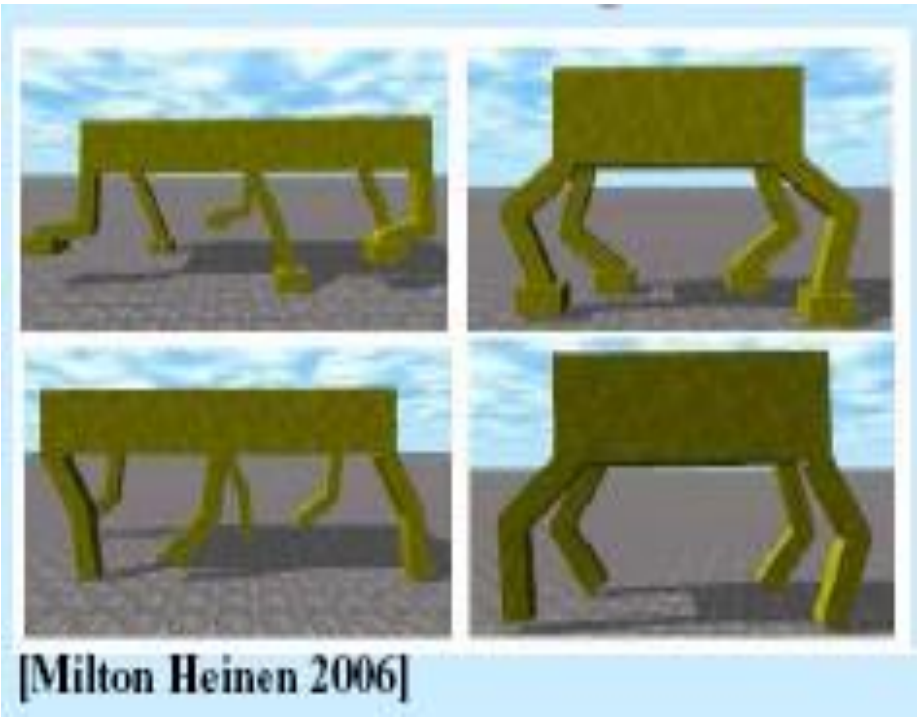

- Fitness: Ir mais longe, estável e mais rápido
- Ambiente e sensores Simulados.

Bibliografia de Algoritmos Genéticos

aprofundamento nos assuntos desta aula, segue a seguinte referência bibliográfica

Solange Rezende (Sistemas Inteligentes)

- Capítulo 9

- Alguns slides desta aula foram baseados no slides:
- Geber Ramalho: “Algoritmos Evolutivos”, UFPE.
- Wendy Willians. Genetic Algorithms: A tutorial.
- A.E. Eiben e J.E. Smith, Introduction to Evolutionary Computing Genetic Algorithms.
- Luis R. M. Lopes. Fundamentos dos Algoritmos Genéticos.
- Jennifer Pittman. Genetic Algorithm for Variable Selection. Duke University
- Carlos Eduardo Thomaz: Aulas do mestrado em RN. FEI 2010
- Grupo ICA – PUC-Rio