CC7711

Inteligência Artificial e Robótica

Prof. Dr. Flavio Tonidandel

Inteligência Coletiva

CC7711 - Inteligência Artificial e Robótica

Inteligência Coletiva(*Swarm Intelligence*)

Swarm Intelligence: "Qualquer tentativa de se desenvolver algoritmos ou dispositivos distribuídos de resolução de problemas inspirados no comportamento coletivo de colônias de insetos sociais ou outras sociedades animais" *[Bonabeau, Dorigo, and Theraulaz, 1999]*

- **Colônias Sociais de Insetos**
  - **Podem desenvolver sistemas complexos, inteligentes,,flexíveis e confiáveis**
  - **Cada indivíduo de uma sociedade**
    - **Segue regras simples, com comunicação local (trilhas de odores, sons, toques), de baixa demanda computacional**
  - **Estrutura Global do Sistema**
    - **Emerge a partir dos comportamentos individuais gerando um comportamento global inteligente**

Colônias de Insetos

- **Colônias Sociais de Insetos (Formigas, Cupins, Abelhas, etc.)**
  - Comportamentos complexos
  - Flexíveis e robustos
  - Comportamento do Inseto depende do de outros iguais a ele
- **Como surge esse comportamento inteligente de grupo ?**
  - **Auto-organização**
  - **Interações Locais**
    - Inseto a inseto
    - Inseto com o ambiente
  - **Especialização**
    - Cada inseto tem o seu objetivo/tarefa a cumprir

Colônia de Formigas
(Ant Colony Optimization – ACO)

Colônia de Formigas

- Formigas não possuem comportamentos individuais sofisticados, porém realizam tarefas complexas coletivamente
- Formigas possuem uma sofisticada sinergia baseada em sinais:
  - comunicação usando feromônios
  - Trilhas são definidas de modo que outras formigas podem seguir

Trilhas de Feromônios

- Espécies liberam trilhas de feromônios quando estão caminhando:
  - a partir da colônia
  - Para a colônia
  - Ambas as direções

- Feromônios evaporam.

- Feromônios se acumulam a medida que multiplas formigas usam a trilha

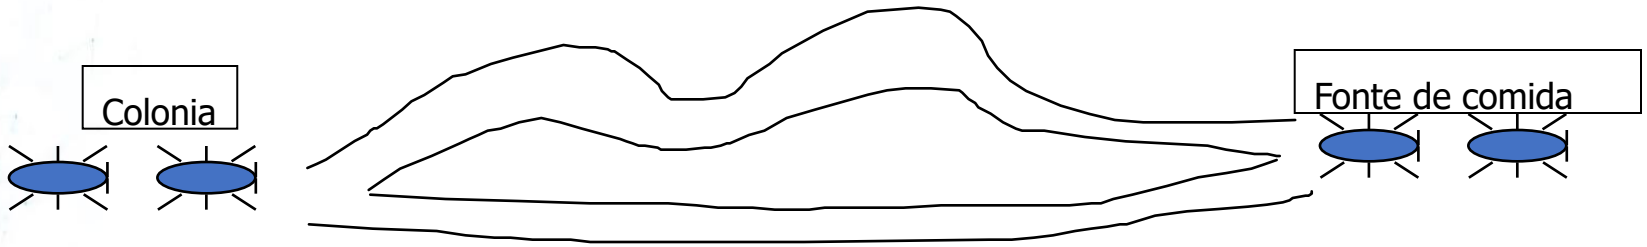

Colonia de Formigas: Problema de Rotas

- Idéia
  - Formigas soltam diferentes feromônios usados para computar o menor caminho entre a fonte e o destino
  - Sistema adaptativo e flexivel contra falhas ou congestionamento da rede
  - Usa somente conhecimento local para as rotas e assim evita verificar todos os nós da rede

Por que roteamento ?

Roteamento convecional depende de:

- Situação global de todos os nós
- controle centralizado
- Menor caminho fixado (algoritmo de Dijkstra);
- Habilidade limitada para lidar com congestionamento ou falhas.

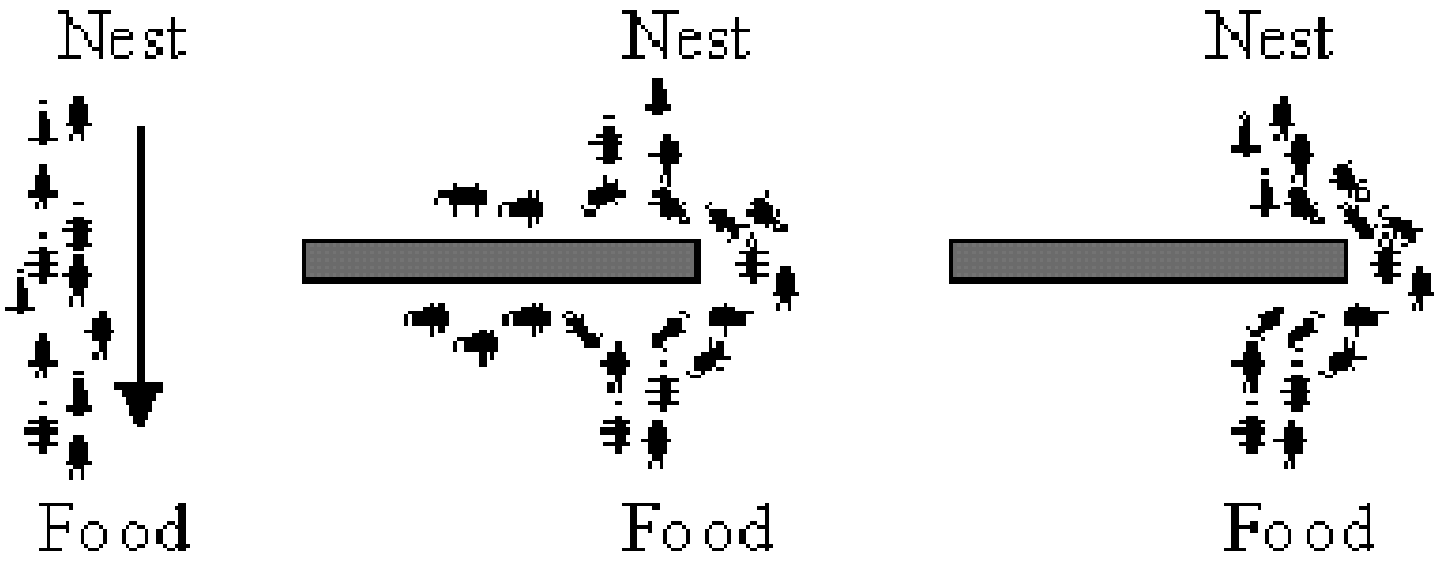

Colônia de Formigas

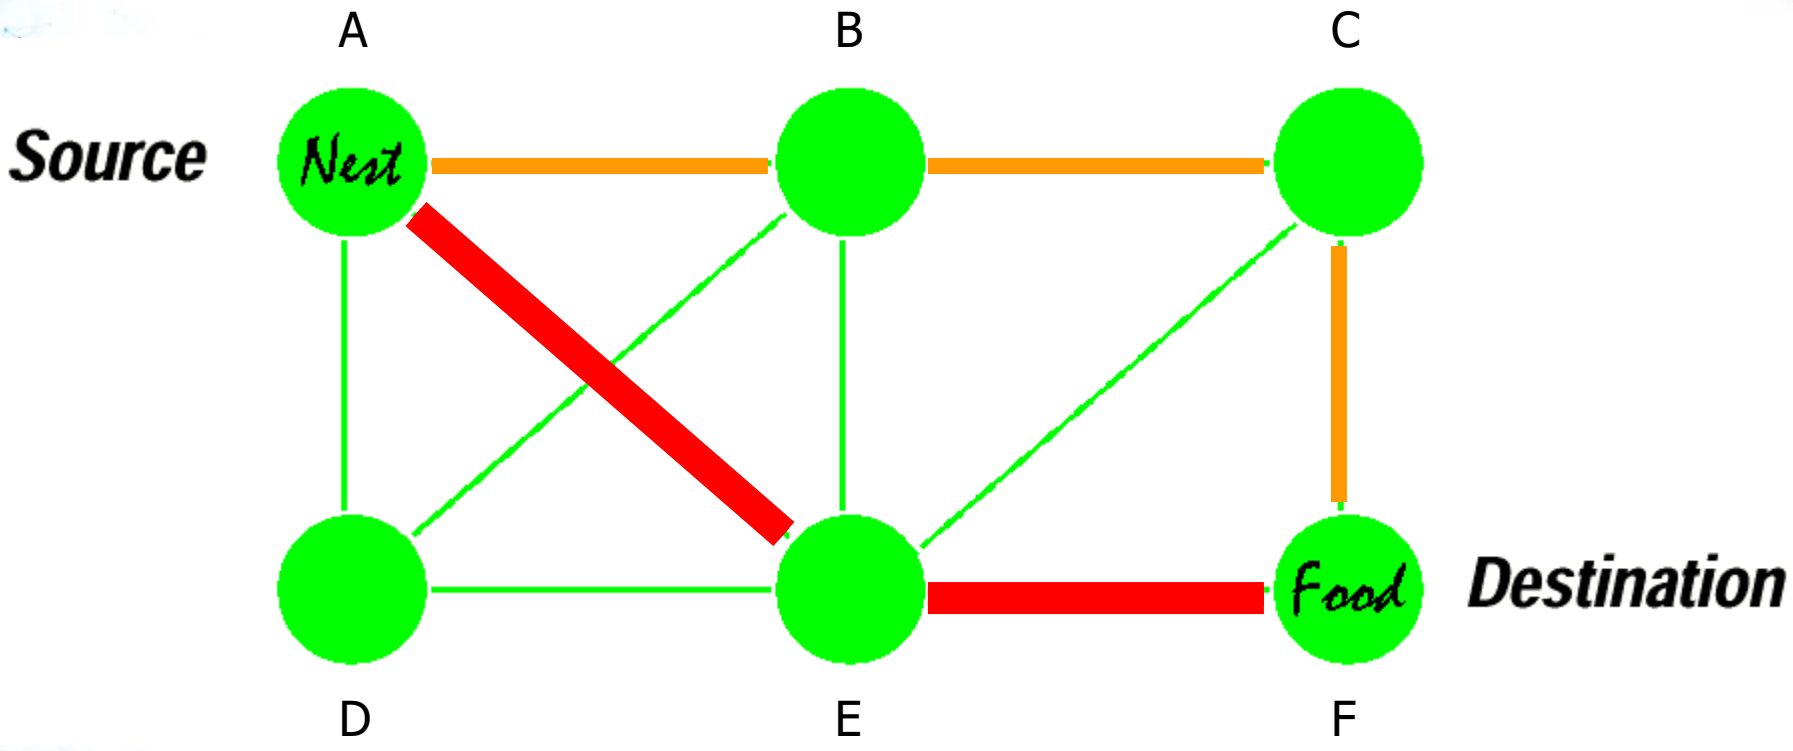

Colônia de Formigas

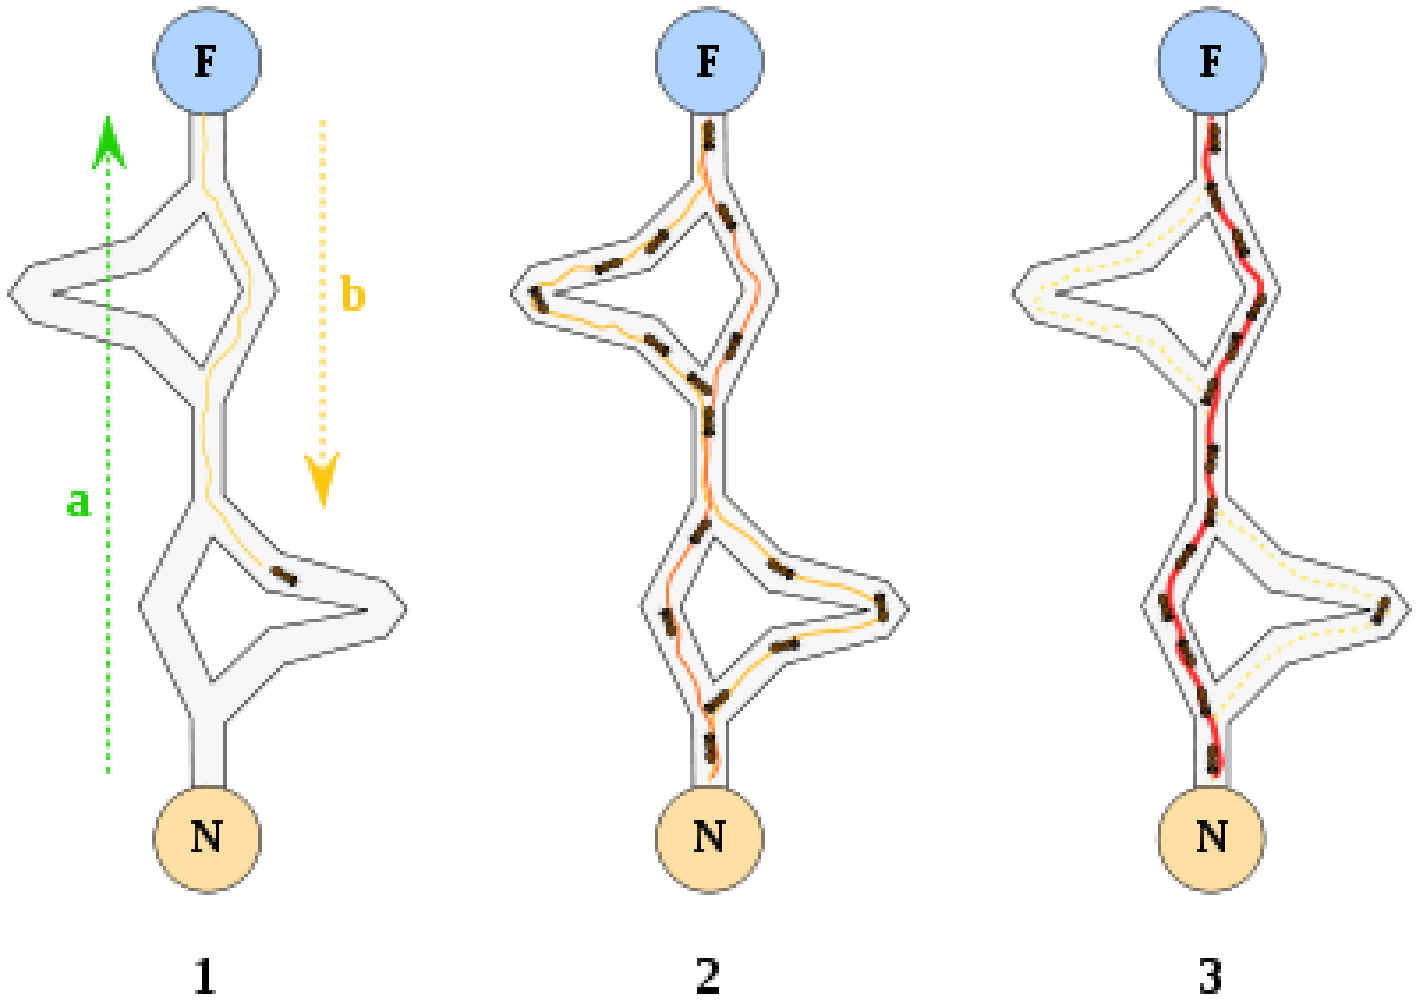

Como escolher o caminho a seguir ?

Probabilidade da formiga ir de i para j:

$$P_{ij} = \frac{\tau_{ij}^{\alpha}\eta_{ij}^{\beta}}{\sum_m \tau_{im}^{\alpha}\eta_{im}^{\beta}}$$

τ_{ij} = Quantidade de feromônios no trajeto entre *i* e *j* no instante *t*

α, ß são parâmetros de controle ajustáveis que determinam a sensividade do algoritmo quanto ao feromônio ou o caminho

m é a quantidade de caminhos a partir de i existentes.

η é uma função constante relacionada à distância entre i e j.
No caso como maior distância é ruim, η = **1 / distância i j**

Atualização de Feromônios

- Atualização de feromônios :

$$\Delta\tau_{ij}^{k} = Q / L^{k}(t) \quad if \ (i, j) \in T^{k}(t) \ else \ 0.$$

- T é o tour de i para j feito pela formiga k no tempo t, L é o tamanho desse tour e Q é uma heurística que determina a quantidade de feromonios.

- Evaporação de Feromônios em função do tempo

$$\tau_{ij}(t) = (1-\rho).\tau_{ij}(t) + \Delta\tau_{ij}(t)$$

  - ρ = taxa de evaporação

Colônias de Formigas

Alguns resultados práticos

- Algoritmos de Otimização por Colônias de Formigas
  - Extremamente bem-sucedidos na otimização de uma grande variedade de problemas combinatoriais de otimização de grande dificuldade
  - Algumas das melhores soluções para alguns problemas conhecidos (Caxeiro Viajante)

- Controle de Sistemas de Telecomunicações Baseados em Formigas
  - Soluções extremamente flexíveis
  - Melhor solução para alguns problemas

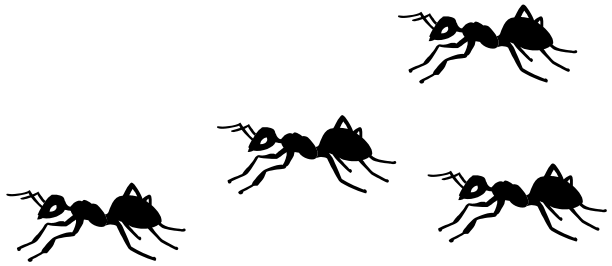

ACO aplicada no Caixeiro Viajante

O objetivo é encontrar a viagem de ida e volta mais curta para ligar todas as cidades sem repetição. O algoritmo geral é relativamente simples e baseado em um conjunto de formigas, cada uma fazendo uma possível viagem de ida e volta pelas cidades. Em cada etapa, a formiga escolhe se muda de uma cidade para outra de acordo com algumas regras:

1. Deve visitar cada cidade exatamente uma vez;
2. Uma cidade distante tem menos chance de ser escolhida (a visibilidade);
3. Quanto mais intensa for a trilha de feromônio disposta em uma borda entre duas cidades, maior a probabilidade de que essa borda seja escolhida;
4. Tendo completado sua jornada, a formiga deposita feromônios em todas as arestas que percorreu;
5. Após cada iteração, rastros de feromônios evaporam

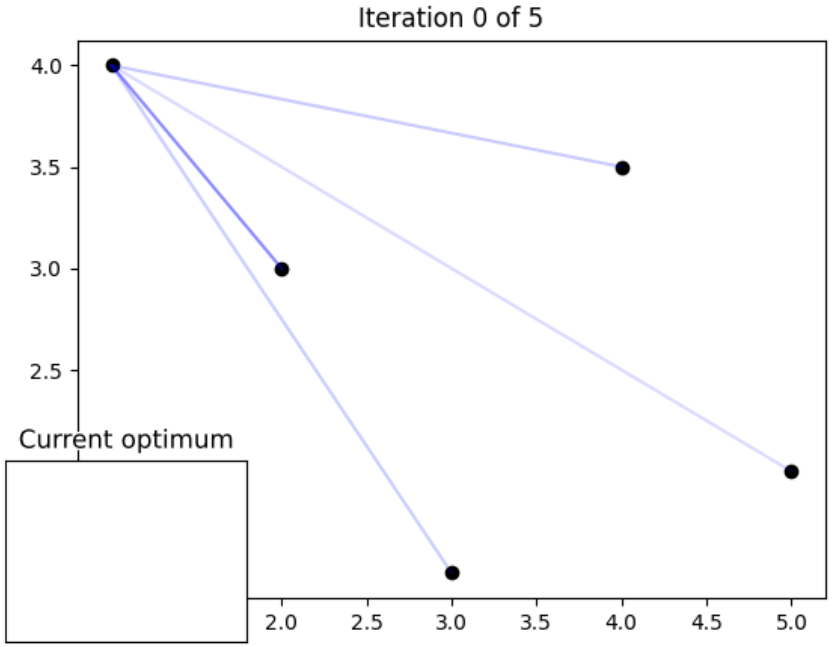

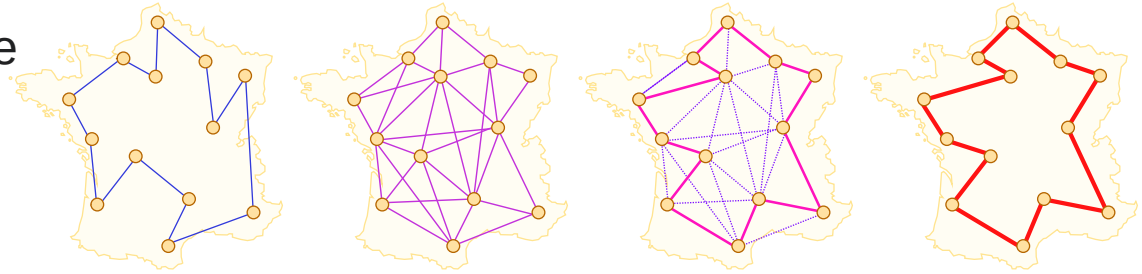

1 2 3 4

Imagem: wikipedia

ACO aplicado ao Caixeiro Viajante

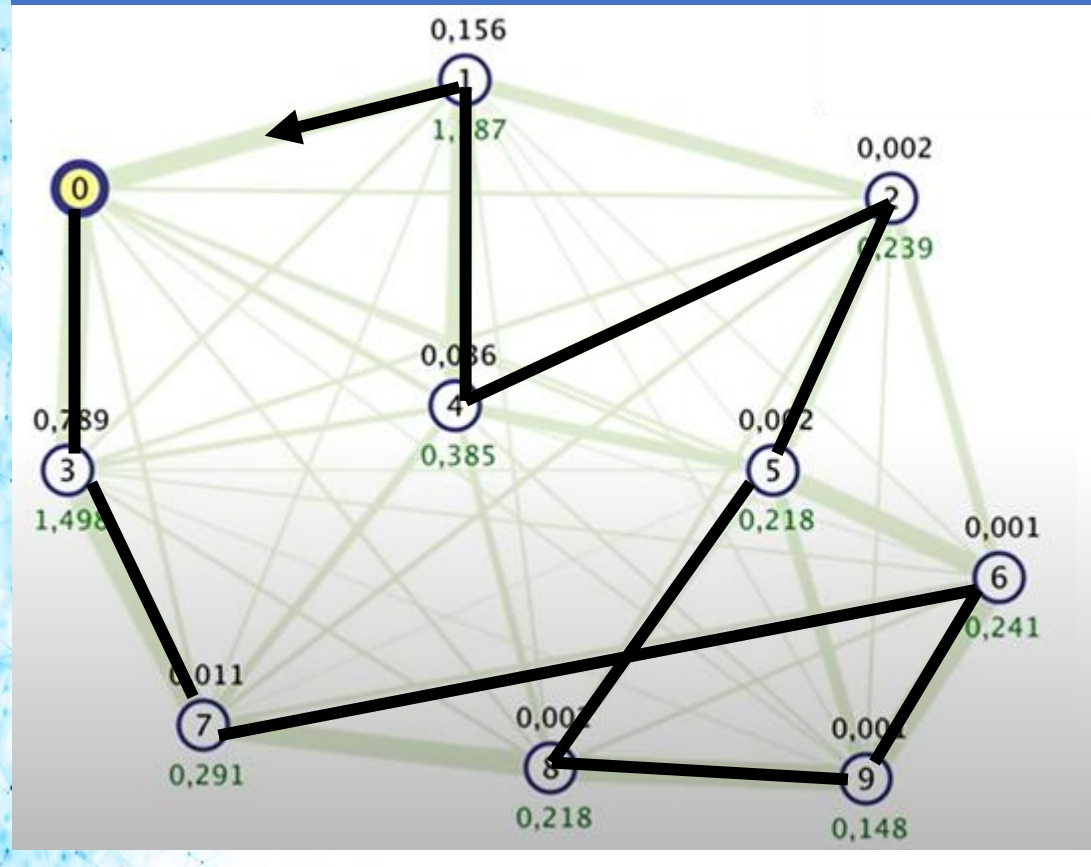

Tour completo da formiguinha

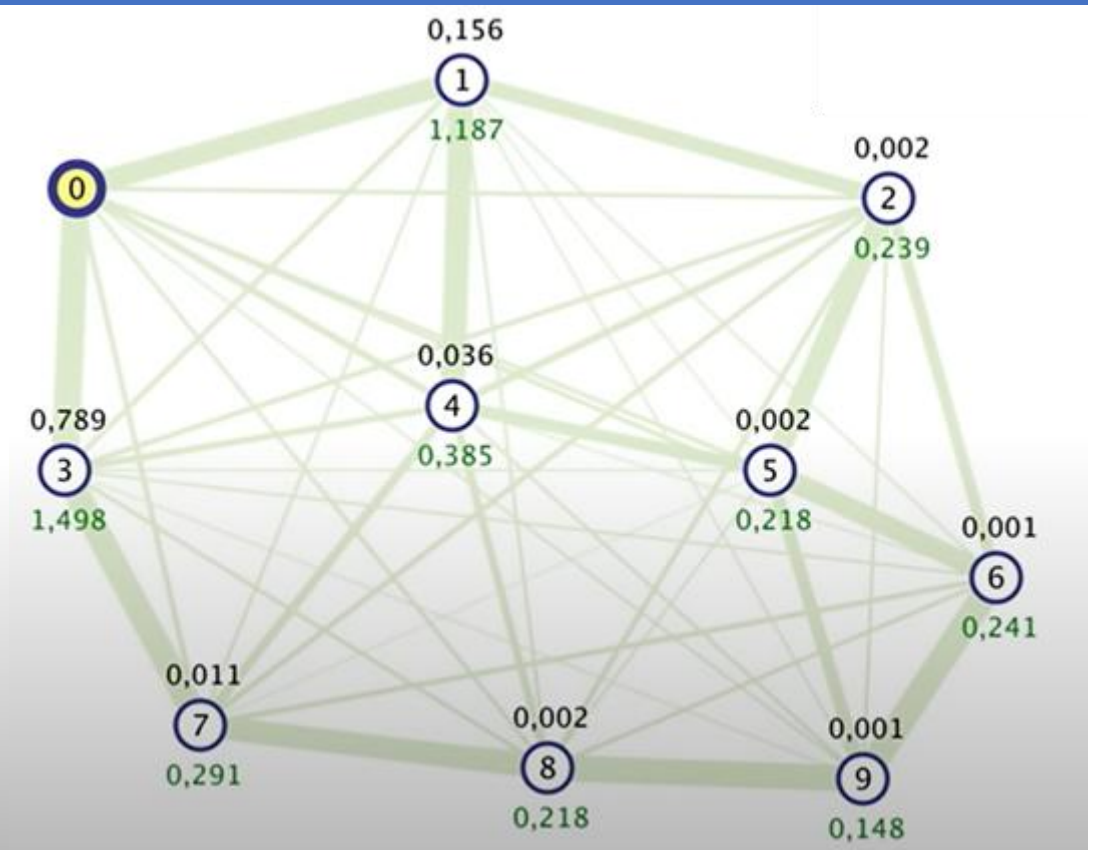

Trilhas com mais feromônios indicando o melhor trajeto entre todas as cidades

Imagens de do canal Simulife Hub – Youtube sobre ACO

Outras Aplicações de CF

Problemas de roteamento de veículos:

roteamento de veículos de vários depósitos
roteamento de veículo de entrega dividida
roteamento de veículos com coleta e entrega
roteamento de veículos com janelas de tempo
roteamento de veículos com vários trabalhadores em serviço

Problema de conjunto

Problema de conjunto de cobertura (set cover)
Problema de partição (partition problem)
Problema de partição de árvore de grafos com restrição de peso
Problema de mochila múltipla (Multiple Knapsack problem)
Problema máximo de conjunto independente

Problemas de Escalonamento:

Escalonamento de oficinas de trabalho
Escalonamento de loja aberta
Escalonamento de agendamento de projetos com restrição de recursos
Escalonamento de sequência de montagem

Outros problemas:

Projeto Físico de Nanoeletrônica
Previsão de falência
Roteamento de rede orientado à conexão
Mineração de dados
Concepção de redes de energia e eletricidade
Projeto de peptídeos inibitórios para interações proteicas
Projeto de circuitos eletrônicos de potência
Enovelamento de proteínas

Fonte: wikipedia

PSO – Particle Swarm Optimization

Particle Swarm Optimization (PSO)

Simples Algoritmo

- Método computacional interativo para minimização de função
- Se está função representar um problema, ela otimiza esta solução
- A função que deve ser minimizada é uma função que mede a distância de uma ou mais partículas à uma possível solução de melhor qualidade.
- Criado por Russell C. Eberhart and James Kennedy em 1995
- Inspirado no comportamernto social de acasalamento das aves e cardumes de peixes

Particle Swarm Optimization (PSO)

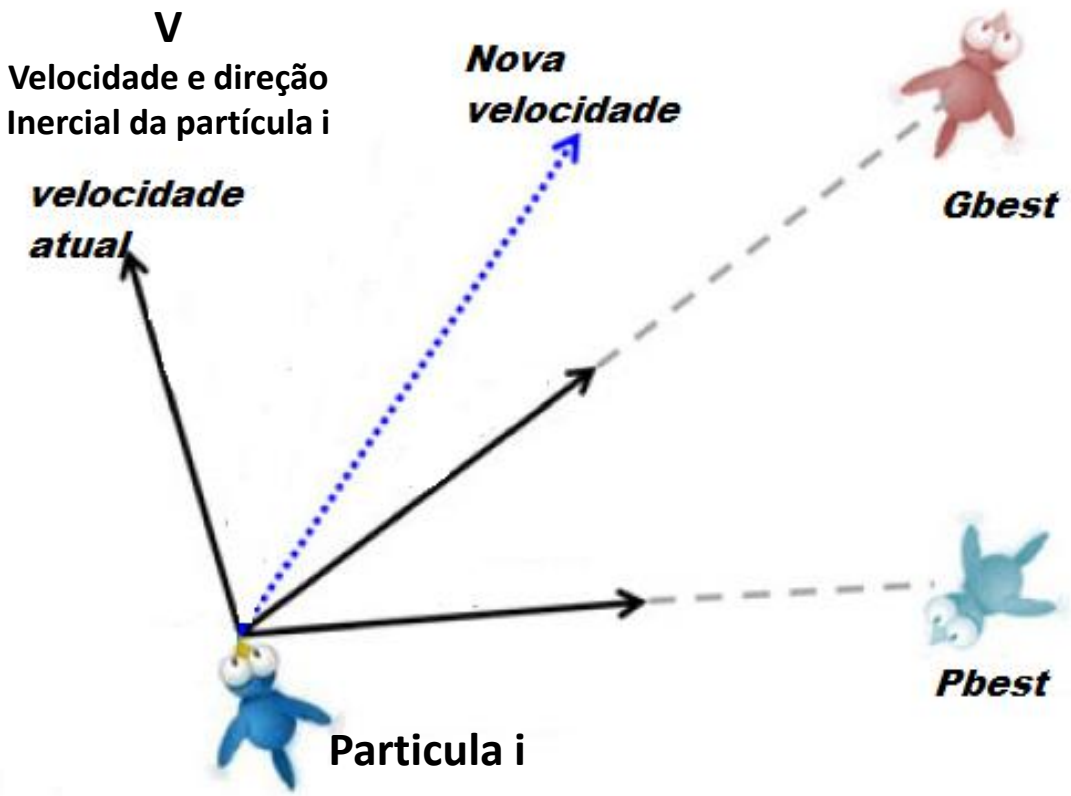

Global best
Melhor posição encontrada por todas as partículas

Personal best
Melhor posição encontrada pela partícula i

Imagem adaptada de: http://www.utdallas.edu/~jiezhang/research.html

Particle Swarm Optimization (PSO)

Para cada partícula p_i, sua nova velocidade vetorial v_i será:

$$v_i = w\boldsymbol{v_i} + c_1.rand().(\boldsymbol{pbest_i} - x_i) + c_2.rand().(\boldsymbol{gbest_i} - x_i)$$

$$x_i = x_i + v_i \quad \textit{(atualiza a posição da partícula)}$$

onde:

$pbest_i$ é a melhor posição em que a partícula a_i já esteve

$gbest_i$ é a melhor posição em que algum vizinho de a_i já esteve.

w é o peso de inércia ; c_1 é o peso dado a pbest e c_2 é o peso dado a gbest

x_i é a posição atual da partícula i

Rand() são números aleatórios entre 0 e 1, que permitem explorar um pouco regiões ao redor.

Particle Swarm Optimization (PSO)

$$v_i = \boxed{wv_i} + \boxed{c_1.rand().(pbest_i - x_i)} + \boxed{c_2.rand().(gbest_i - x_i)}$$

Termo de Inércia
Força a partícula
a manter sua
velocidade e
direção atuais

Termo Cognitivo
Força a partícula
a voltar para uma posição
anterior melhor

Tendência Conservativa

Termo Aprendizado Social
Força a partícula
a aprender e seguir a melhor
posição já alcançada por uma
partícula

Influência Social

Particle Swarm Optimization (PSO)

Parâmetros a serem definidos:

1 – **Número de partículas**
Estima-se que entre 10 e 50 seja um bom número de partículas iniciais. Elas devem ser bem espalhadas para evitar mínimos locais.

2 – **Constantes C1, C2 e W**
Usualmente C1+C2 = 4.
W foi originalmente definido como 1,
mas tem-se explorado valores diferentes para W

3 – **Velocidade máxima da partícula**
Vmax – baixa velocidade = demora em convergir
alta velocidade = muita instabilidade

4 – **Critério de parada**
Solução alcançada; velocidade baixa das partículas; pouca movimentação; etc

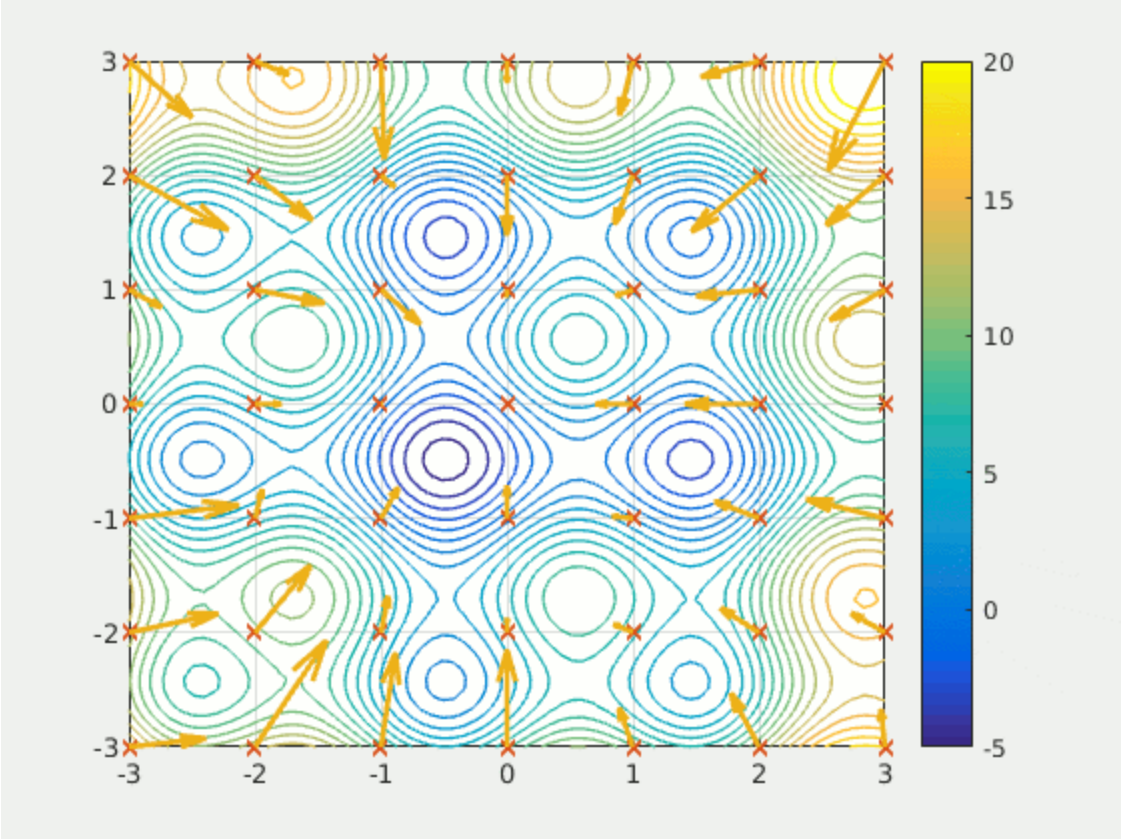

Imagem: wikipedia

Aplicações de Particle Swarm Optimization (PSO)

Posicionamento de robôs em um jogo de futebol:

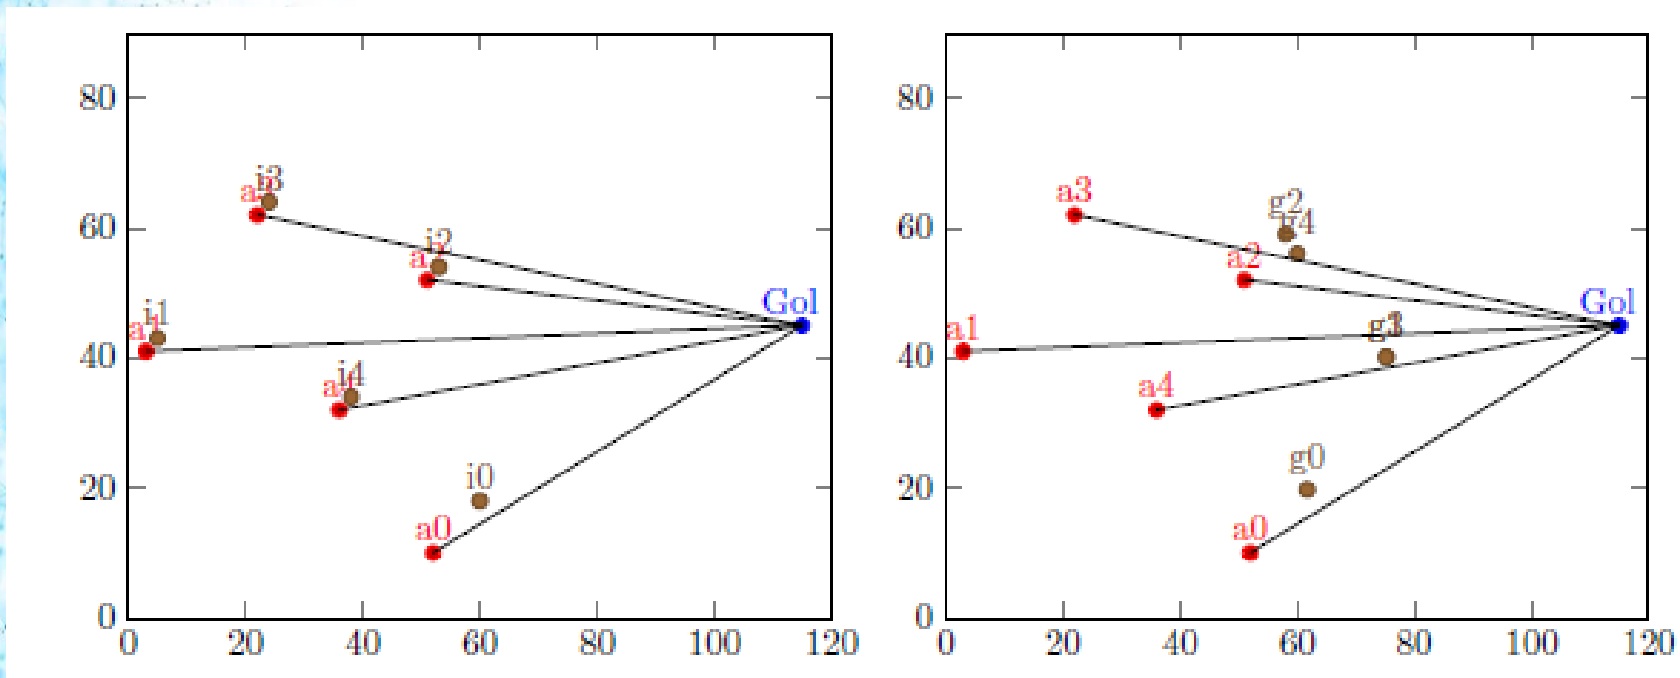

Cada partícula é um cenário que envolve a posição de 5 robôs

Aplicações de Particle Swarm Optimization (PSO)

Segmentação de imagem:

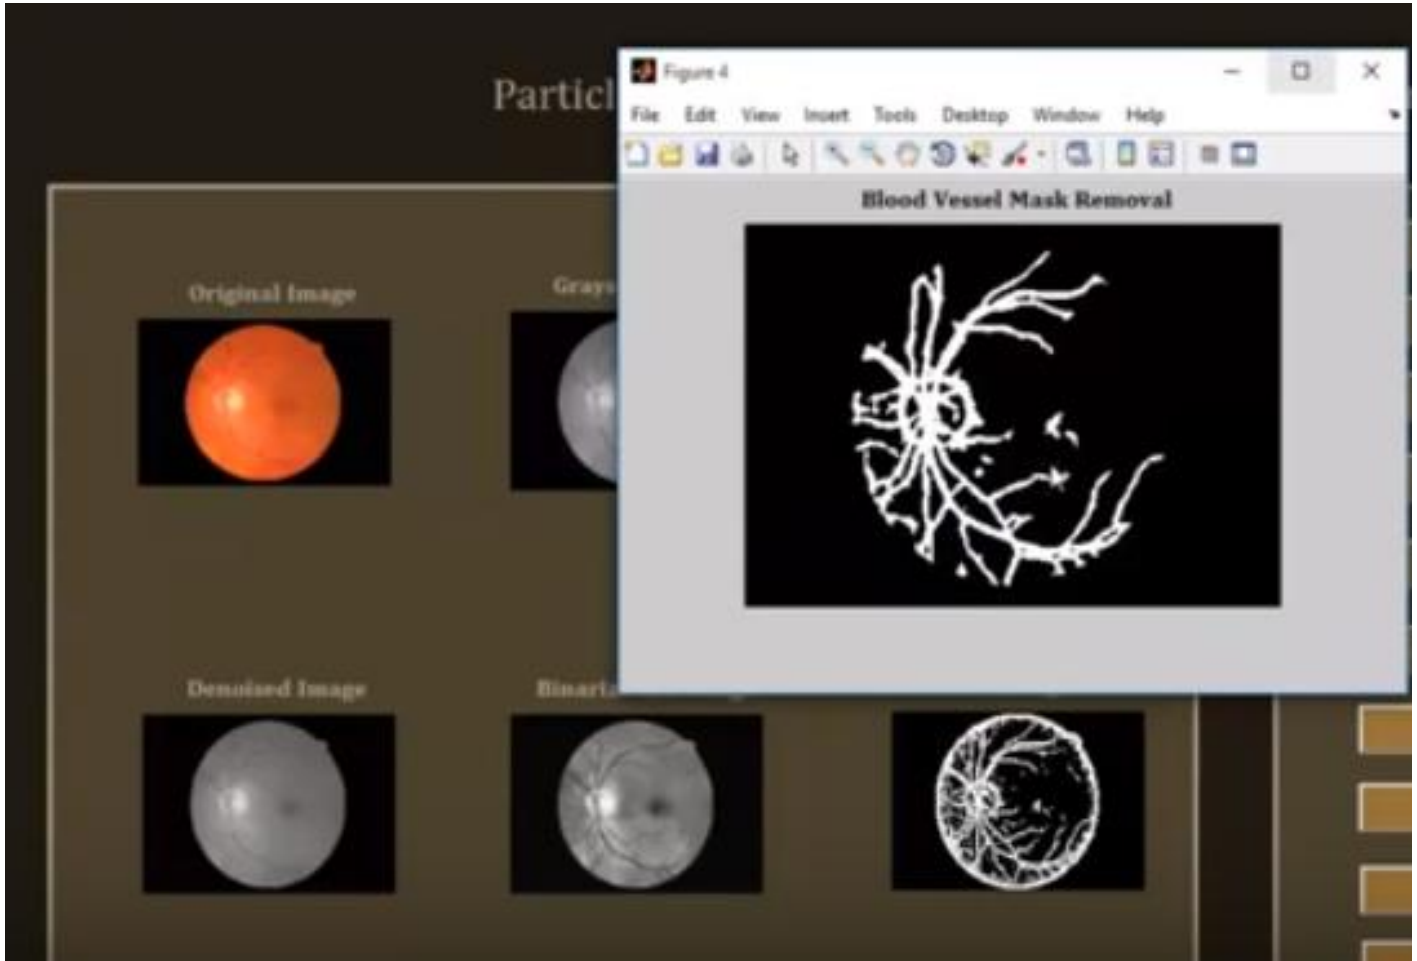

Robótica baseada em *Swarms*

Múltiplos Robôs

- Vantagens significativas em relação a robôs individuais
  - Sensoreamento e ação em múltiplos lugares
  - Reconfiguração dependente da tarefa
  - Divisão de trabalho eficiente
  - Robustez devido à redundância e adaptabilidade
  - Auto-organização de comportamento

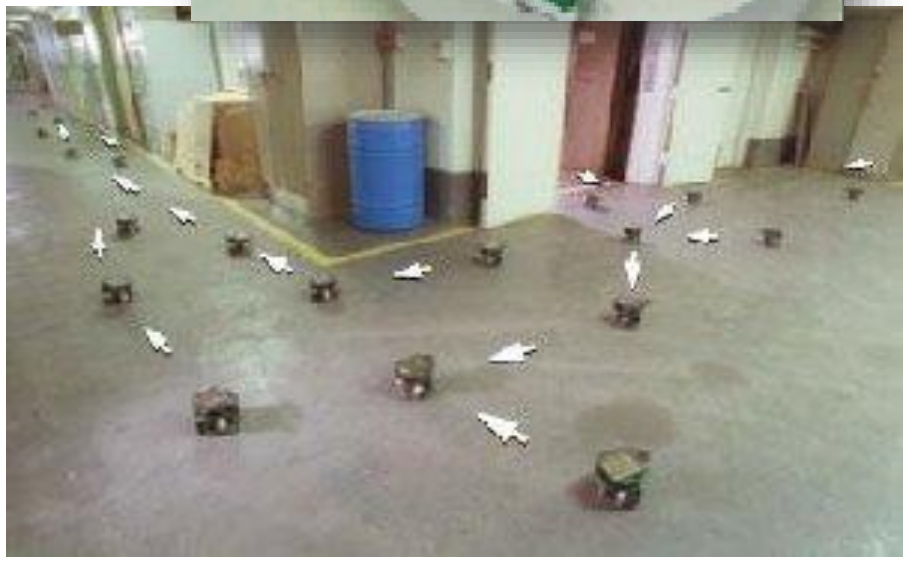

Bibliografia desta aula

Para aprofundamento da Aula de Inteligência Coletiva (Colônia Formiga):

Recomendação de Leitura

- M. Dorigo and T. Stützle. *Ant Colony Optimization*. MIT Press, Cambridge, MA, 2004.
- J. Kennedy and R. Eberhart. Swarm Intelligence. Morgan Kaufmann Publishers, Inc, San Francisco, CA, 2001
- J. Kennedy and R. Eberhart. Particle Swarm Optimization, in: Proc. IEEE Int'l. Conf. on Neural Networks (Perth, Australia), IEEE Service Center,Piscataway, NJ, IV:1942-1948.
- C.A. Coello Coello, G. Toscano, M.S. Lechuga. Handling Multiple Objectives with Particle Swarm Optimization. IEEE Transactions on Evol. Computation, Vol. 8, No. 3, June 2004.