CC7711

Inteligência Artificial e Robótica

Prof. Dr. Flavio Tonidandel

Aprendizado de Máquina

Métodos Estatísticos de Classificação – parte 1

CC7711 - Inteligência Artificial e Robótica

Machine Learning (Aprendizado de Máquina)

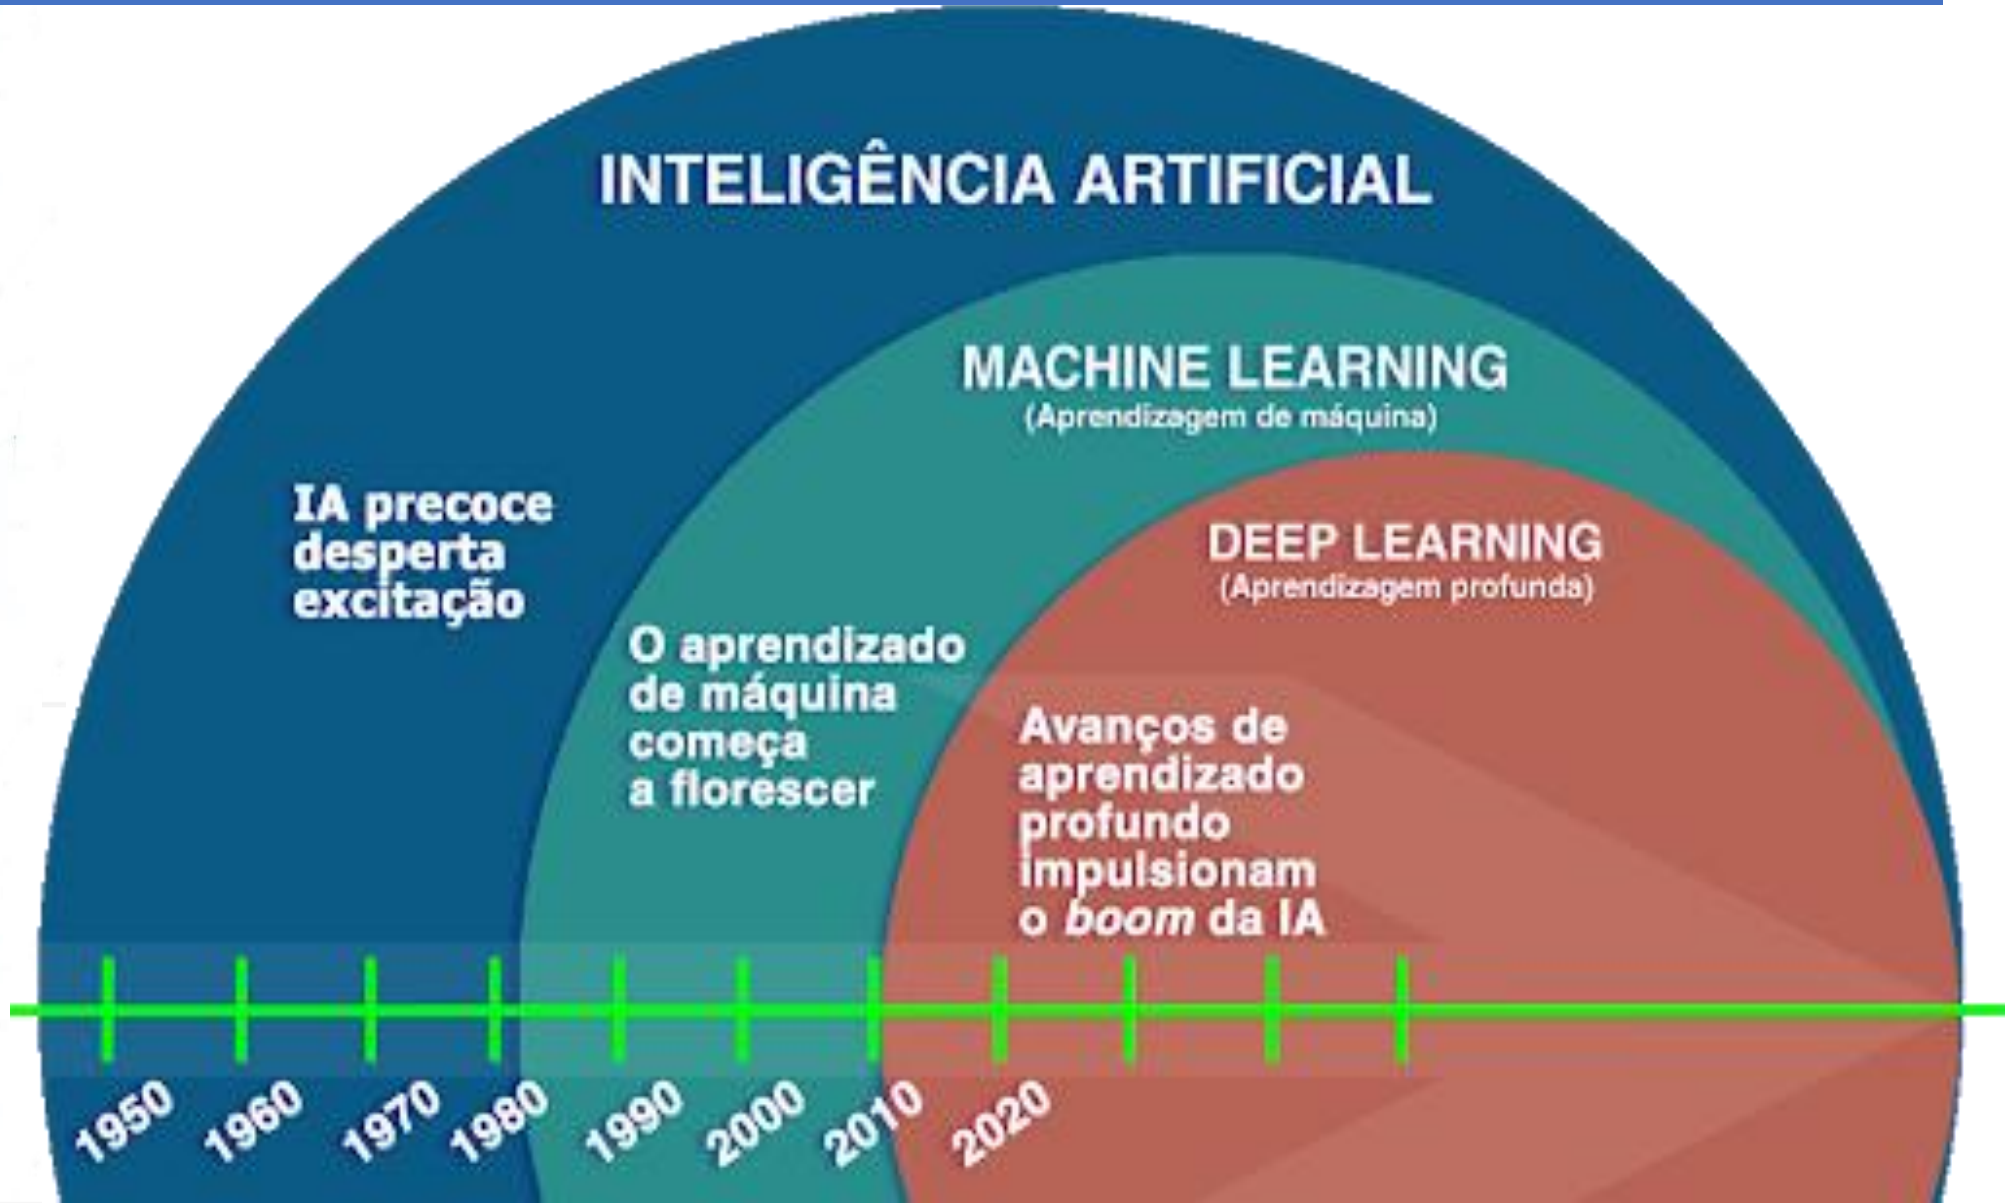

Imagem: BuZZrobot/Tradução: Thiago Zina Crepaldi - obtida em Comunica.ufu.br

Machine Learning - Definição

O Aprendizado de Máquina é uma disciplina científica que se preocupa com o design e o desenvolvimento de algoritmos que permitem aos computadores desenvolver comportamentos baseados em dados empíricos, como dados de sensores ou bancos de dados.

O objetivo principal de um aprendizado é generalizar a partir de sua experiência

Machine Learning - Aplicações

- Classificação, regressão, reconhecimento e previsão; Resolução de problemas e planejamento; Raciocínio e inferência; Mineração de dados; Mineração na web; Descoberta científica; Recuperação de informação; Processamento de linguagem natural; Projeto e diagnóstico; Visão e percepção de fala; Robótica e controle; Otimização combinatória; Jogos; Aplicações industriais, financeiras e científicas de todos os tipos.

Fonte: Journal of M

Tipos de Machine Learning

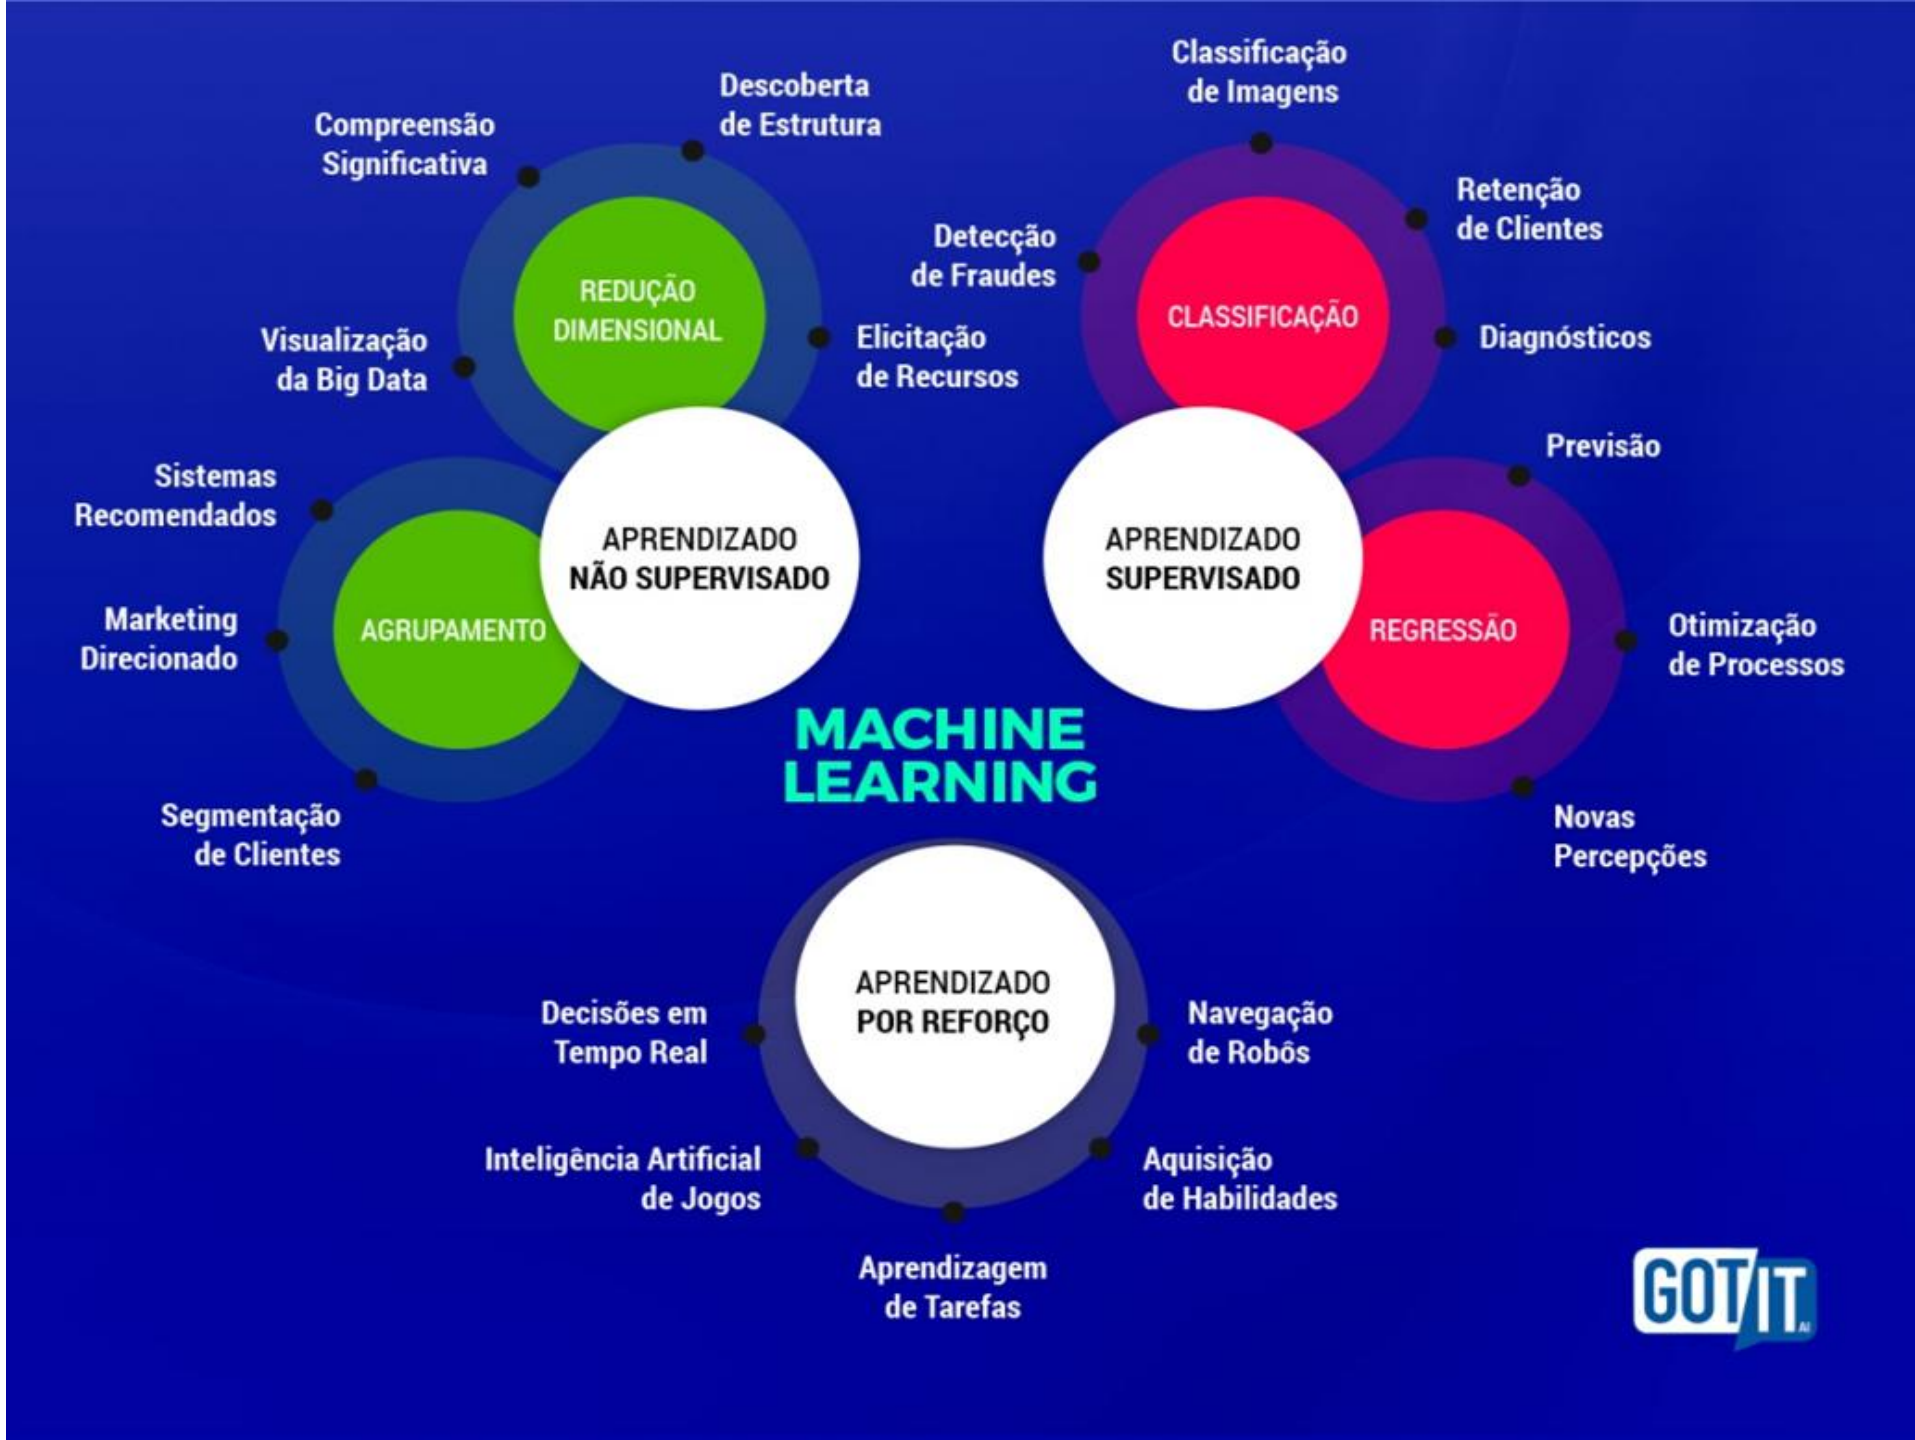

Fonte: https://blog.gotit.ai/por-que-o-aprendizado-de-maquina-se-tornou-indispensavel

Machine Learning - Taxonomia

- **Aprendizado supervisionado:** aprende com base em exemplos pré-classificados - par entrada-saída
- **Aprendizado não supervisionado:** as respostas desejadas não são conhecidas. O algoritmo descobre por si mesmo propriedades e similaridades do sistema.
- **Aprendizado por reforço:** no aprendizado por reforço um agente aprende a agir diante da observação do mundo, recebendo recompensas e castigos.

Machine Learning - Taxonomia

- **Aprendizado supervisionado:** aprende com base em exemplos pré-classificados - par entrada-saída
  - **Regressão**: Métodos dos Mínimos Quadrados
  - **Classificação**: Aprendizado Indutivo; Redes Neurais; Deep Learning; Métodos Estatísticos (KNN; SVM; etc)
- **Aprendizado não supervisionado:** as respostas desejadas não são conhecidas. O algoritmo descobre por si mesmo propriedades e similaridades do sistema.
  - **Agrupamento**: K-means

Regressão Linear

Métodos Mínimos Quadrados

Regressão Linear: Mínimos Quadrados

- **Busca o melhor ajuste para um conjunto de dados tentando minimizar a soma dos quadrados das diferenças entre o valor estimado e os dados observados**

Visa minimizar a soma:

$$S \equiv \sum_{i=1}^{N} (y_i^o - y_i)^2$$

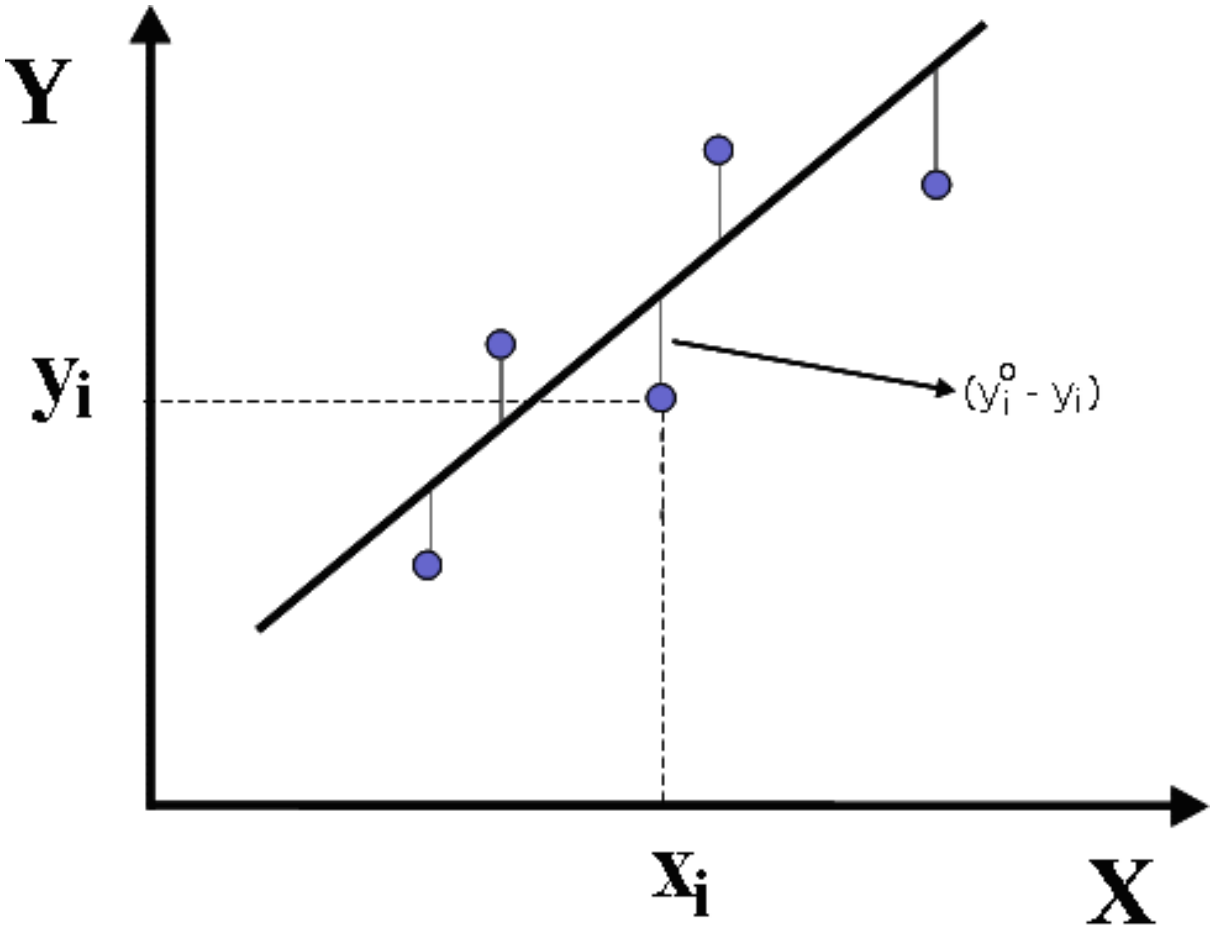

Fonte: http://astro.if.ufrgs.br/minq/

Regressão Linear: Mínimos Quadrados

- Uma vez que se encontra a reta, pode-se fazer previsões com dados de entrada diferentes dos observados

- É um aprendizado supervisionado! Dados de entrada e saída (x,y) são apresentados ao modelo!

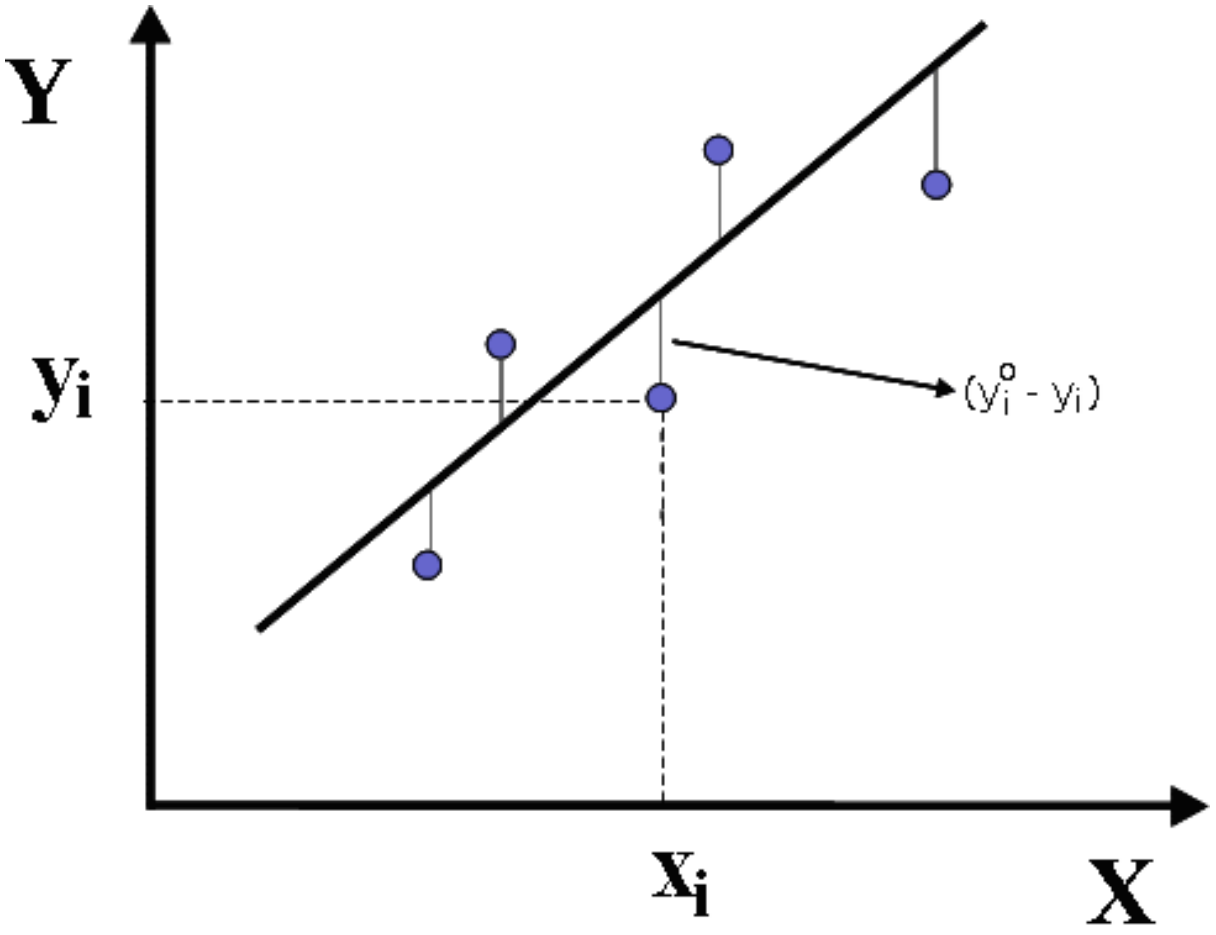

Método dos Mínimos Quadrados - Least Squares Method

- Como encontrar a reta ?

A reta possui o seguinte formato:

$$y_i = a + b.x_i$$

As equações para obtenção de a e b obtidas dos dados de amostragem são:

$$a = \bar{y} - b\bar{x}$$

$$b = \frac{\sum_{i=1}^{n} x_i \left(y_i - \bar{y}\right)}{\sum_{i=1}^{n} x_i \left(x_i - \bar{x}\right)}$$

Onde $\bar{x}$ e $\bar{y}$ são as médias dos dados x e dos dados y
n é a quantidade de dados (x,y) de amostragem

Método dos Mínimos Quadrados - Least Squares Method

- Exemplo: Consumo x Renda (ex. retirado do Wikipedia)
- As relações entre consumo e renda é conhecida em alguns casos (amostragem)

	Consumo y_i	Renda x_i
1	122	139
2	114	126
3	86	90
4	134	144
5	146	163
6	107	136
7	68	61
8	117	62
9	71	41
10	98	120
Soma	1063	1082
Média	106,30	108,20

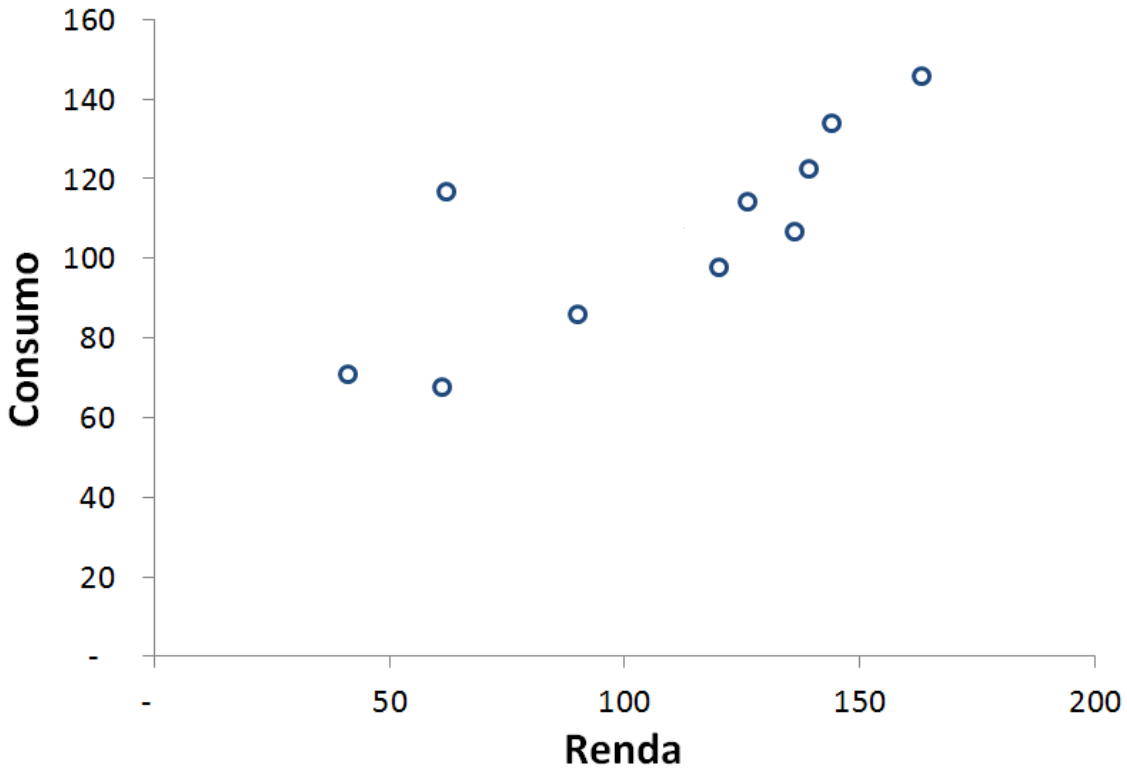

Método dos Mínimos Quadrados - Least Squares Method

$$a = \bar{y} - b\bar{x}$$

$$b = \frac{\sum_{i=1}^{n} x_i \left(y_i - \bar{y}\right)}{\sum_{i=1}^{n} x_i \left(x_i - \bar{x}\right)}$$

Onde $\bar{x}$ = 108,20 e $\bar{y}$ = 106,30
n = 10

Aplicando as equações acima:

$$b = \frac{7.764,40}{15.671,60} = 0,4954$$

$$a = 106,30 - 0,4954 \times 108,20 = 52,69$$

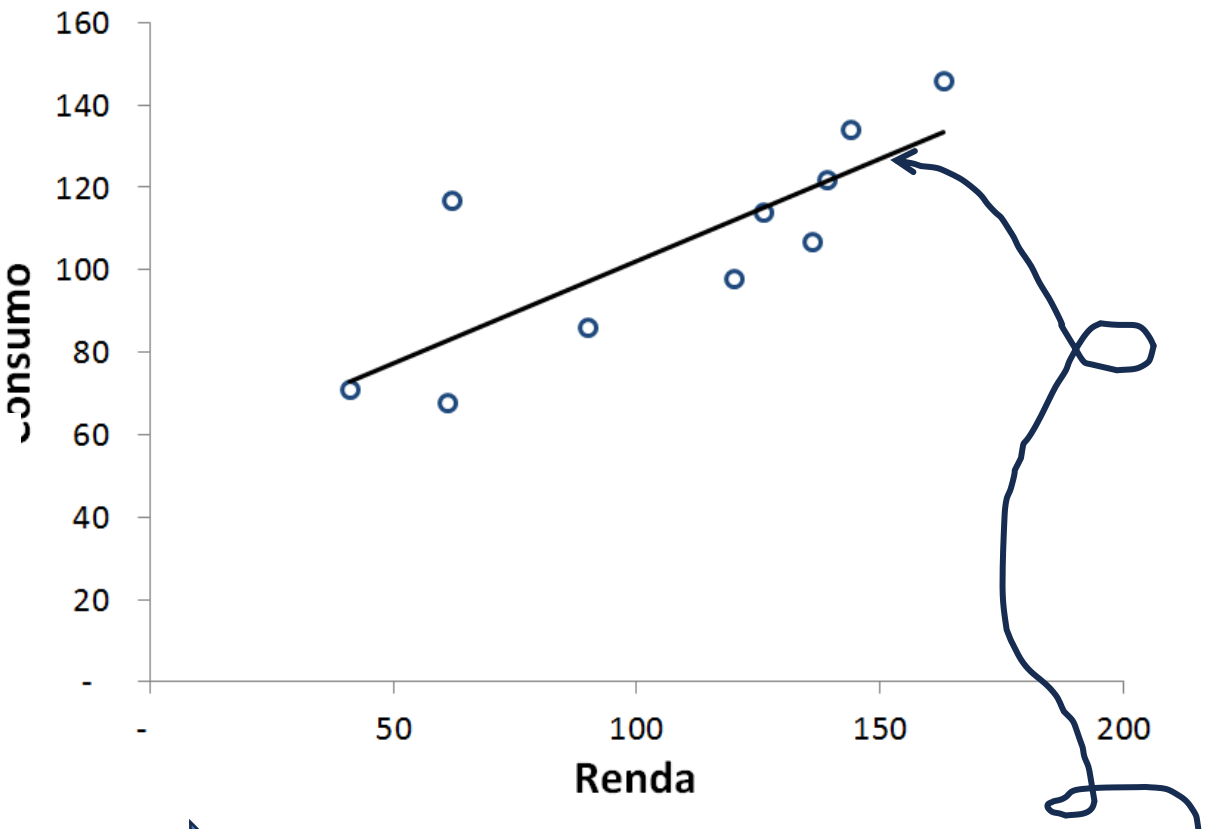

$$Consumo = 52,69 + 0,4954 \times Renda$$

Método dos Mínimos Quadrados - Least Squares Method

- Com o Método dos Mínimos Quadrados pode-se encontrar uma reta que se ajusta bem aos dados
- Com a reta, podemos fazer previsões!

$$Consumo = 52,69 + 0,4954 \times Renda$$

***Interpretação*: Existe uma parte do Consumo que não é influenciada pela Renda, e a que é influenciada, a cada incremento de $ 1 na Renda causa um incremento esperado de $ 0,4954 no Consumo**

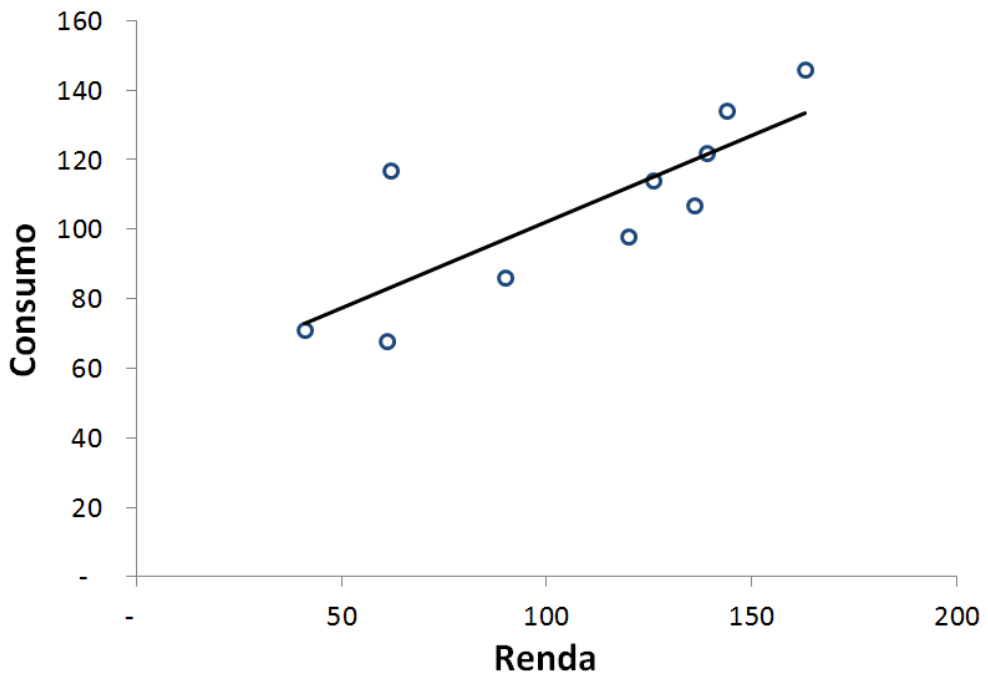

Codificando em Python

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

# 1) Dados (os seus) ------------------------------------------------
x = np.array([139, 126,  90, 144, 163, 136,  61,  62,  41, 120])  # Renda
y = np.array([122, 114,  86, 134, 146, 107,  68, 117,  71,  98])  # Consumo
X = x.reshape(-1, 1)  # scikit-learn espera matriz 2D

# 2) Ajuste do modelo ------------------------------------------------
model = LinearRegression()
model.fit(X, y)

b0 = model.intercept_      # intercepto
b1 = model.coef_[0]        # inclinação
# Previsões nos próprios dados (só para demonstrar)
y_hat = model.predict(X)
r2 = r2_score(y, y_hat)
print(f"Modelo: Consumo = b0 + b1 * Renda")
print(f"b0 (intercepto) = {b0:.4f}")
print(f"b1 (inclinação) = {b1:.4f}")
print(f"R² = {r2:.4f}")

# 3) Gráfico: pontos + reta ------------------------------
x_line = np.linspace(x.min(), x.max(), 200).reshape(-1, 1)
y_line = model.predict(x_line)
plt.figure()
plt.scatter(x, y, label="Dados (Renda, Consumo)")
plt.plot(x_line, y_line, label="Reta ajustada")
plt.xlabel("Renda (x)")
plt.ylabel("Consumo (y)")
plt.grid(True, alpha=0.3)
plt.legend()
plt.show()
```

Regressão Logística

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Nota
0,5	1,2
0,75	3,5
1	2,4
1,25	2
1,5	1,4
1,75	4,2
1,75	5,1
2	3
2,25	5,5
2,5	3,4
2,75	6,7
3	4,5
3,25	7
3,5	3,9
4	8
4,25	7,5
4,5	9
4,75	9,1
5	8,9
5,5	9,6

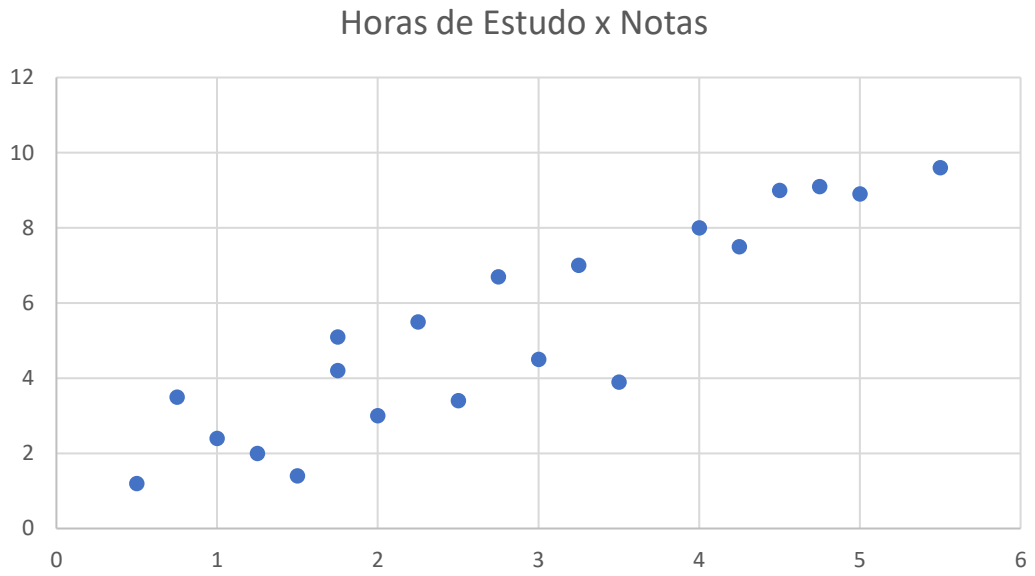

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Nota
0,5	1,2
0,75	3,5
1	2,4
1,25	2
1,5	1,4
1,75	4,2
1,75	5,1
2	3
2,25	5,5
2,5	3,4
2,75	6,7
3	4,5
3,25	7
3,5	3,9
4	8
4,25	7,5
4,5	9
4,75	9,1
5	8,9
5,5	9,6

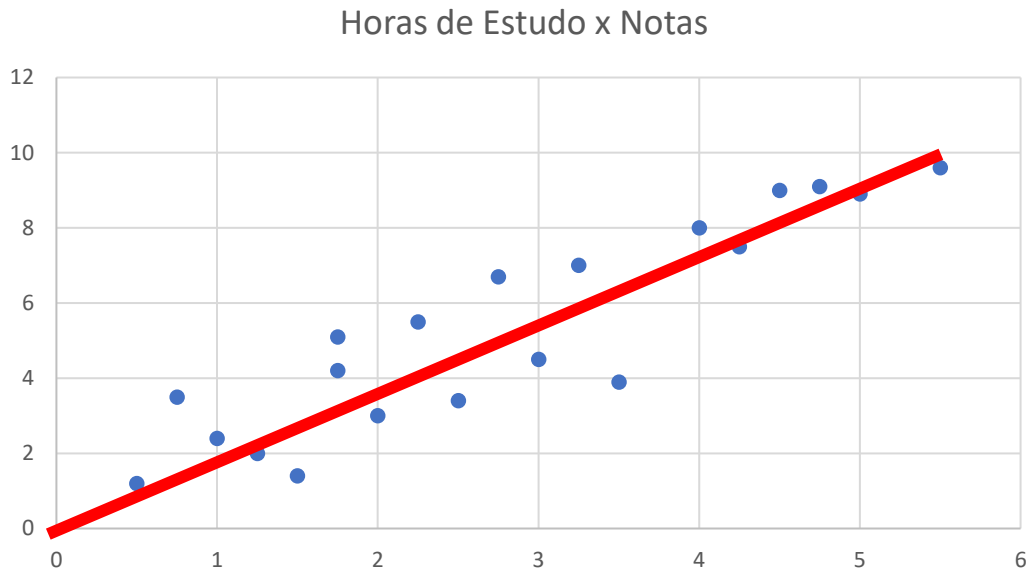

Se aplicássemos uma regressão linear, o que obteríamos é uma estimativa de nota conforme horas de estudo.

Mas essa relação não parece ser linear ! Os erros são grandes

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Nota
0,5	1,2
0,75	3,5
1	2,4
1,25	2
1,5	1,4
1,75	4,2
1,75	5,1
2	3
2,25	5,5
2,5	3,4
2,75	6,7
3	4,5
3,25	7
3,5	3,9
4	8
4,25	7,5
4,5	9
4,75	9,1
5	8,9
5,5	9,6

O que então podemos fazer ??

Se aplicássemos uma regressão linear, o que obteríamos é uma estimativa de nota conforme horas de estudo.

Mas essa relação não parece ser linear ! Os erros são grandes

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Nota	Passou ?
0,5	1,2	0
0,75	3,5	0
1	2,4	0
1,25	2	0
1,5	1,4	0
1,75	4,2	0
1,75	5,1	1
2	3	0
2,25	5,5	1
2,5	3,4	0
2,75	6,7	1
3	4,5	0
3,25	7	1
3,5	3,9	0
4	8	1
4,25	7,5	1
4,5	9	1
4,75	9,1	1
5	8,9	1
5,5	9,6	1

Podemos criar uma nova coluna TRUE e FALSE para saber se o aluno passou ou não passou na prova (nota >= 5,0)

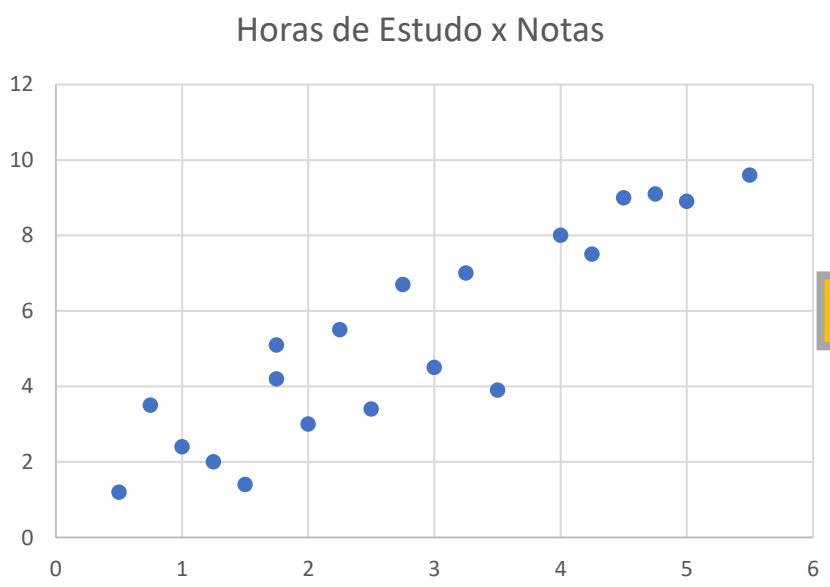

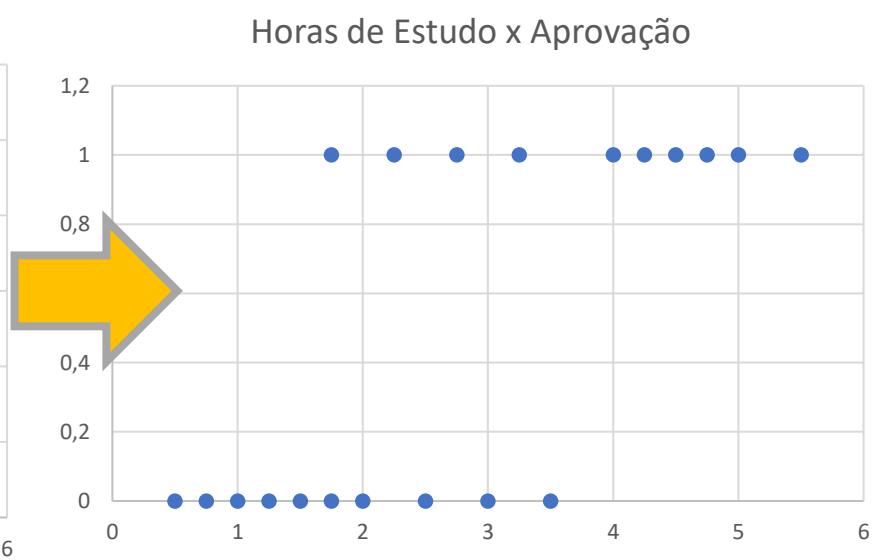

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Passou ?
0,5	0
0,75	0
1	0
1,25	0
1,5	0
1,75	0
1,75	1
2	0
2,25	1
2,5	0
2,75	1
3	0
3,25	1
3,5	0
4	1
4,25	1
4,5	1
4,75	1
5	1
5,5	1

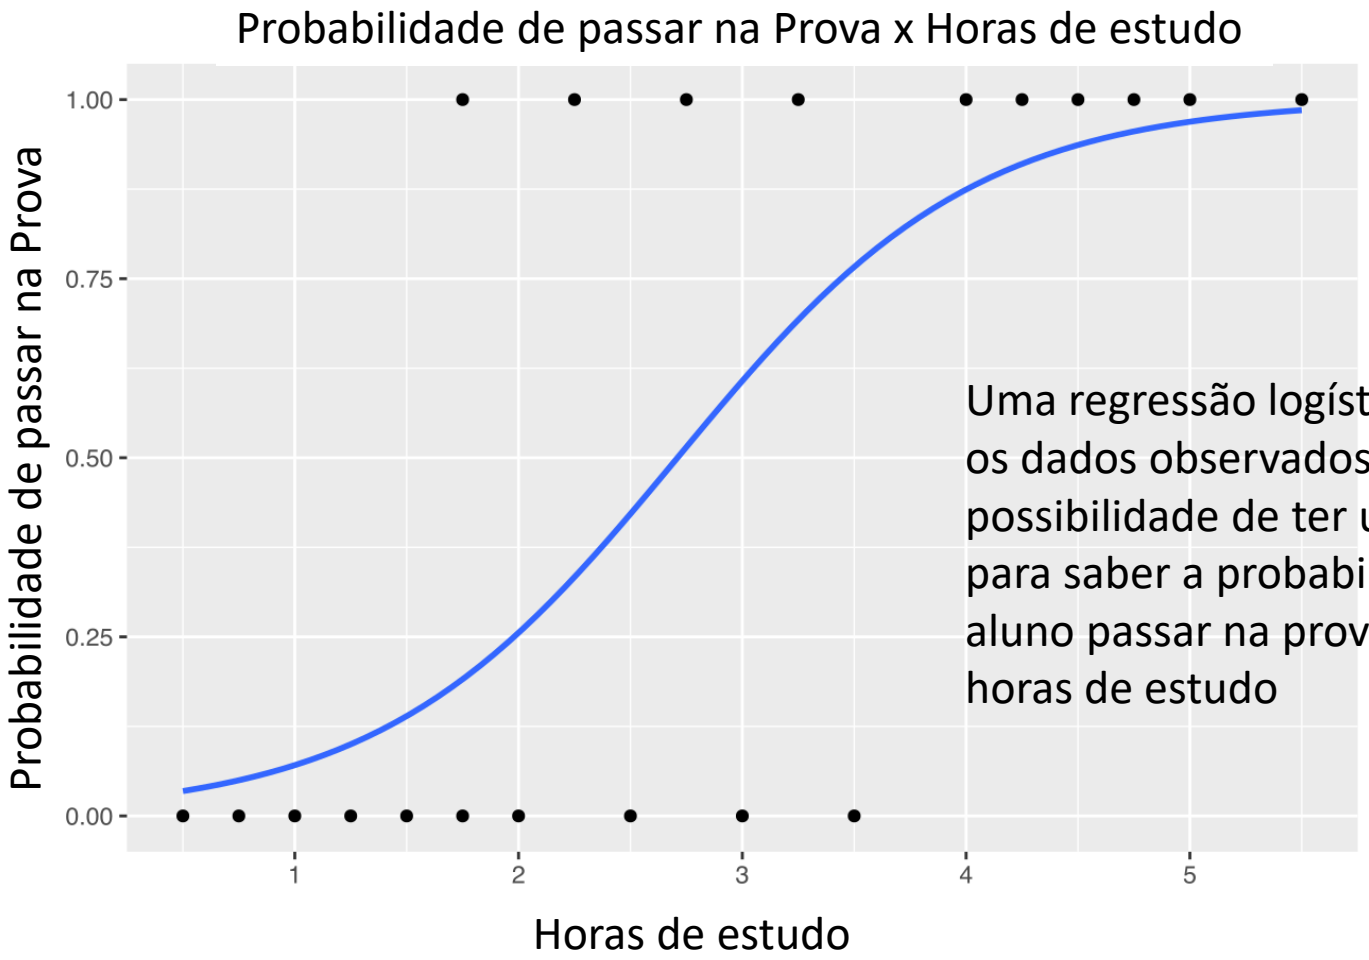

Uma regressão logística pode explicar os dados observados e nos trazer a possibilidade de ter um “mecanismo” para saber a probabilidade de um aluno passar na prova conforme suas horas de estudo

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Passou ?
0,5	0
0,75	0
1	0
1,25	0
1,5	0
1,75	0
1,75	1
2	0
2,25	1
2,5	0
2,75	1
3	0
3,25	1
3,5	0
4	1
4,25	1
4,5	1
4,75	1
5	1
5,5	1

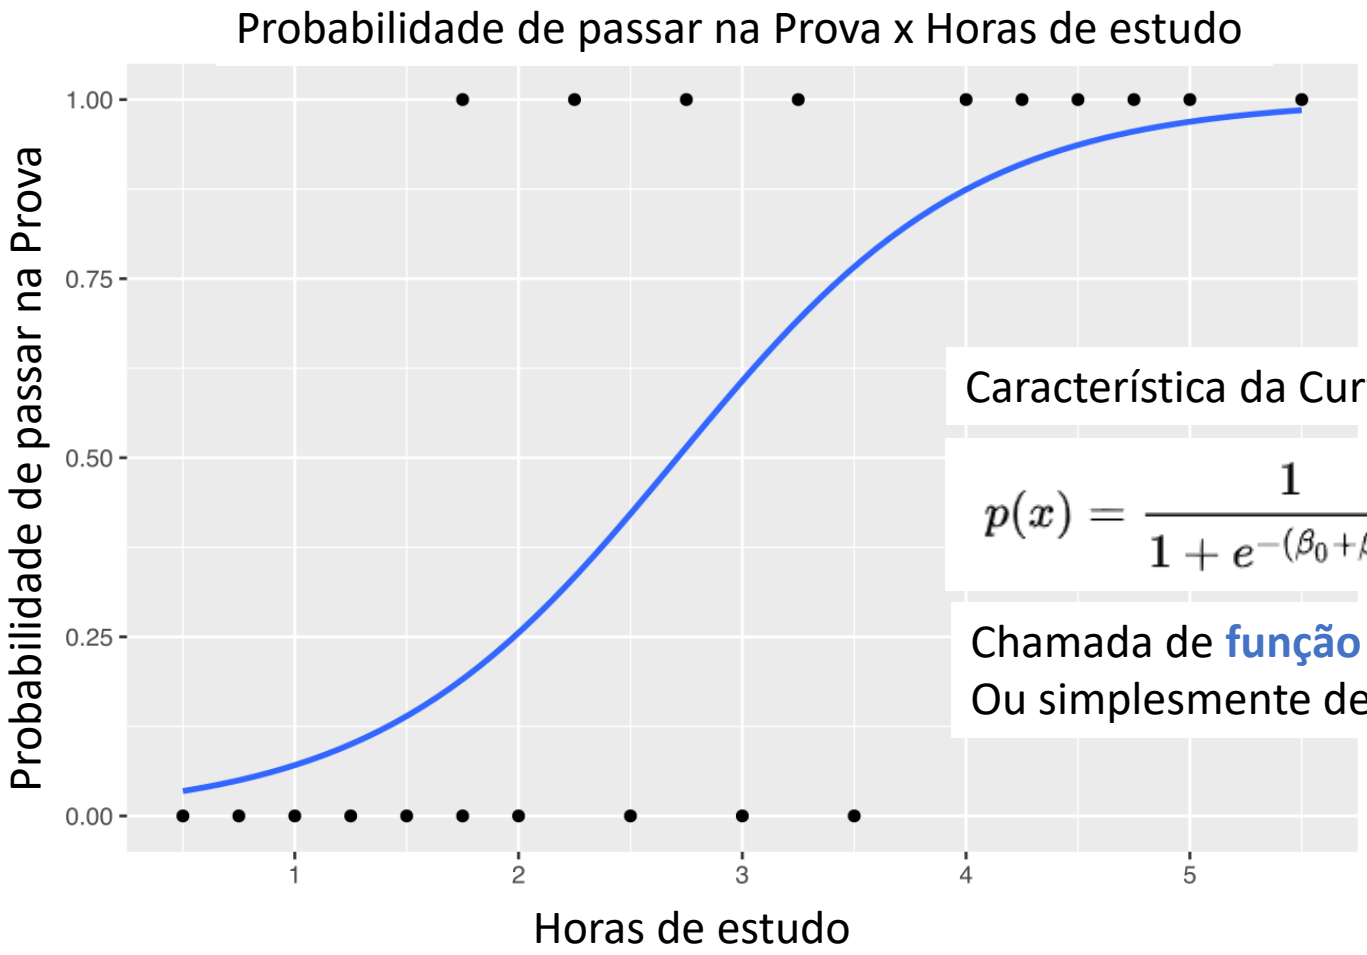

Característica da Curva:

$$p(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

Chamada de **função logística**
Ou simplesmente de **sigmóide**

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Passou ?
0,5	0
0,75	0
1	0
1,25	0
1,5	0
1,75	0
1,75	1
2	0
2,25	1
2,5	0
2,75	1
3	0
3,25	1
3,5	0
4	1
4,25	1
4,5	1
4,75	1
5	1
5,5	1

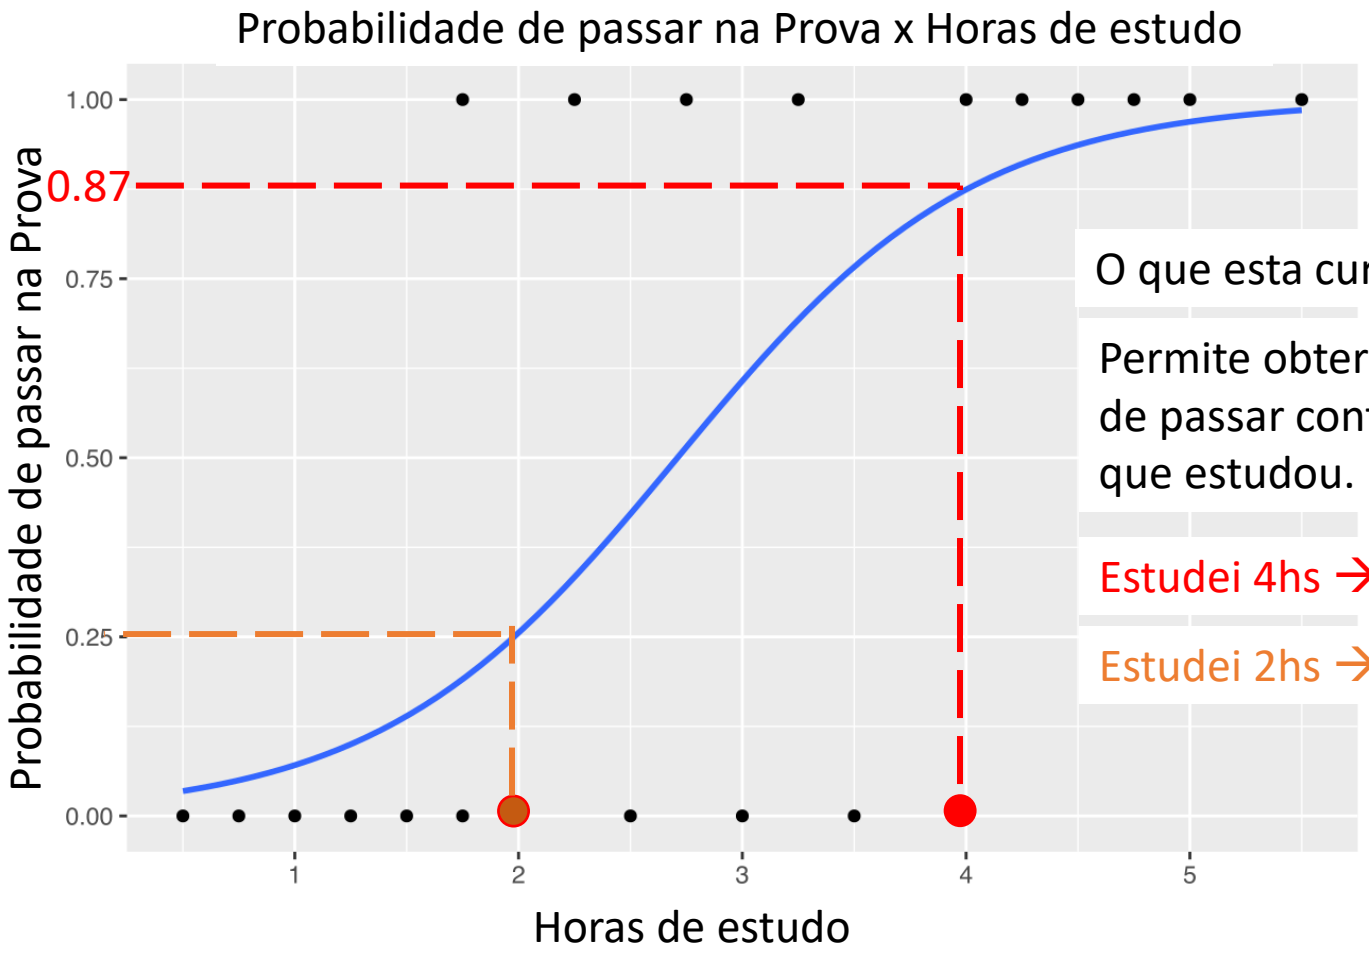

O que esta curva nos permite ?

Permite obter a probabilidade de passar conforme as horas que estudou. Por exemplo:

Estudei 4hs → 87% de chance

Estudei 2hs → 25% de chance

Exemplo (retirado do Wikipedia)

Um grupo de 20 estudantes passa entre 0 e 6 horas estudando para uma prova.
Como o número de horas dedicadas ao estudo afeta a probabilidade do estudante passar na prova?

Horas	Passou ?
0,5	0
0,75	0
1	0
1,25	0
1,5	0
1,75	0
1,75	1
2	0
2,25	1
2,5	0
2,75	1
3	0
3,25	1
3,5	0
4	1
4,25	1
4,5	1
4,75	1
5	1
5,5	1

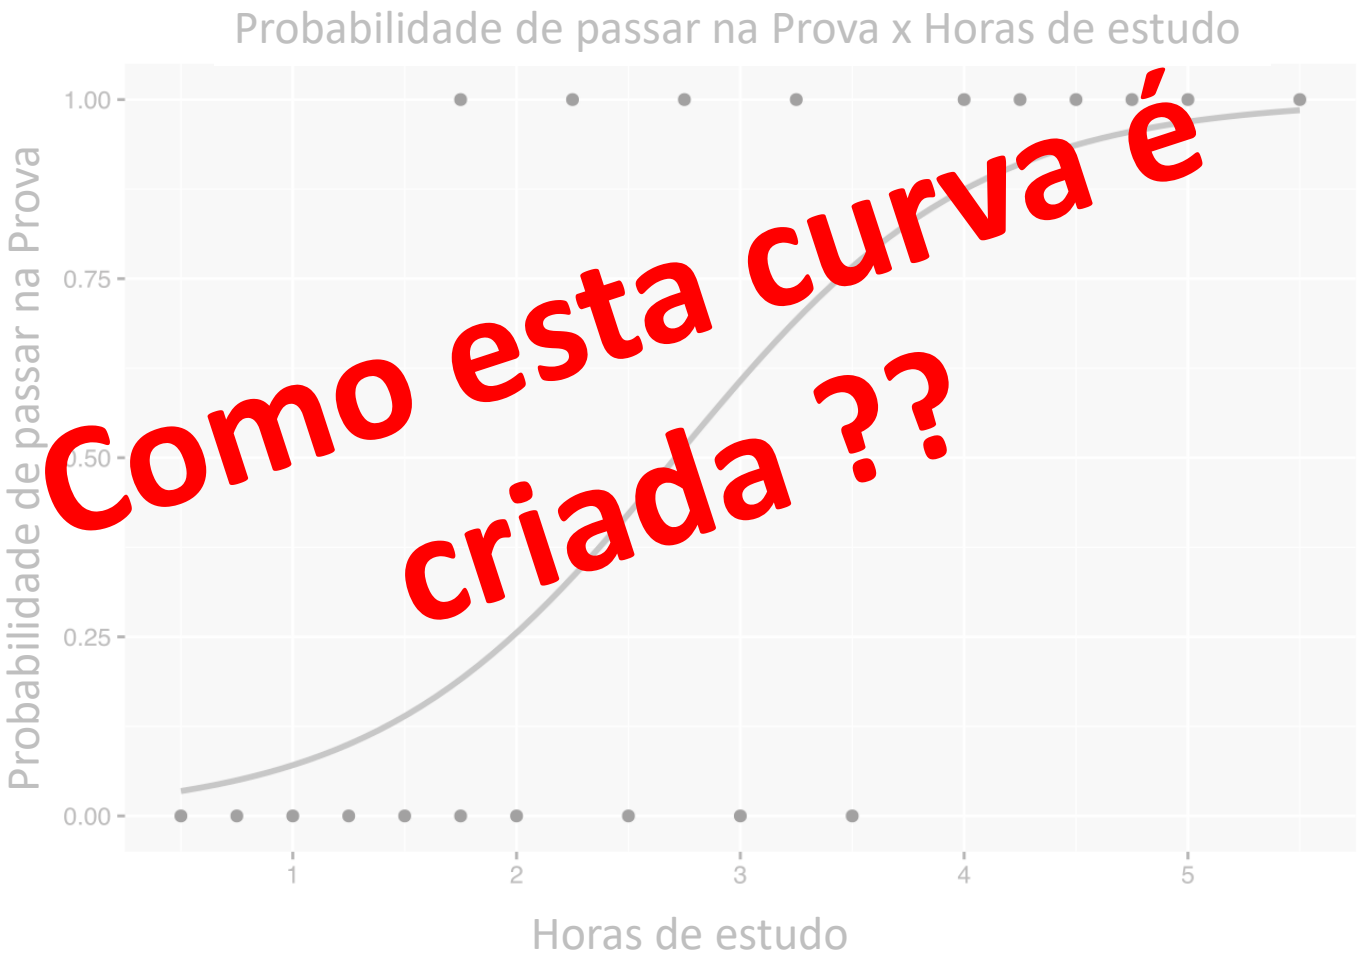

Como esta curva é criada ??

Regressão Logística

O cálculo para criação da Função Logística com base nos dados é algo que extrapola a ementa desta aula

Para conhecimento, este cálculo envolve probabilidade, log-odds, regressão linear e diversas outros métodos estatísticos. E ainda assim, é feito um teste estatístico de várias curvas para ver qual delas melhor se adaptam os dados:

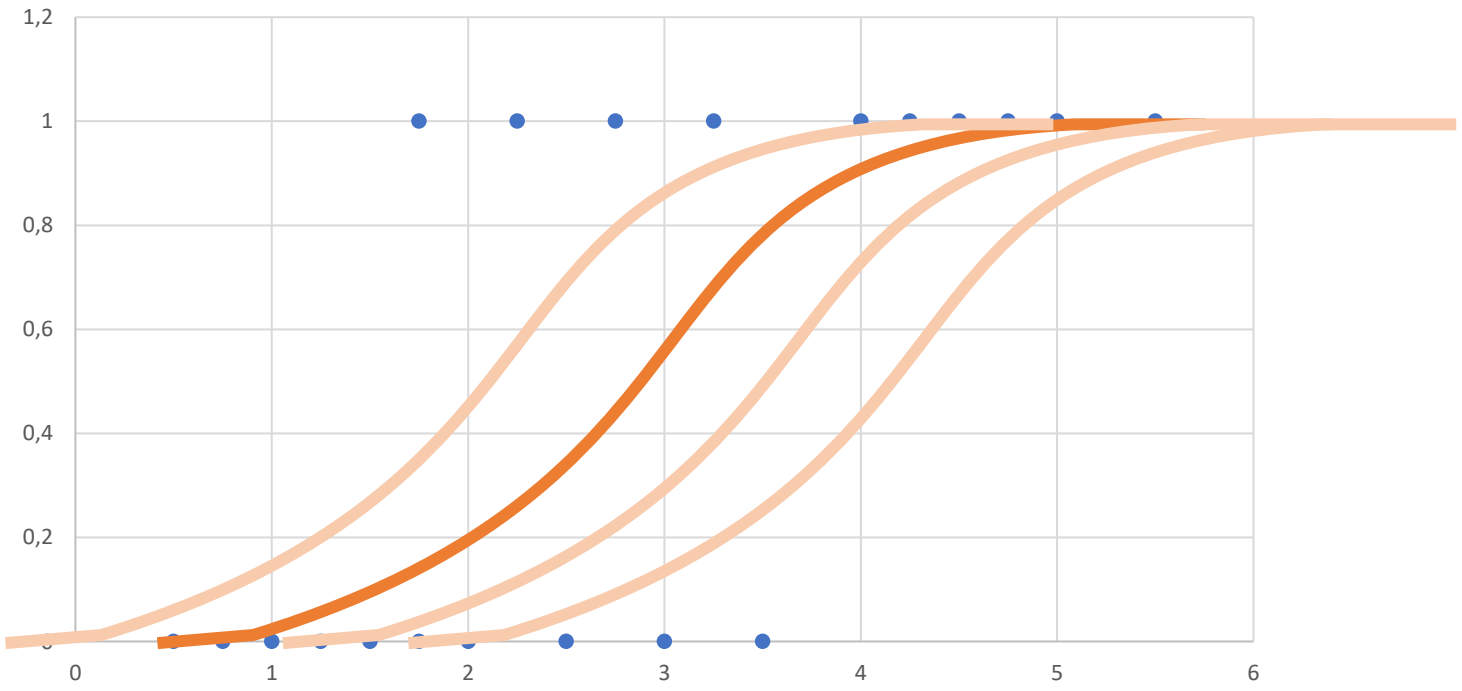

Codificando em Python

```python
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression

# 1) Dados (os seus)
hours = np.array([0.50, 0.75, 1.00, 1.25, 1.50, 1.75, 1.75, 2.00, 2.25, 2.50,2.75, 3.00, 3.25, 3.50, 4.00, 4.25, 4.50, 4.75, 5.00, 5.50])
passed = np.array([0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 1, 0, 1, 0, 1, 1, 1, 1, 1, 1])
X = hours.reshape(-1, 1)   # scikit-learn espera 2D: (n_amostras, n_features)
y = passed

# 2) Treino do modelo   ------------------------------------------------------------
model = LogisticRegression()  # default já funciona bem aqui
model.fit(X, y)

# 3) Probabilidade ao longo das horas + curva logística ---------------------------------
x_grid = np.linspace(hours.min(), hours.max(), 300).reshape(-1, 1)
p_grid = model.predict_proba(x_grid)[:, 1]  # probabilidade da classe 1 (Pass=1)
plt.figure()
plt.scatter(hours, y, label="Dados (0/1)", zorder=3)
plt.plot(x_grid, p_grid, label="P(Pass=1) (curva logística)")
plt.axhline(0.5, linestyle="--", linewidth=1, label="P=0.5")
plt.xlabel("hours")
plt.ylabel("Pass / Probabilidade")
plt.ylim(-0.05, 1.05)
plt.grid(True, alpha=0.3)
plt.legend()
plt.show()

# 4) Hora aproximada onde P(passar)=0.5 (fronteira de decisão)-------------------
beta1 = model.coef_[0][0]
beta0 = model.intercept_[0]
x_threshold = -beta0 / beta1
print("\nHora onde P(passar)=0.5 (aprox):", x_threshold)
```

KNN – K Nearest Neighbor

K vizinhos mais próximos

KNN – K nearest neighbors

KNN é um algoritmo supervisionado de *Machine Learning*

Faz parte dos algoritmos de aprendizado não-paramétricos

- Precisa de um conjunto de dados pré-classificados (com entrada e saída)
- O KNN pode classificar um novo elemento apenas analisando os vizinhos próximos a ele

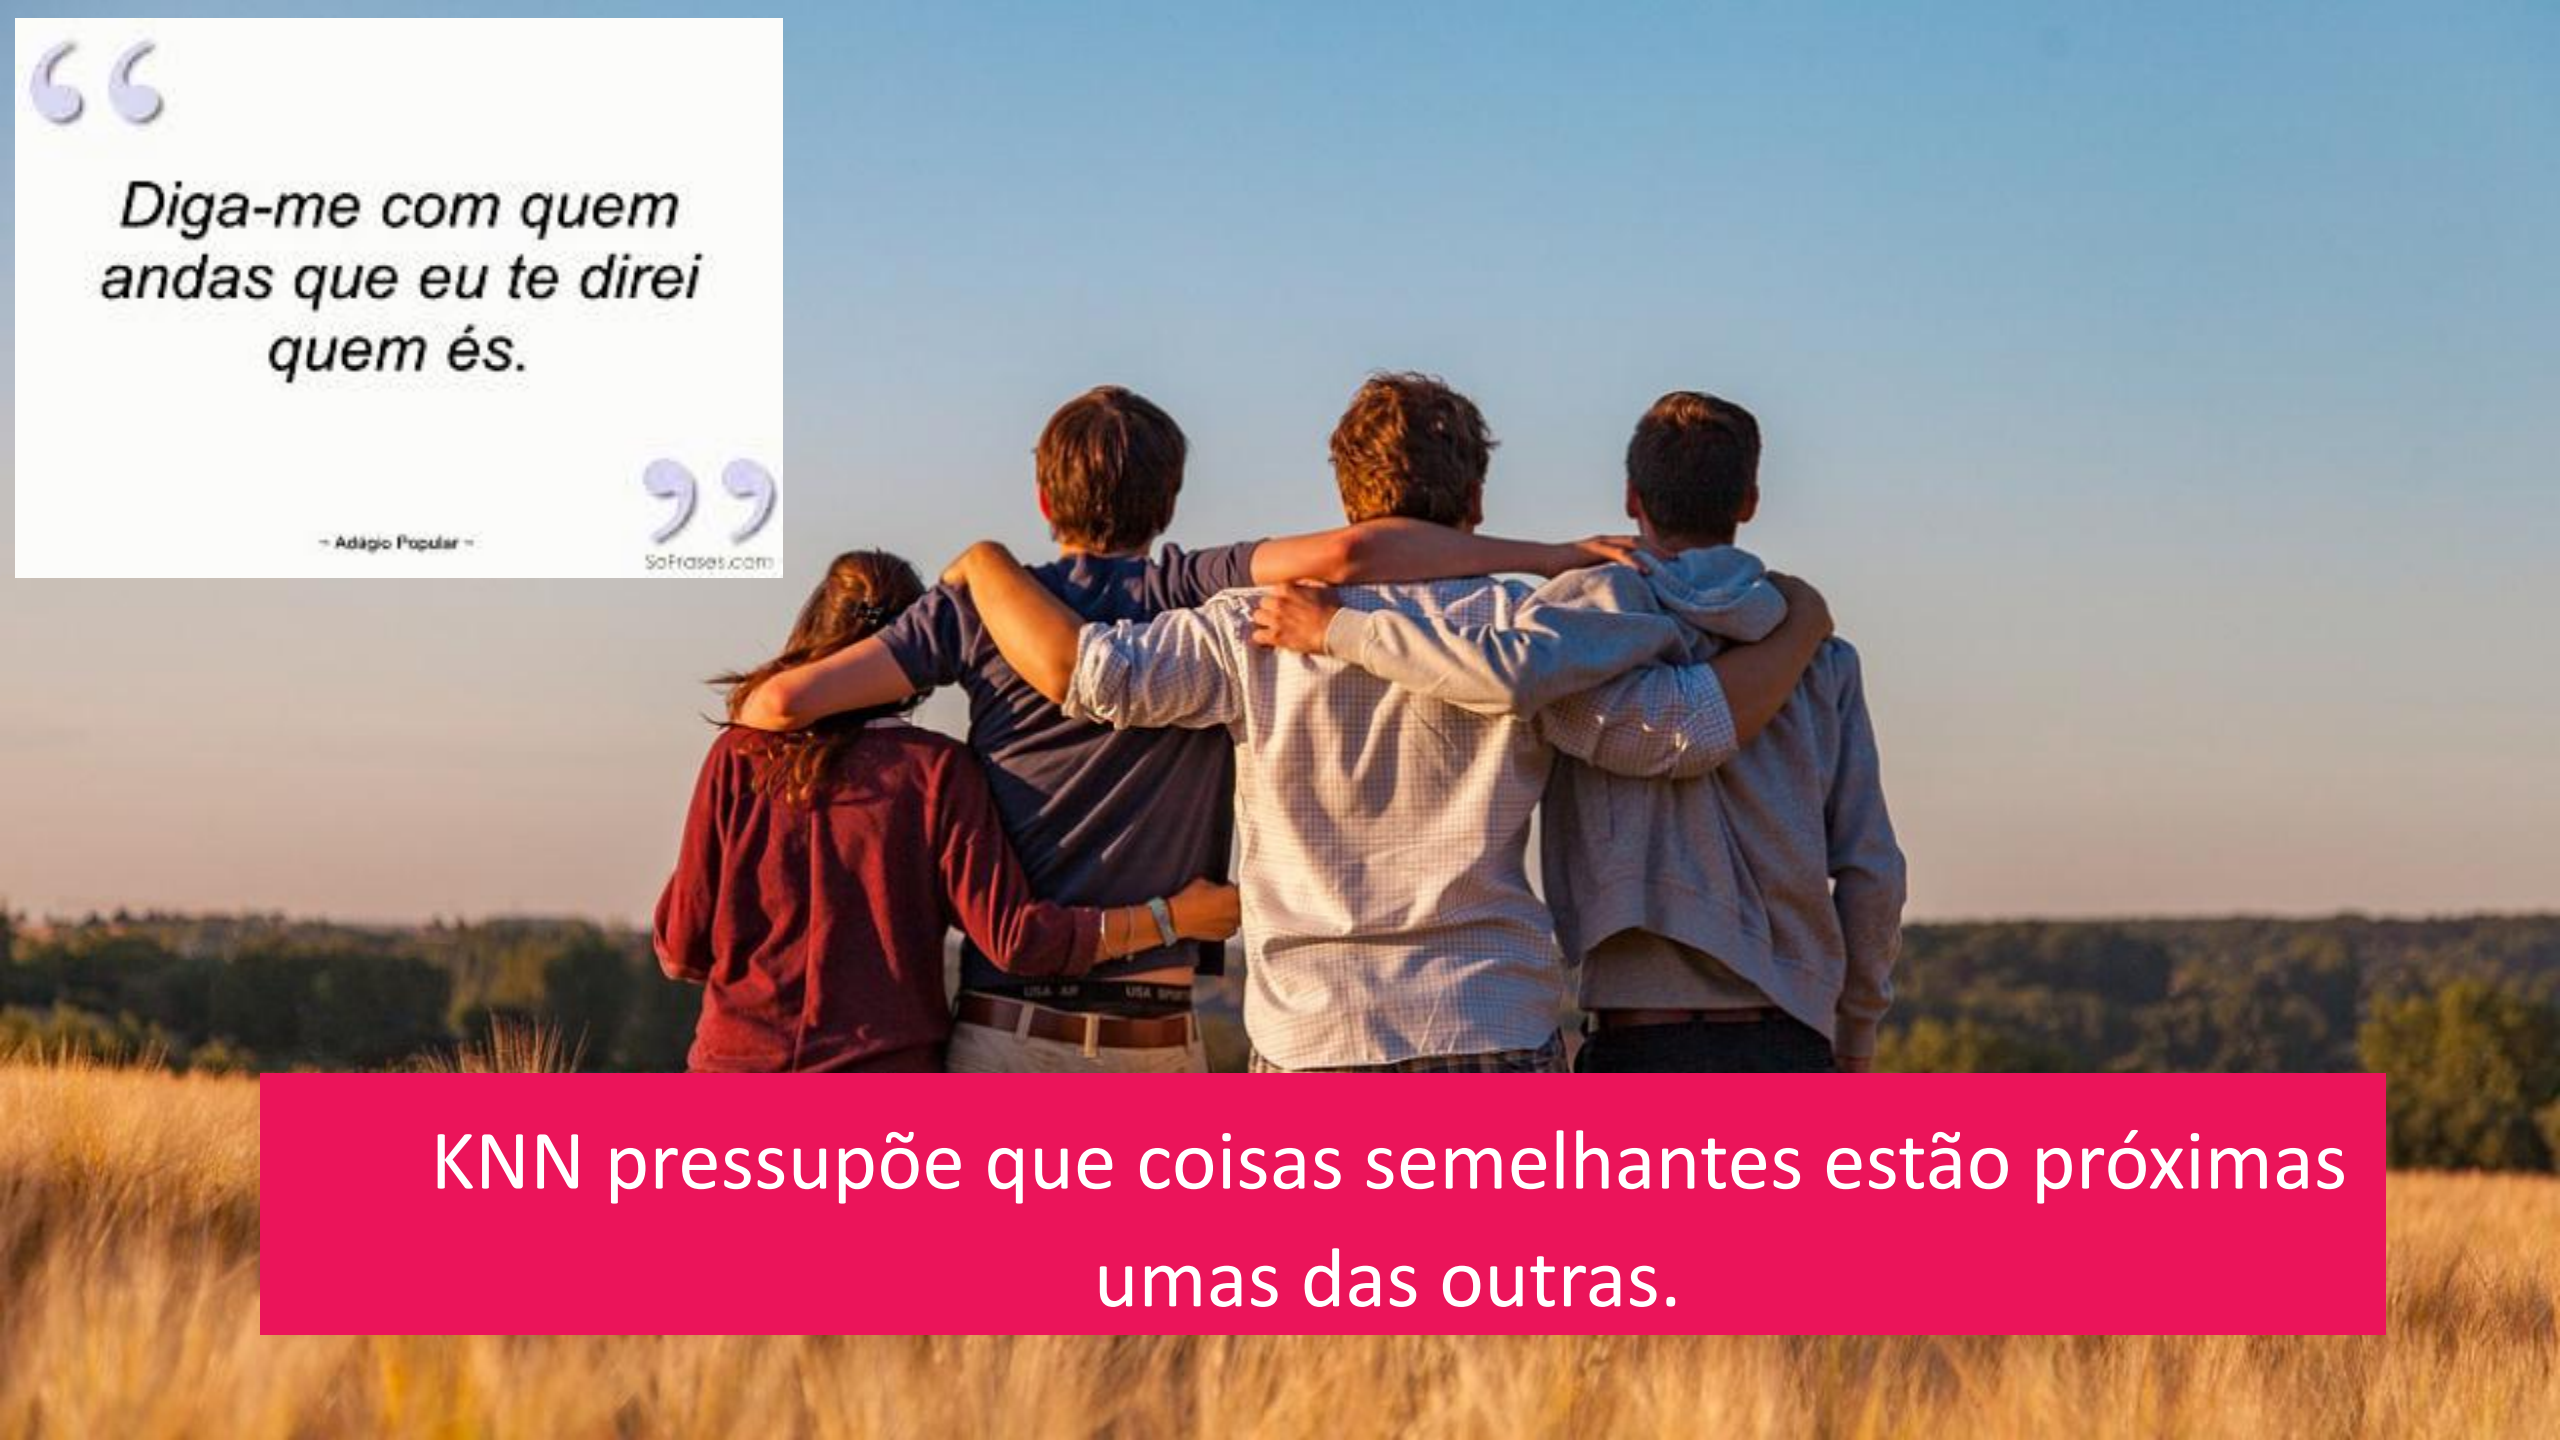

KNN pressupõe que coisas semelhantes estão próximas umas das outras.

KNN – K nearest neighbors

Exemplo com duas classes: A e B

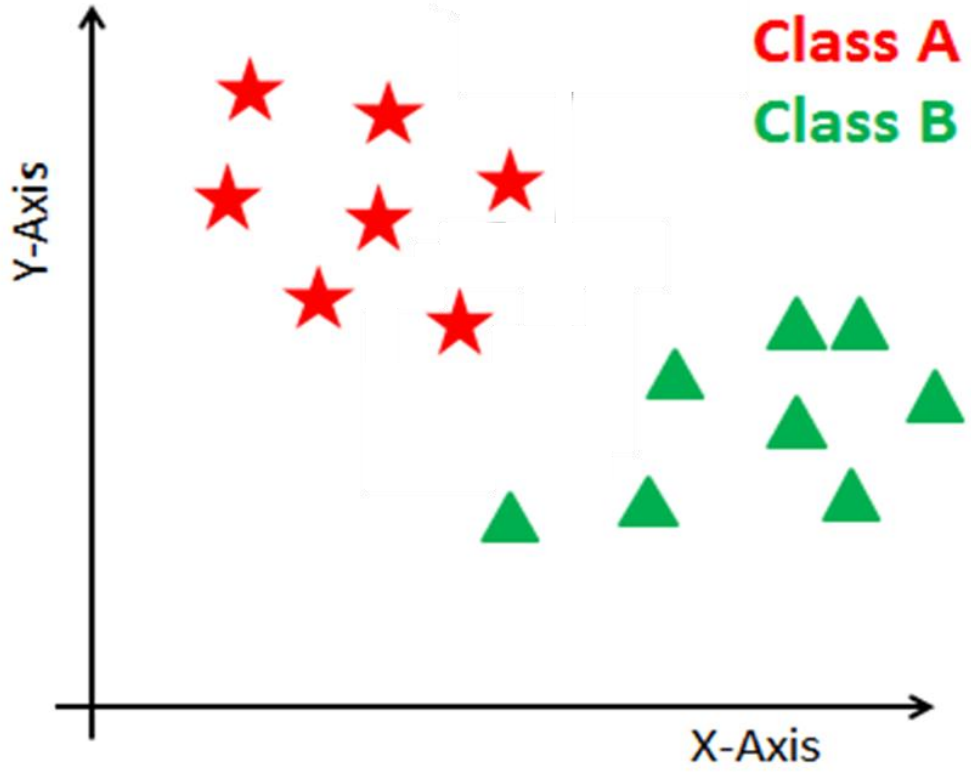

KNN – K nearest neighbors

Exemplo com duas classes: A e B

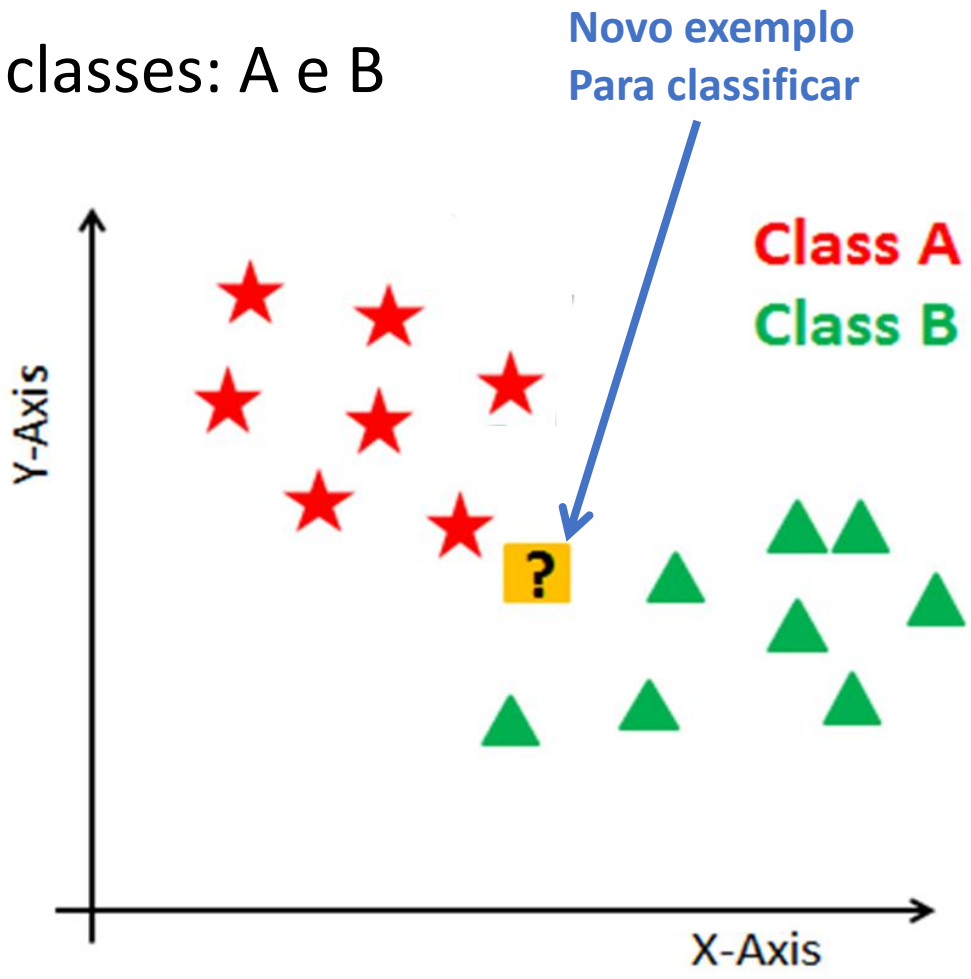

KNN – K nearest neighbors

Exemplo com duas classes: A e B

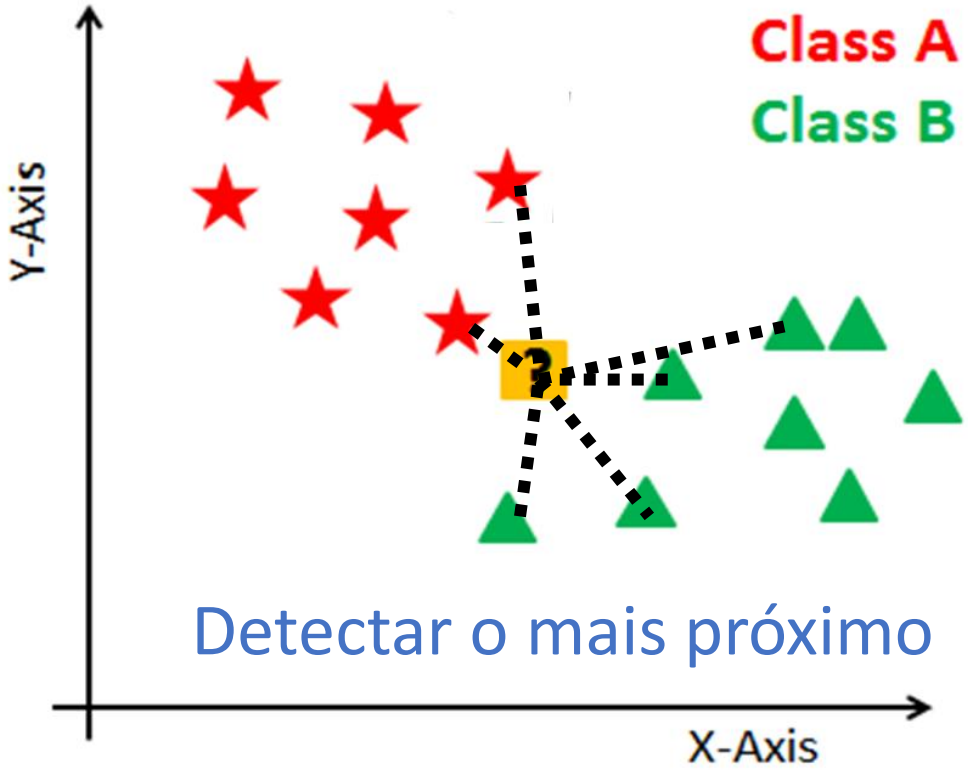

Detectar o mais próximo

DISTÂNCIA EUCLIDIANA

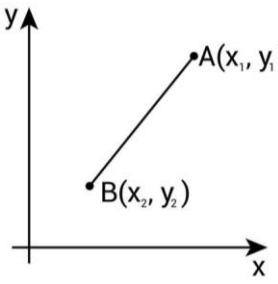

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

KNN – K nearest neighbors

Exemplo com duas classes: A e B

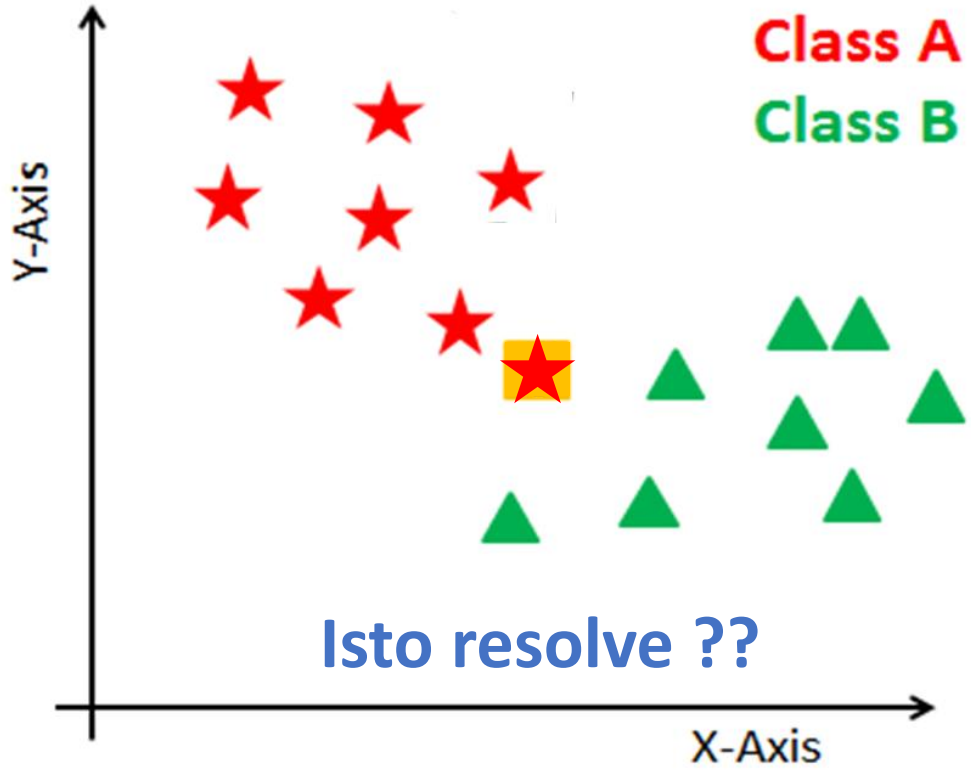

Isto resolve ??

KNN – K nearest neighbors

Exemplo com duas classes: A e B

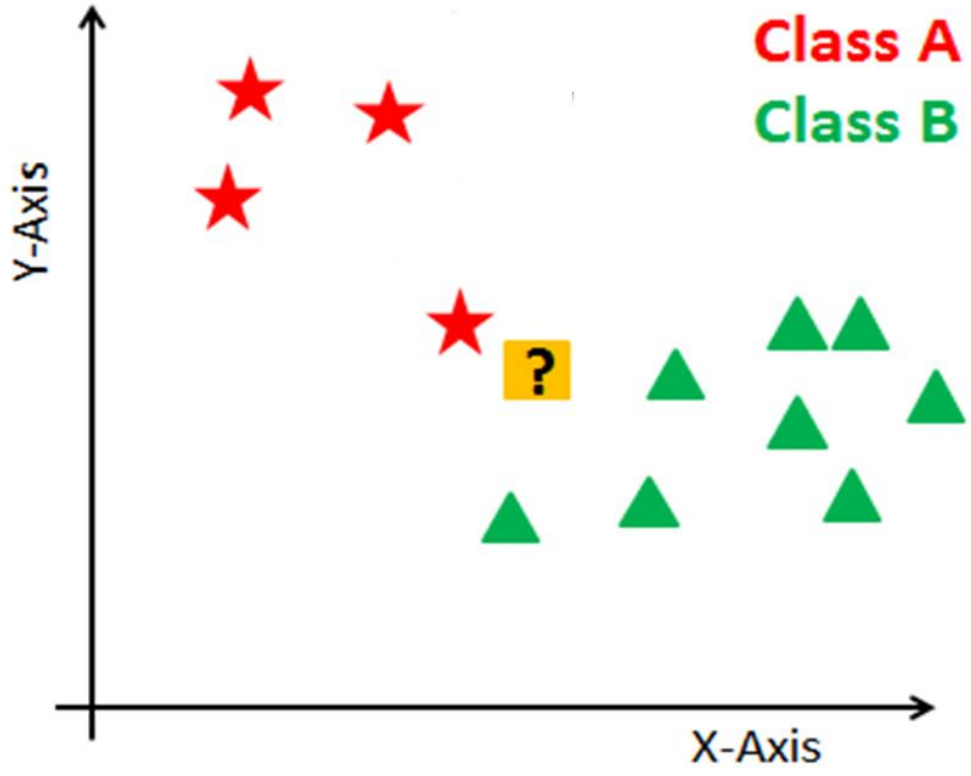

Neste caso mesmo o novo exemplo estando mais perto da estrela, parece ser mais correto classifica-lo como triângulo

KNN – K nearest neighbors

Podemos definir a comparação do novo exemplo com k exemplos

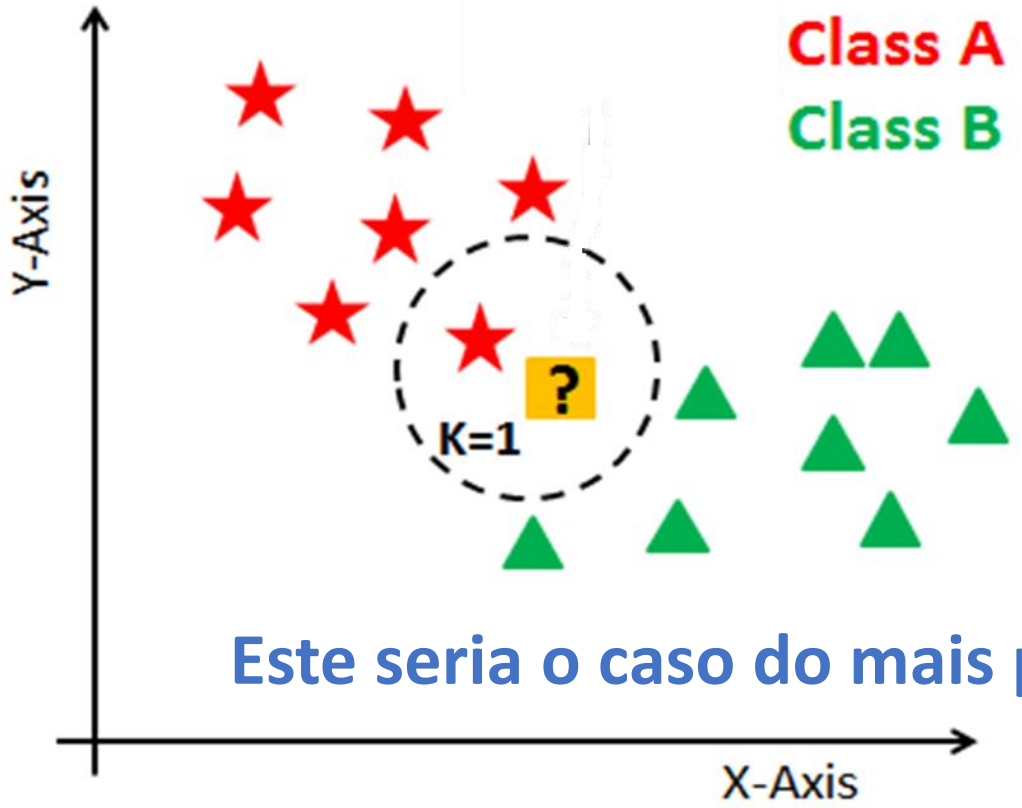

Este seria o caso do mais próximo anterior

KNN – K nearest neighbors

Ex: K=3

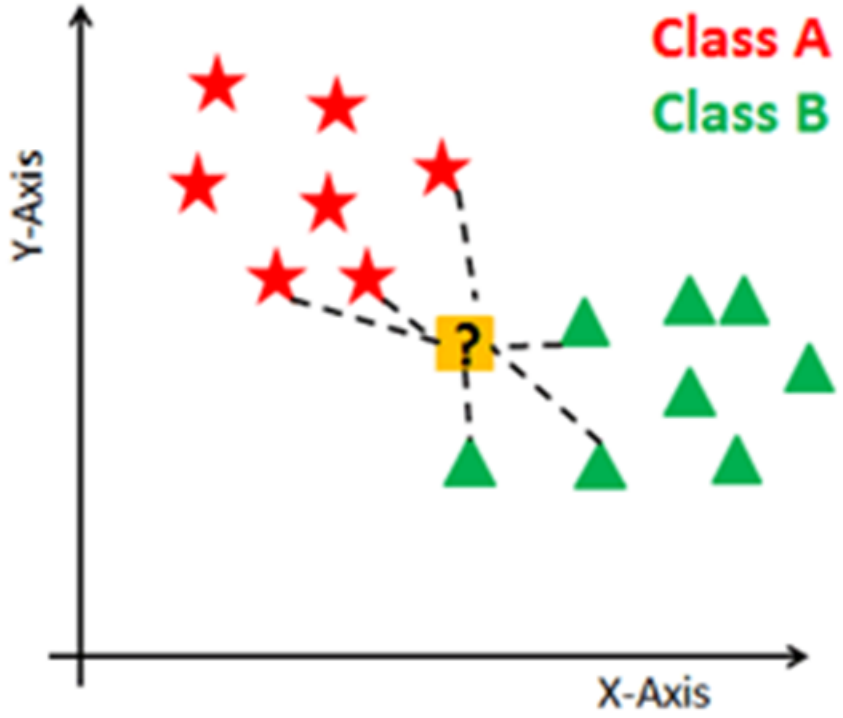

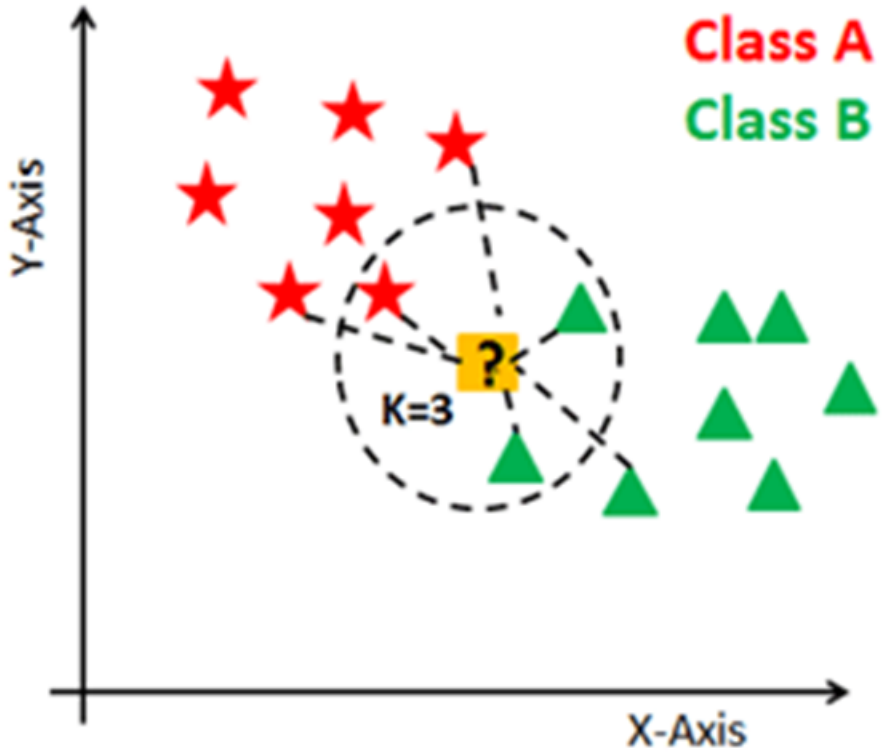

Neste caso o novo exemplo está mais próximo de 2 triângulos e 1 estrela

KNN – K nearest neighbors

Ex: K=3

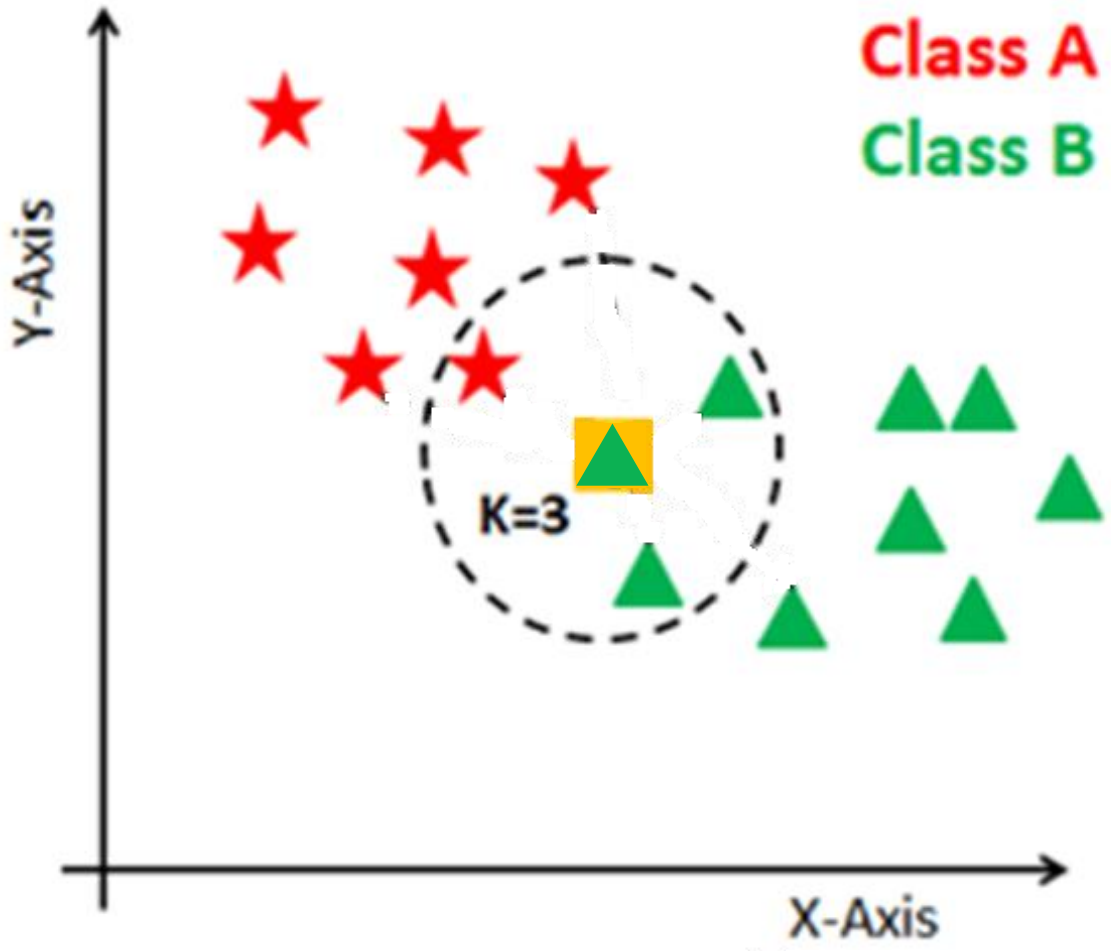

Por votação da maioria, o novo elemento se torna Class B

KNN – K nearest neighbors

Formalizando....

Cada elemento Xi tem uma classe. Existem dois valores de classes {A, B}

Podemos definir uma função $\delta\ (v, f(x_i))$ que retorna 1 se o valor da $f(x_i)$ for igual a v ou 0 se for diferente. Em outras palavras, se a classe de x_i dada por $f(x_i)$ for igual a classe v

Deste modo, o sistema de votação seria dada por esta equação:

$$f(x_q) = argmax_{v \in V} \sum_{i=1}^{k} \delta\ (v, f(x_i))$$

Existem as classes V = {A, B}. Os k pontos existentes possuem suas classes dadas por $f(x_i)$. Logo, a função acima encontra qual é a classe do novo elemento x_q pela maior soma dos k pontos mais próximos escolhidos pertencentes a uma classe

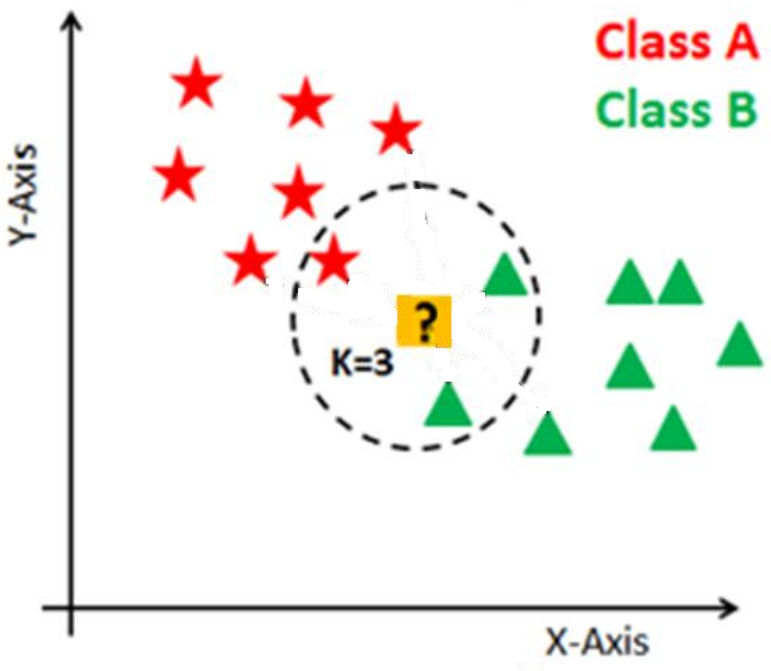

Por votação da maioria, o novo elemento se torna Class B

Exemplo

Ponto	X	Y	Classe
1	150	50	Medium
2	155	55	Medium
3	160	60	Large
4	161	59	Large
5	158	65	Large

Novo exemplo para ser classificado: $x_q = (157,54)$

Exemplo retirado de: https://www.youtube.com/watch?v=UAIIW3Bs5HE

Exemplo

Ponto	X	Y	Classe	Distância	Proximidade
1	150	50	Medium	8,06	
2	155	55	Medium	2,24	1
3	160	60	Large	6,71	3
4	161	59	Large	6,40	2
5	158	65	Large	11,05	

K=3

Novo exemplo para ser classificado: $x_q = (157,54)$

DISTÂNCIA EUCLIDIANA

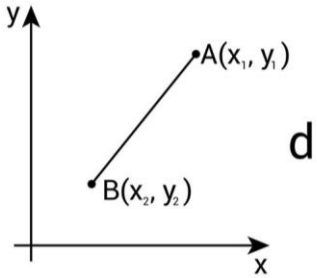

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Exemplo

Ponto	X	Y	Classe	Distância	Proximidade
1	150	50	Medium	8,06	
2	155	55	Medium	2,24	1
3	160	60	Large	6,71	3
4	161	59	Large	6,40	2
5	158	65	Large	11,05	

K=3

Novo exemplo para ser classificado: x_q = (157,54)

$$f(x_q) = argmax \sum_{i=1}^{k} \delta\left(Medium, f(x_i)\right) = 1 + 0 + 0 = 1$$

$$f(x_q) = argmax \sum_{i=1}^{k} \delta\left(Large, f(x_i)\right) = 0 + 1 + 1 = 2$$

$\therefore$ $f(x_q)$ = Large

Exemplo

Ponto	X	Y	Classe	Distância	Proximidade
1	150	50	Medium	8,06	
2	155	55	Medium	2,24	1
3	160	60	Large	6,71	3
4	161	59	Large	6,40	2
5	158	65	Large	11,05	

K=3

Mas...PODEMOS MELHORAR !!!!

Novo exemplo para se classificado: x_q = (157,54)

$$f(x_q) = argmax \sum_{i=1}^{k} \delta\left(Medium, f(x_i)\right) = 1 + 0 + 0 = 1$$

$$f(x_q) = argmax \sum_{i=1}^{k} \delta\left(Large, f(x_i)\right) = 0 + 1 + 1 = 2$$

$\therefore$ $f(x_q)$ = Large

Exemplo

Ponto	X	Y	Classe	Distância	Proximidade
1	150	50	Medium	8,06	
2	155	55	Medium	2,24	1
3	160	60	Large	6,71	3
4	161	59	Large	6,40	2
5	158	65	Large	11,05	

K=3

Perceba que o novo exemplo x_q = (157,54) está MUITO PRÒXIMO de x_2 e longe de X_3 e X_4.

O ideal seria considerarmos a distância como parte da decisão de qual classe o novo exemplo irá ser associada.

Iremos considerar um peso em cada ponto i já classificado, que é o inverso da distância ao quadrado:

$$w_i = \frac{1}{d(x_q, x_i)^2}$$

Exemplo

Ponto	X	Y	Classe	Distância	Peso	Proximidade
1	150	50	Medium	8,06		
2	155	55	Medium	2,24	0,45	1
3	160	60	Large	6,71	0,15	3
4	161	59	Large	6,40	0,16	2
5	158	65	Large	11,05		

K=3

Novo exemplo x_q = (157,54)

$$f(x_q) = argmax_{v \in V} \sum_{i=1}^{k} \boldsymbol{w_i} * \delta\,(v, f(x_i))$$

$$w_i = \frac{1}{d(x_q, x_i)^2}$$

Exemplo

Ponto	X	Y	Classe	Distância	Peso	Proximidade
1	150	50	Medium	8,06		
2	155	55	Medium	2,24	0,45	1
3	160	60	Large	6,71	0,15	3
4	161	59	Large	6,40	0,16	2
5	158	65	Large	11,05		

K=3

Novo exemplo x_q = (157,54)

$$f(x_q) = argmax \sum_{i=1}^{k} \boldsymbol{w_i} * \delta\left(Medium, f(x_i)\right) = 0{,}45 * 1 + 0{,}15 * 0 + 0{,}15 * 0 = 0{,}45$$

$$f(x_q) = argmax \sum_{i=1}^{k} \boldsymbol{w_i} * \delta\left(Large, f(x_i)\right) = 0{,}45 * 0 + 0{,}15 * 1 + 0{,}16 * 1 = 0{,}31$$

$\therefore\ f(x_q)$ = Medium

Tornar o KNN mais eficiente

- Determinar os K vizinhos mais próximos por força bruta é ineficiente
- Para resolver as ineficiências computacionais da abordagem de força bruta, usa-se estruturas de dados baseadas em árvores, como a Kd-Tree.
- A ideia básica destas estruturas é que se o ponto A está muito distante do ponto B, e o ponto B está muito próximo do ponto C, então sabemos que os pontos A e C estão muito distantes, sem ter que calcular explicitamente sua distância.
- O custo computacional de uma pesquisa de vizinhos mais próximos pode ser reduzido para O(N log N) ou melhor.

Kd-tree

Árvore k-dimensional

Kd-Tree

- A Árvore k-D (k-Dimensional Tree) é uma Árvore Binária de Busca (BST) que permite um eficiente processamento de chaves multidimencionais.
- Uma árvore k-d é uma estrutura de dados de particionamento do espaço para a organização de pontos em um espaço k-dimensional.

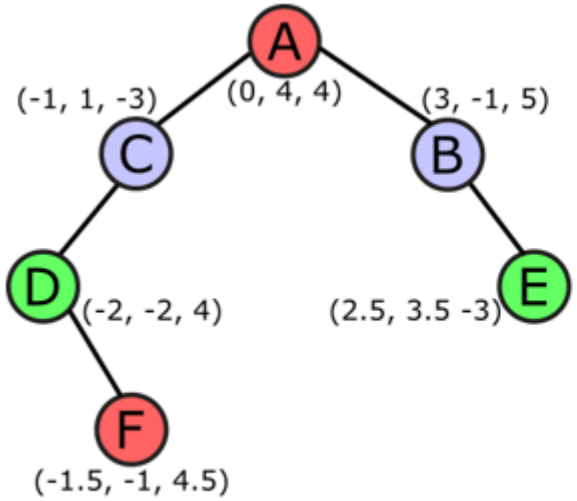

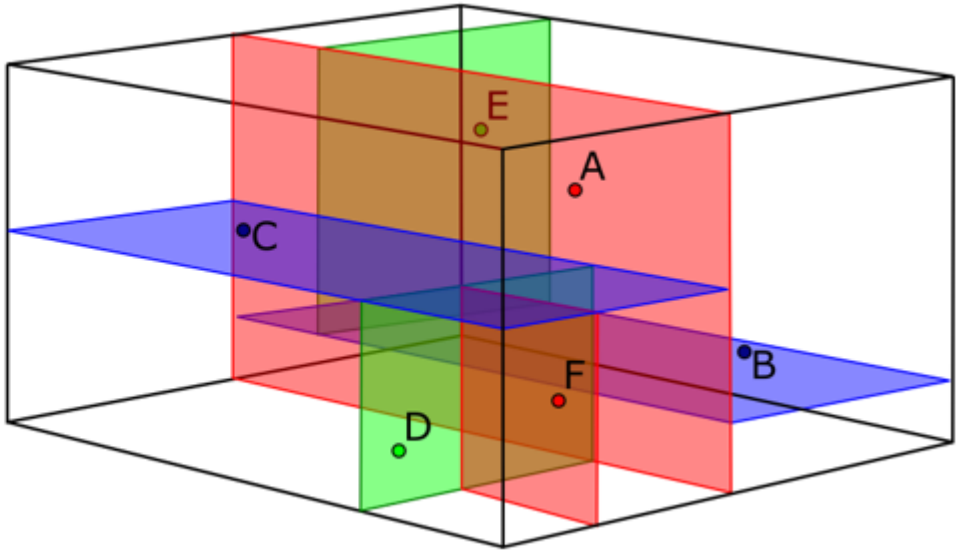

Criando uma Kd-Tree

- Começando com uma lista de pontos D-dimensionais

Pt	X[1]	X[2]
1	0,86	3,12
2	0,52	1,81
3	0,68	3,97
4	0,95	2,03
5	0,17	4,83
6	0,59	1,3
....		

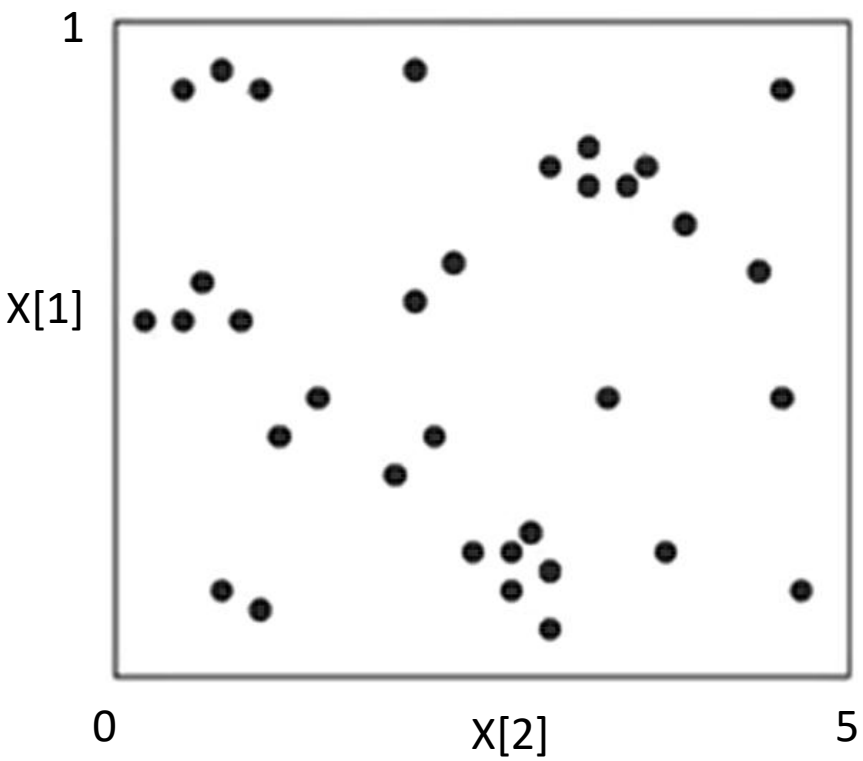

Criando uma Kd-Tree

- Divido uma das dimensões (neste exemplo, no meio)

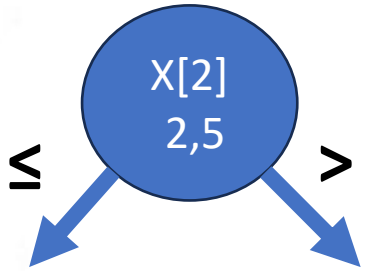

Pt	X[1]	X[2]
2	0,52	1,81
4	0,95	2,03
6	0,59	1,3
....		

Pt	X[1]	X[2]
1	0,86	3,12
3	0,68	3,97
5	0,17	4,83
....		

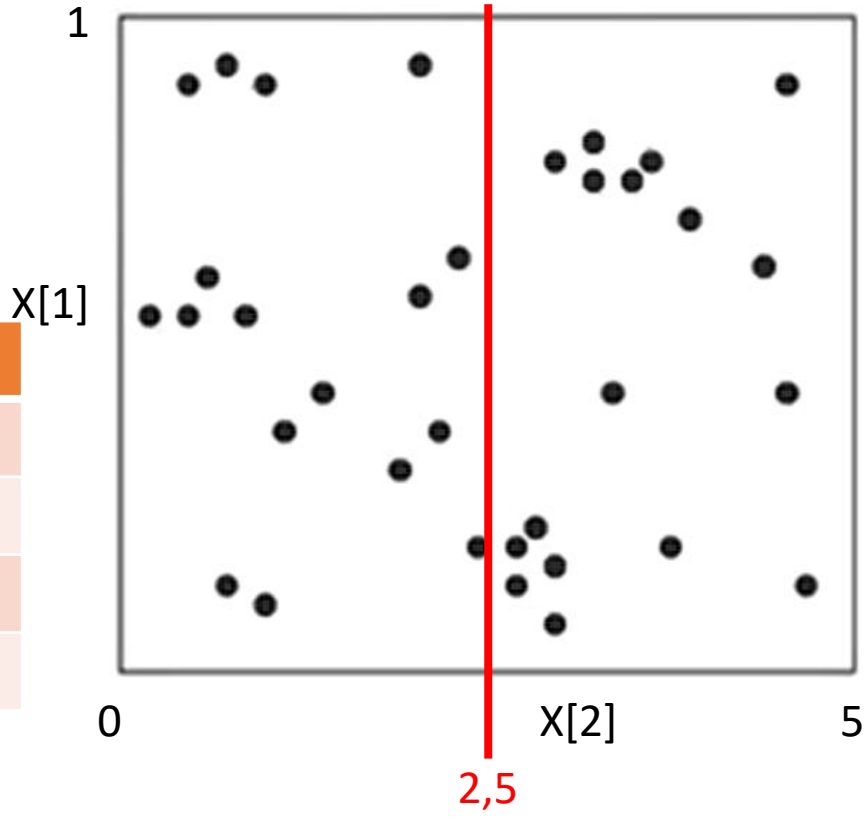

Criando uma Kd-Tree

- Divido outra dimensão

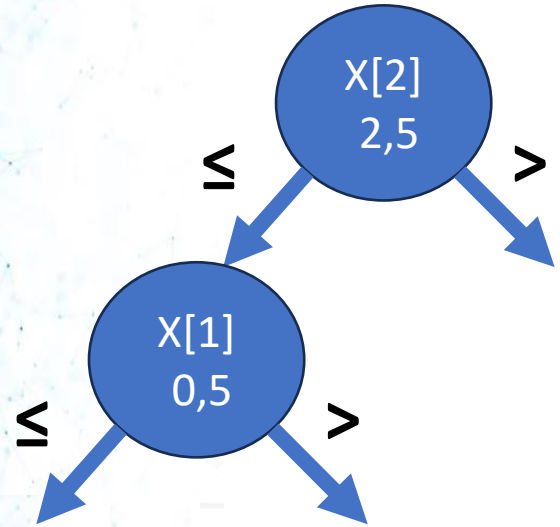

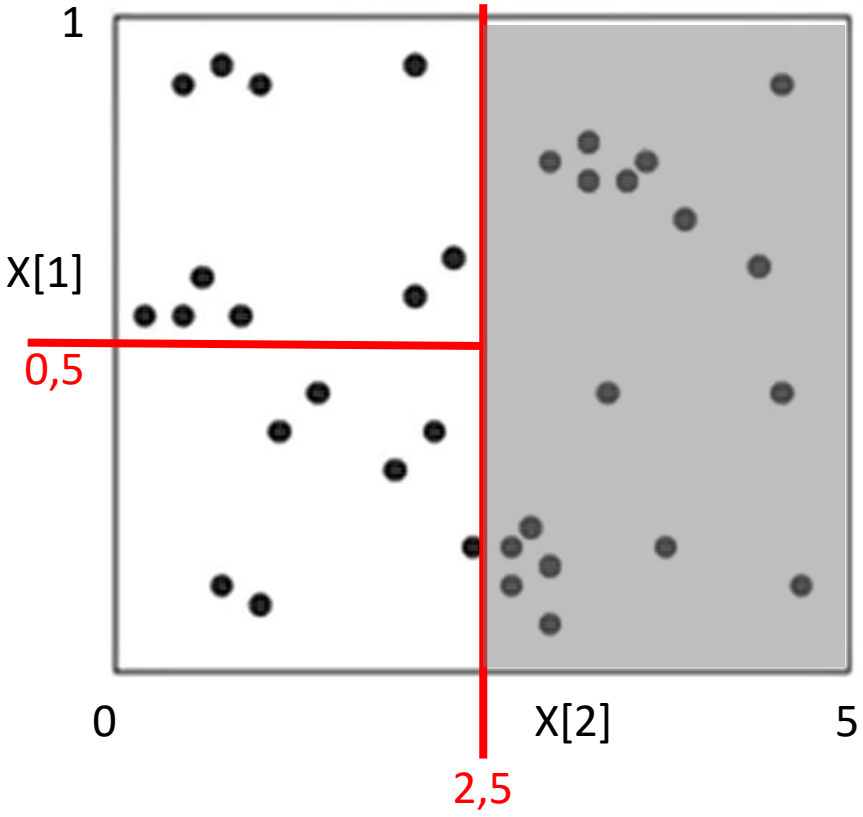

Criando uma Kd-Tree

- Divido outra dimensão

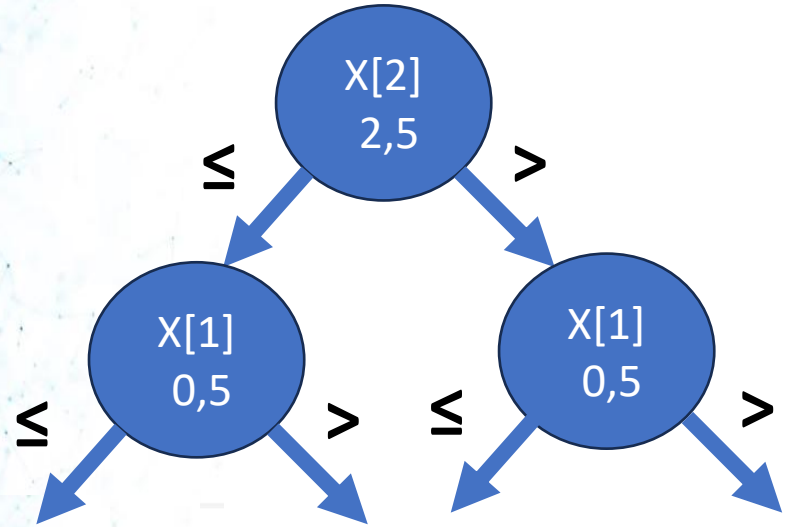

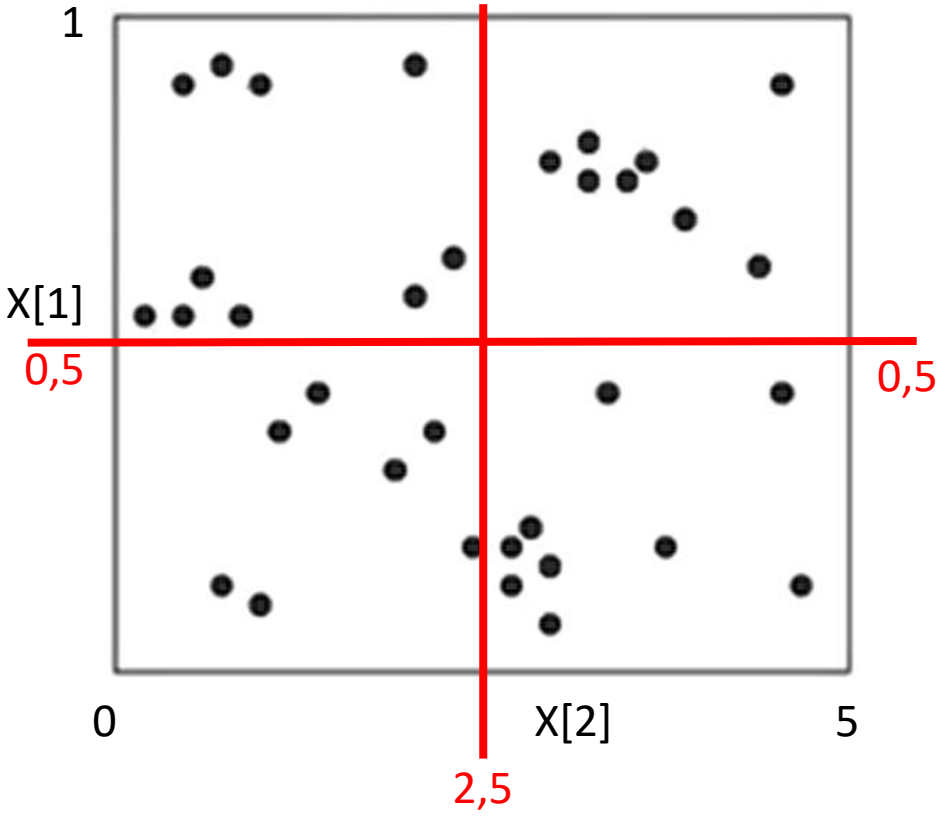

E assim por diante.....

Kd-Tree

É uma árvore de busca binária (não balanceada)

Mas com 2 diferenças:

1. Cada nível se refere à uma dimensão e elas se intercalam
2. O nó folha é uma lista de pontos da região delimitada pelos nós da árvore

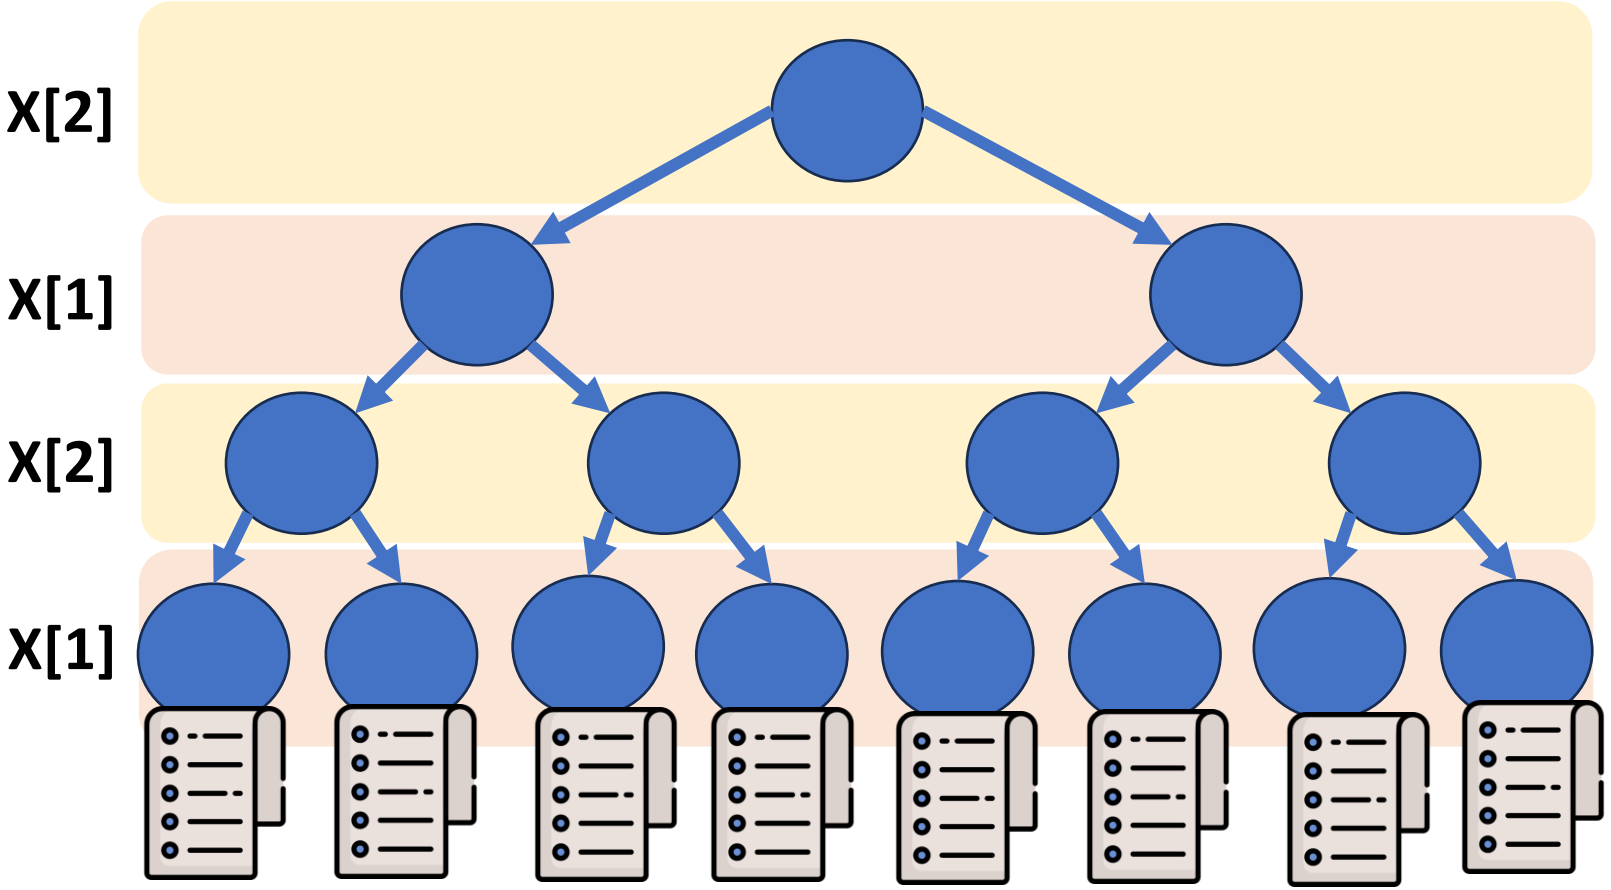

Divisão dos pontos

- Mas dividir pelo “meio” não é legal.

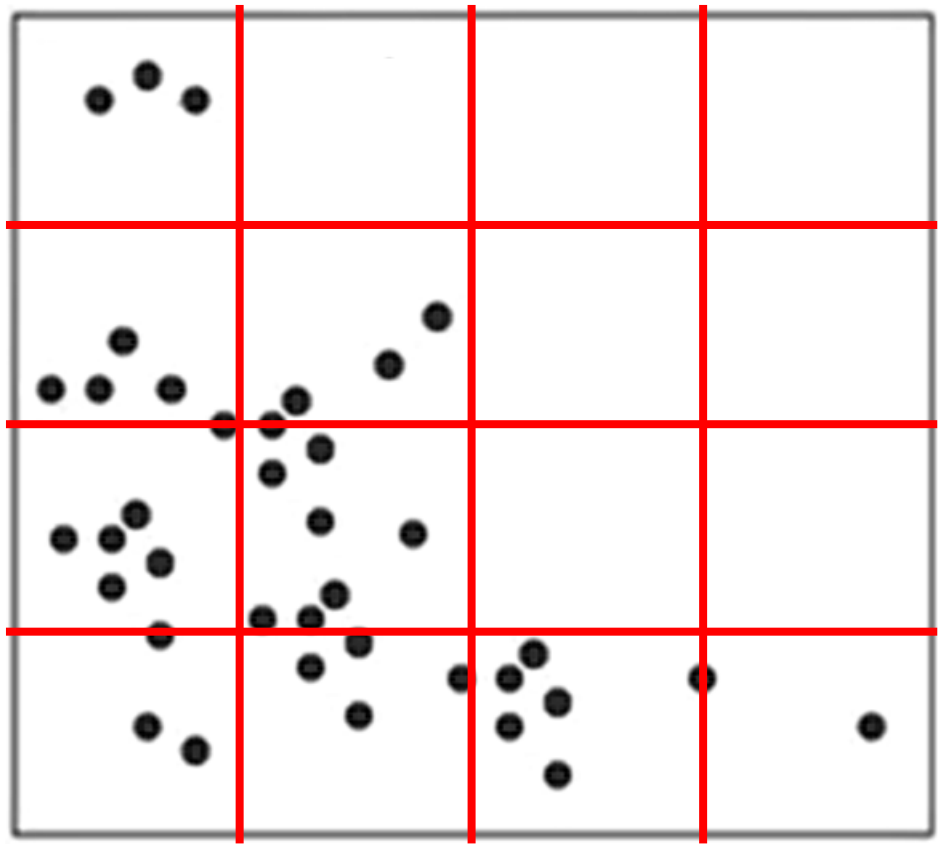

Divisão de Pontos

- Escolhendo o ponto de divisão adequado que deixará a árvore mais balanceada

Divisão pelo ponto que representa a MEDIANA

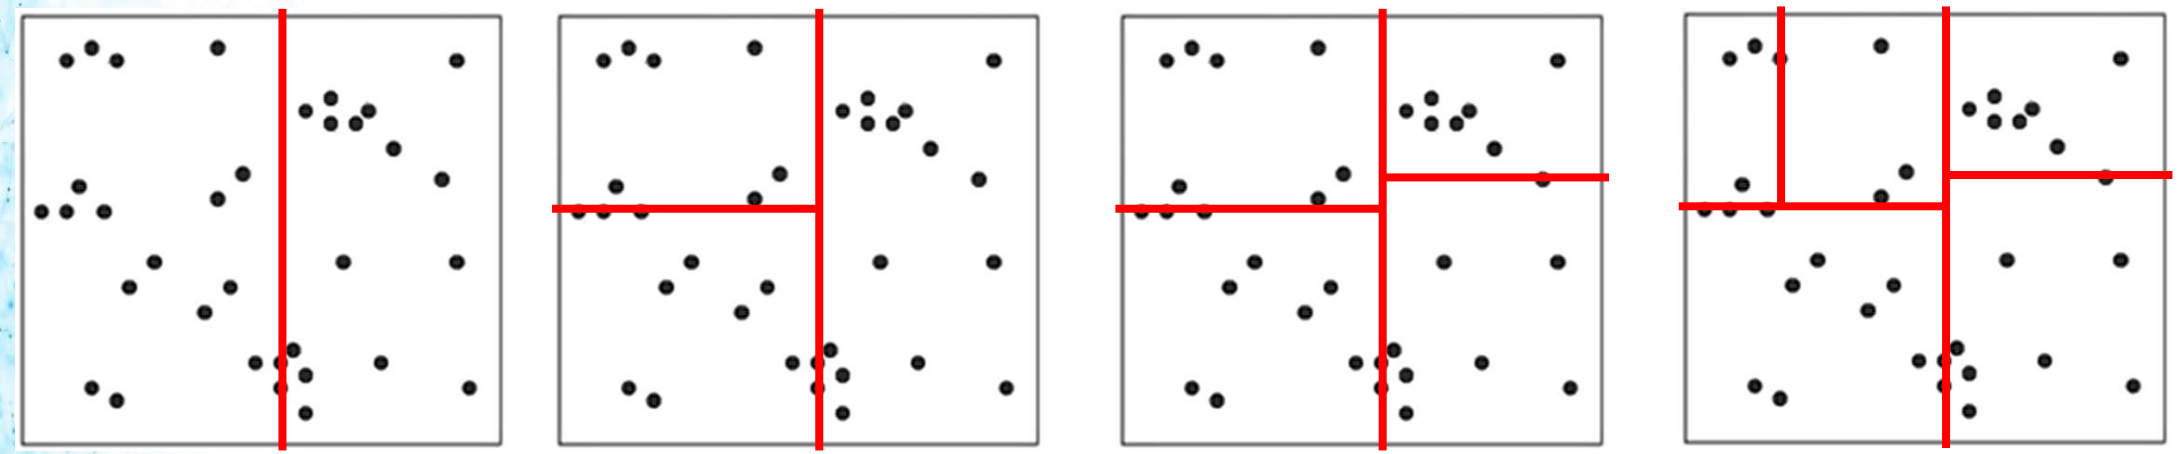

Divisão de Pontos

Divisão pelo ponto que representa a MEDIANA

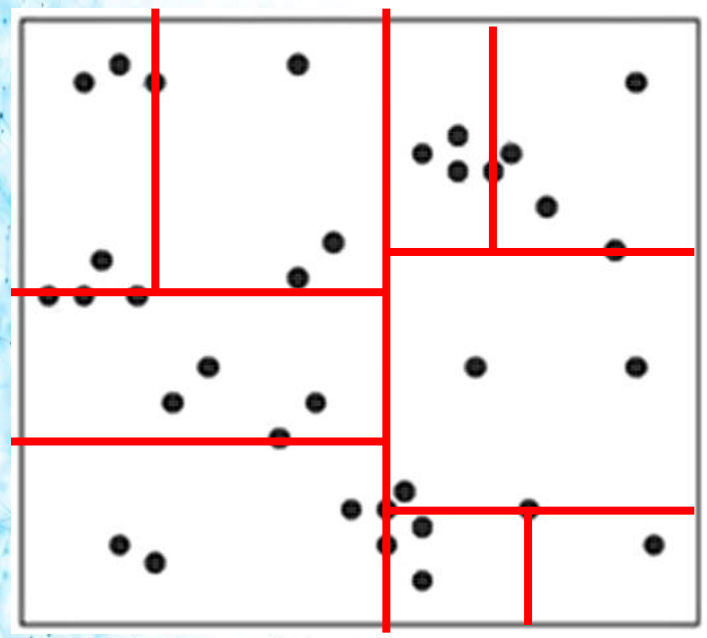

Quando parar de dividir ?

- Menos do que m pontos sobraram dentro dos boxs
- As áreas atingiram um tamanho mínimo determinado

Pela divisão passar em cima de um ponto existente, os nós das Kd-trees podem ser representados por esses pontos

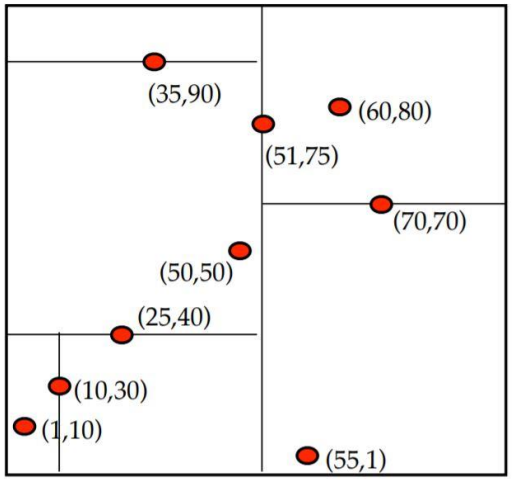

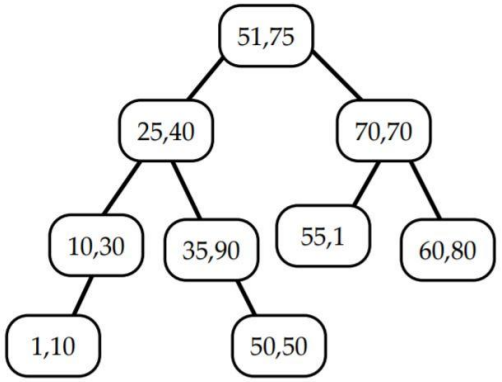

Imagem from Stackoverflow.com

Divisão dos Pontos

(3,2)	(5,8)	(6,1)	(9,0)	(4,4)	(1,1)	(2,2)	(8,7)

Coordenada x

(3,2)	(5,8)	(6,1)	(9,0)	(4,4)	(1,1)	(2,2)	(8,7)

Descobrindo a mediana:

1	2	3	4	5	6	8	9

O ponto (4,4) é a mediana da coordenada x.

(3,2)	(5,8)	(6,1)	(9,0)	(4,4)	(1,1)	(2,2)	(8,7)

O ponto (4,4) se torna raiz da árvore

(4,4)

(3,2)	(1,1)	(2,2)

(5,8)	(6,1)	(9,0)	(8,7)

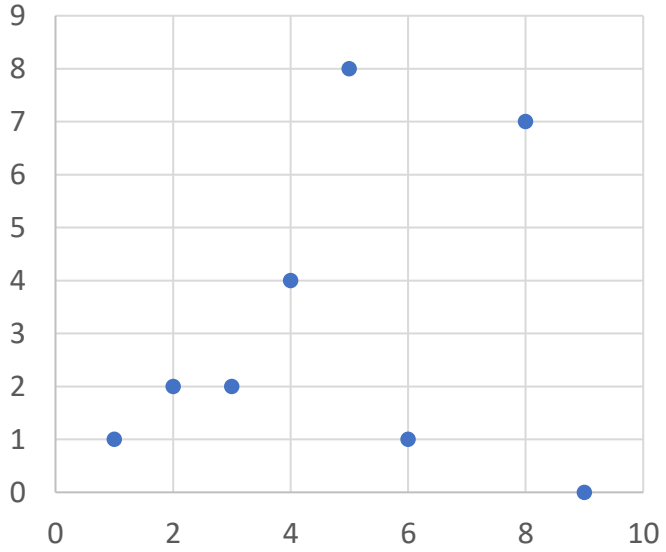

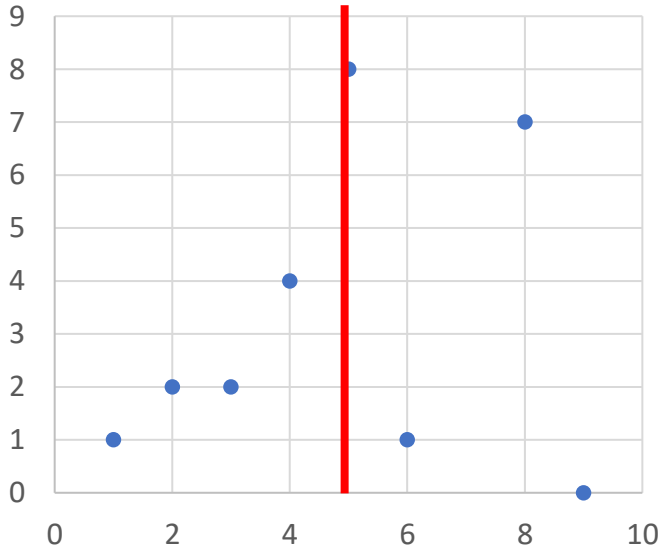

Divisão dos Pontos

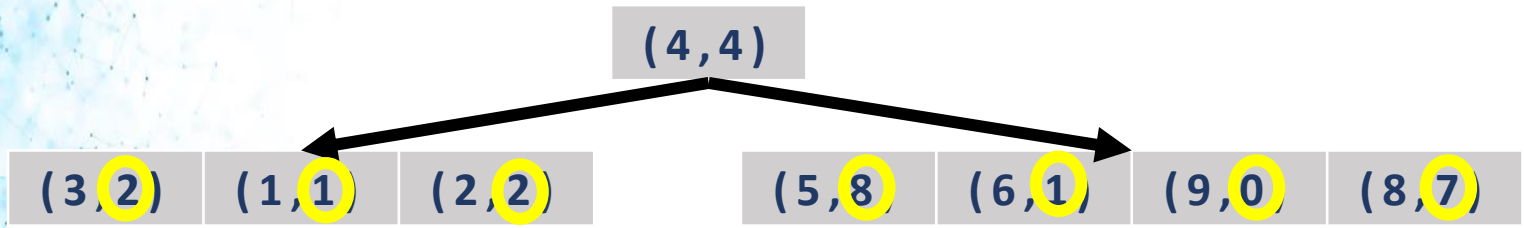

Encontre a mediana em relação a coordenada y em cada subarray

As medianas se tornam raízes da sub-árvores, e o processo se repete....

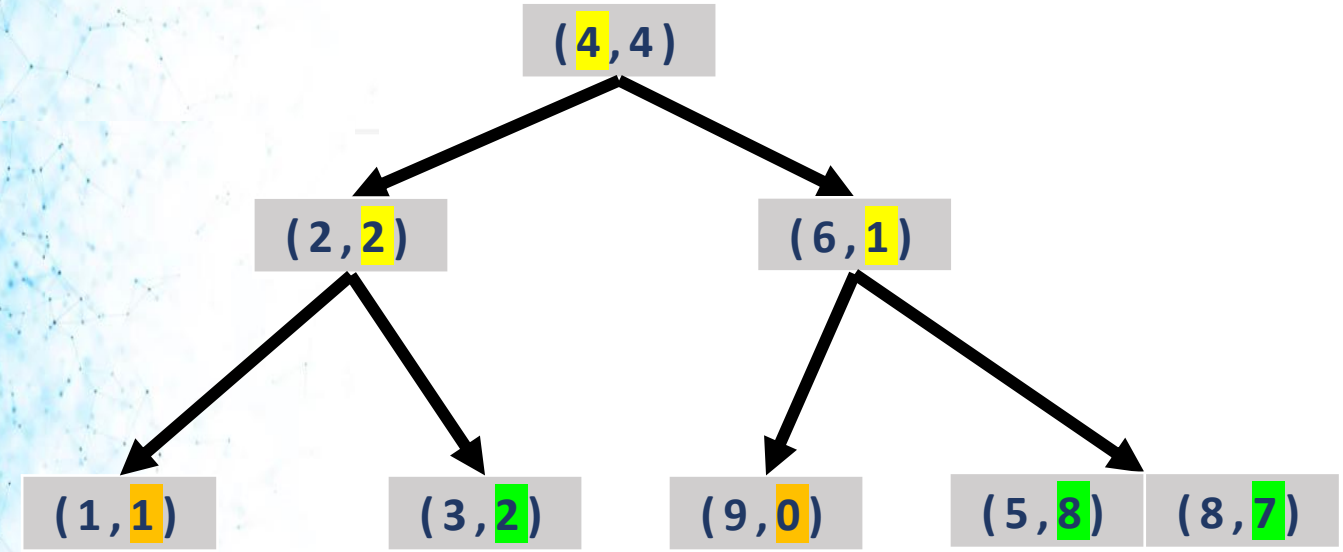

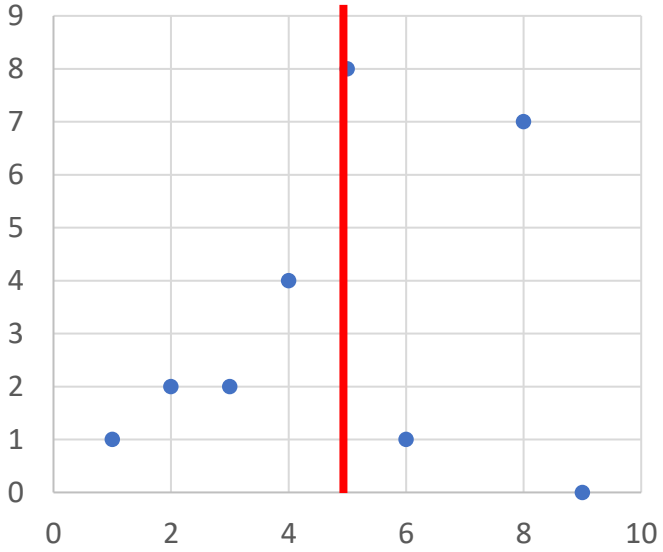

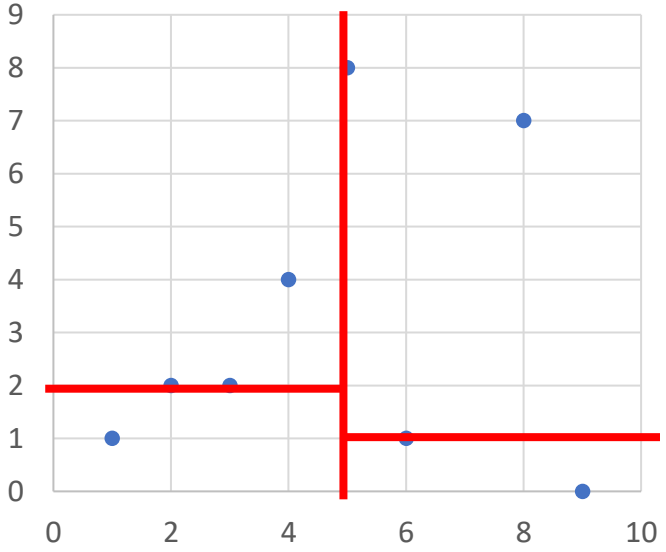

Representação dos pontos na Kd-Tree

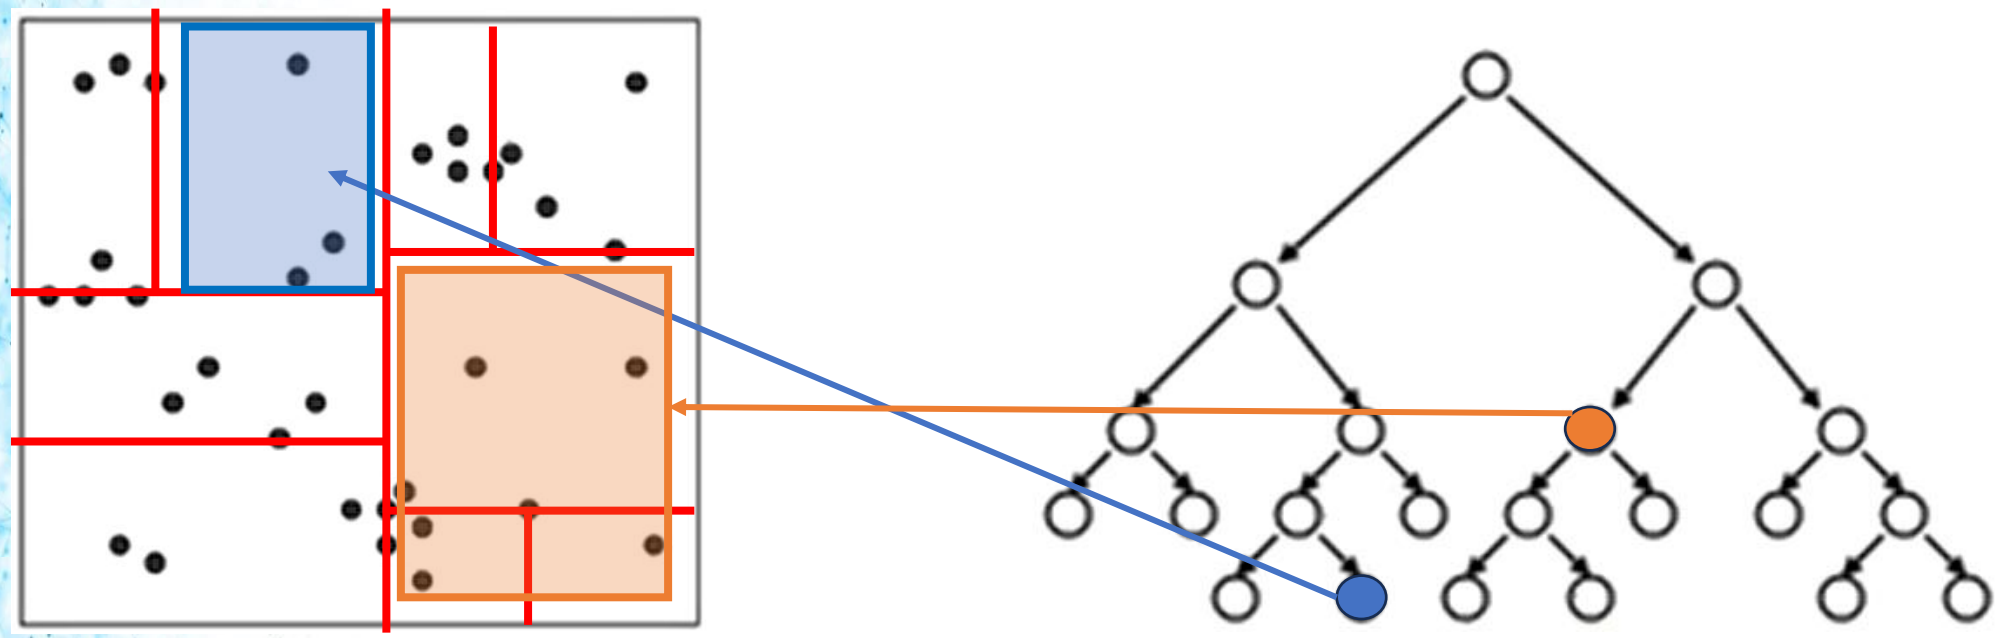

Nós das árvores representam regiões.
Uma folha representa os pontos de 1 única região
Nós intermediários da árvore representam mais de uma região (sub-árvore)

Outras divisões ?

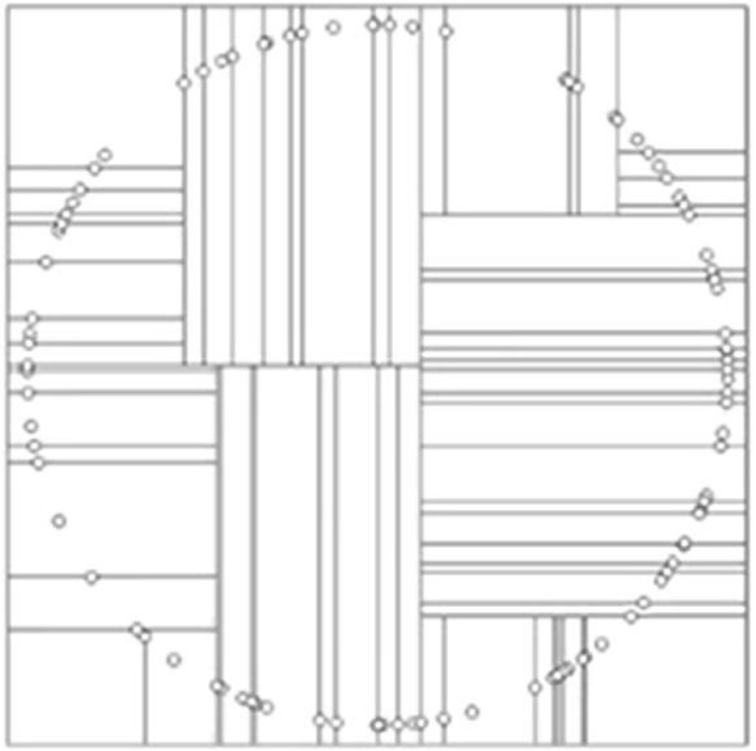

Ponto mediano

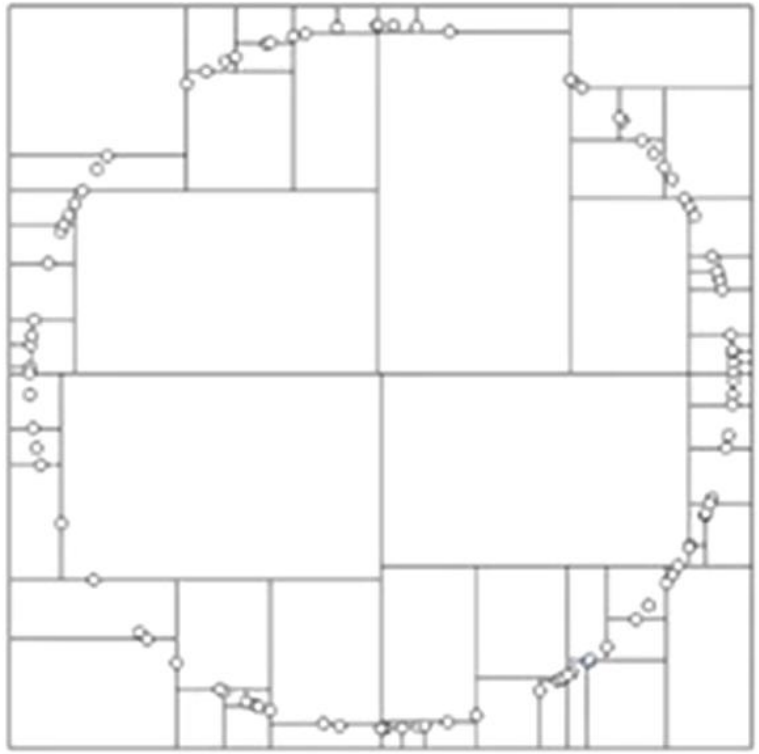

Centro da faixa (center-of-range)

KNN com Kd-Tree

Como usar a Kd-Tree na busca pelos K vizinhos mais próximos ?

KNN com Kd-Tree

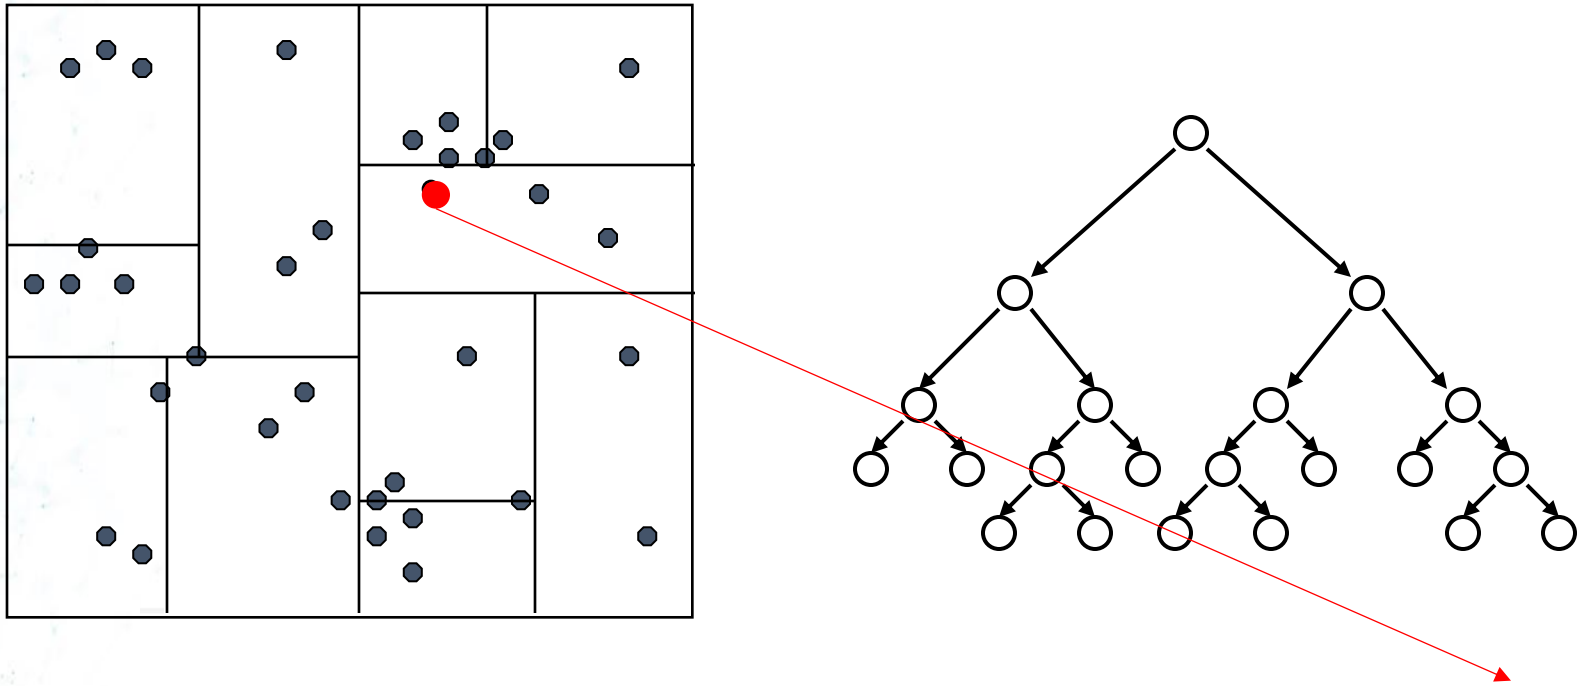

Analisar a árvore procurando o vizinho mais próximo do **ponto de consulta**.

KNN com Kd-Tree

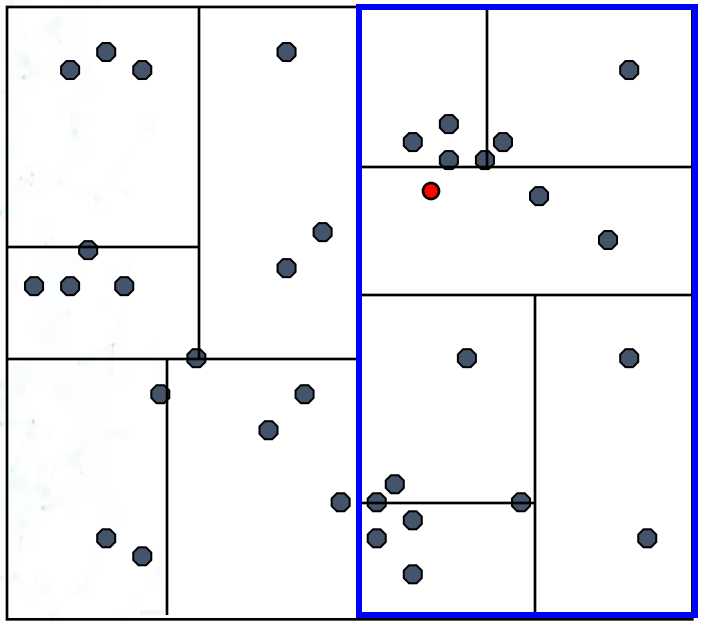

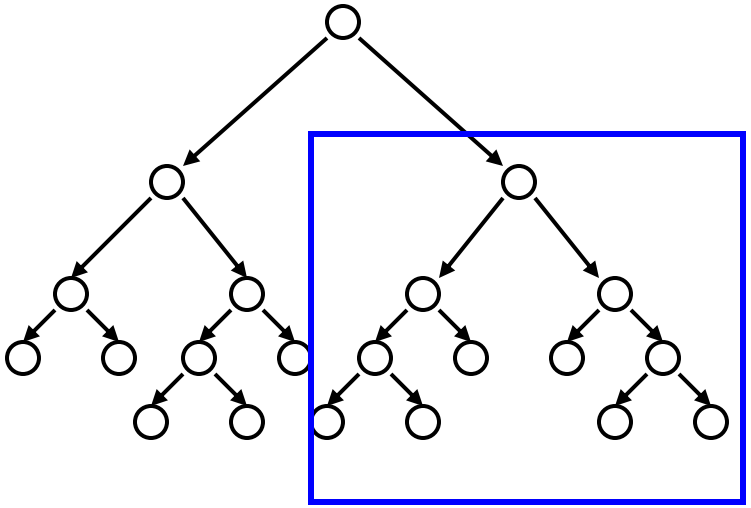

Examine primeiro os pontos próximos: explore primeiro o galho da árvore mais próximo do ponto de consulta.

KNN com Kd-Tree

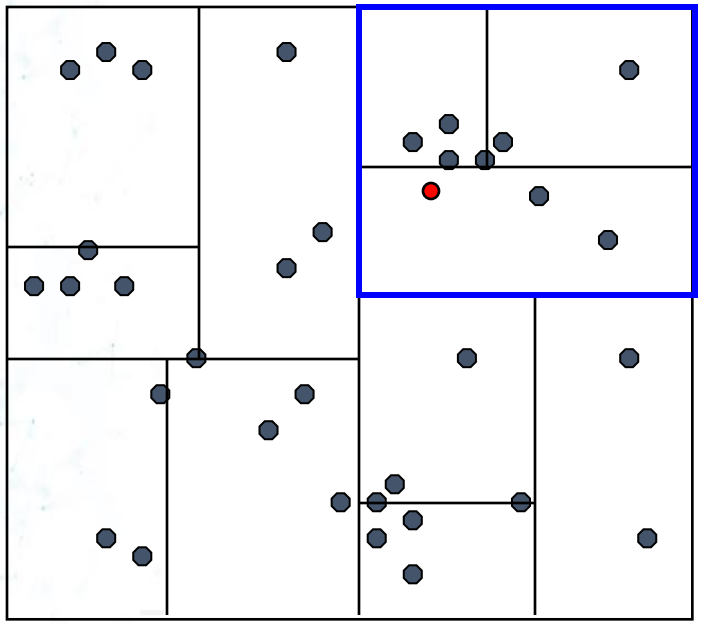

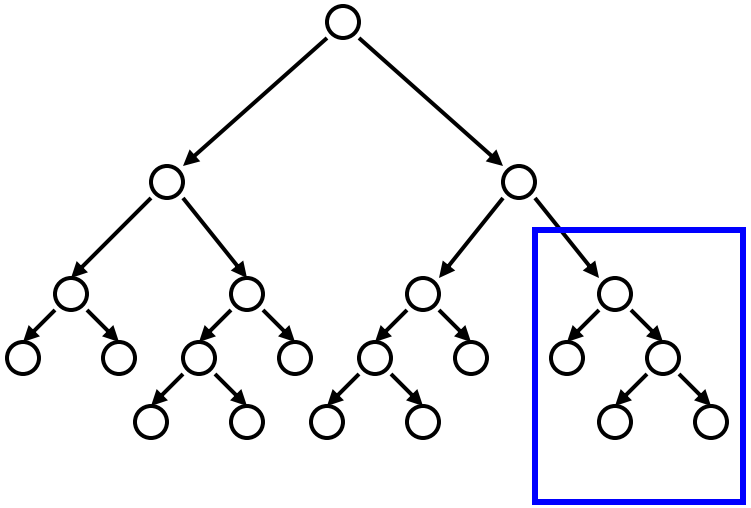

Examine os pontos próximos primeiro: explore primeiro o ramo da árvore mais próximo do ponto de consulta.

KNN com Kd-Tree

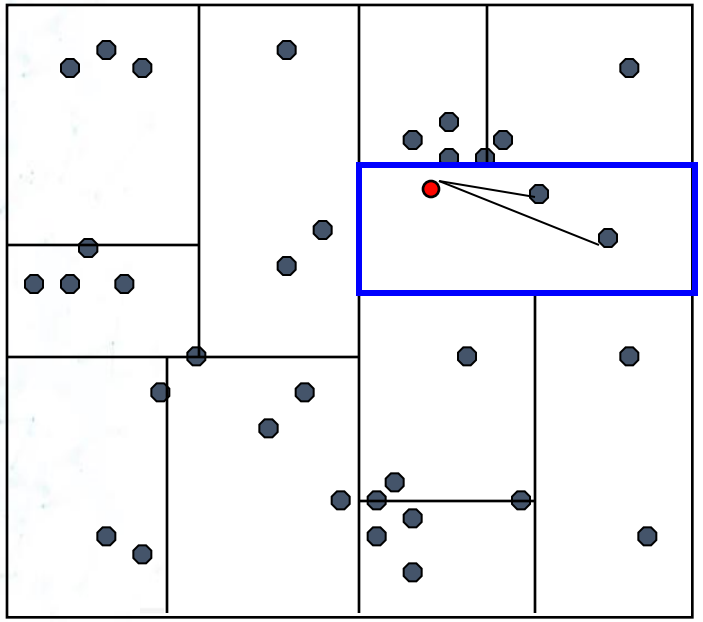

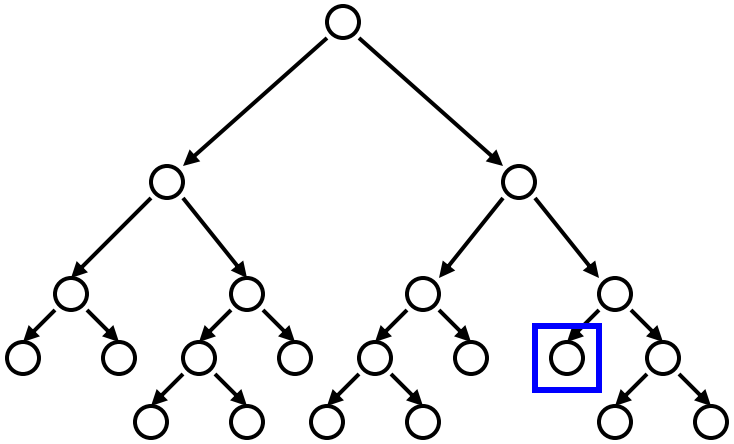

Quando chegarmos a um nó de folha: calcule a distância de cada ponto na lista do nó folha ao **ponto de consulta.**

KNN com Kd-Tree

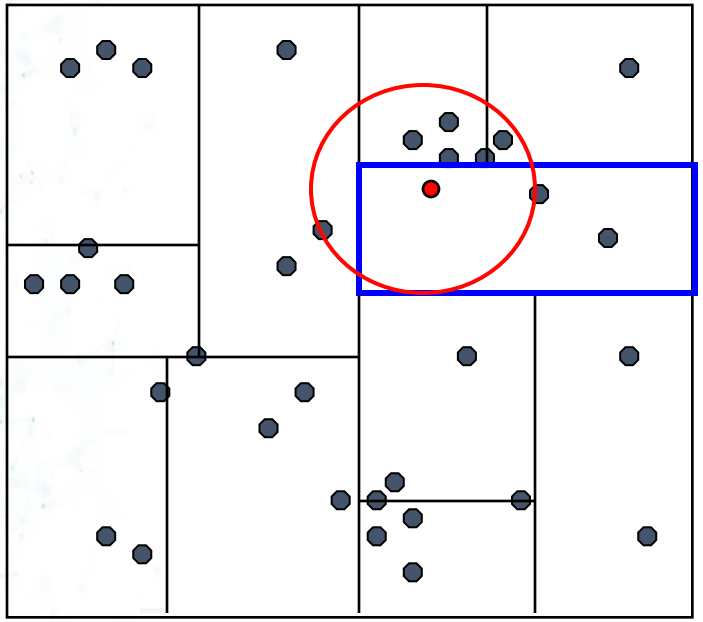

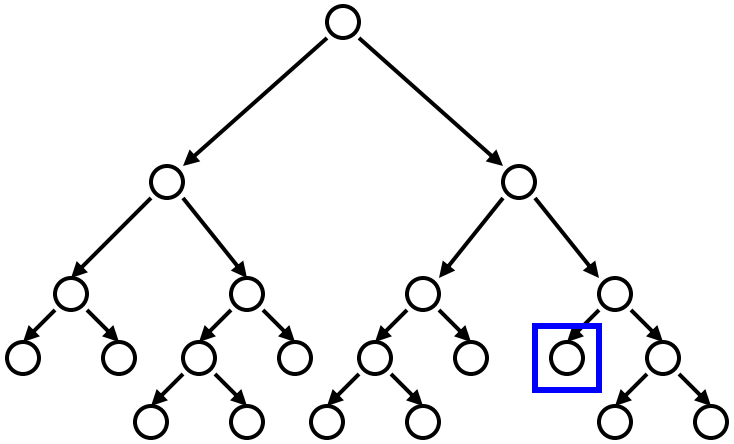

Quando chegamos a um nó de folha: temos que calcular a distância a cada ponto dos nós vizinhos

KNN com Kd-Tree

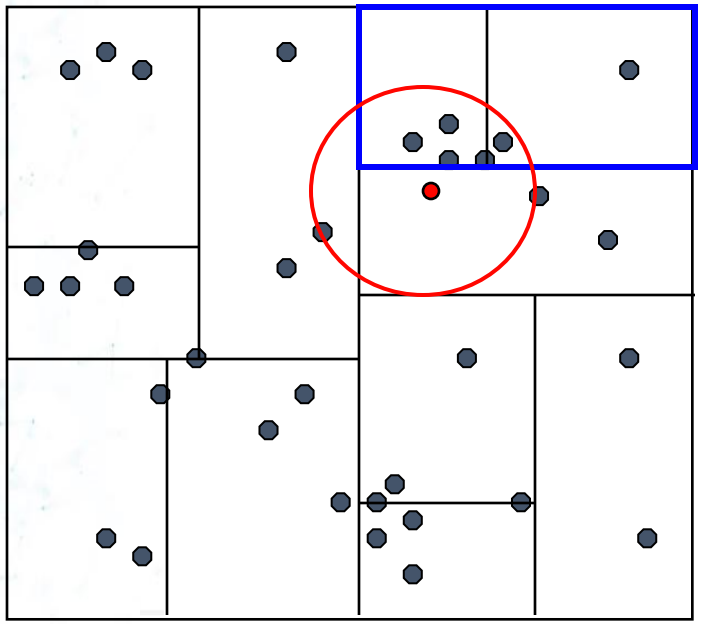

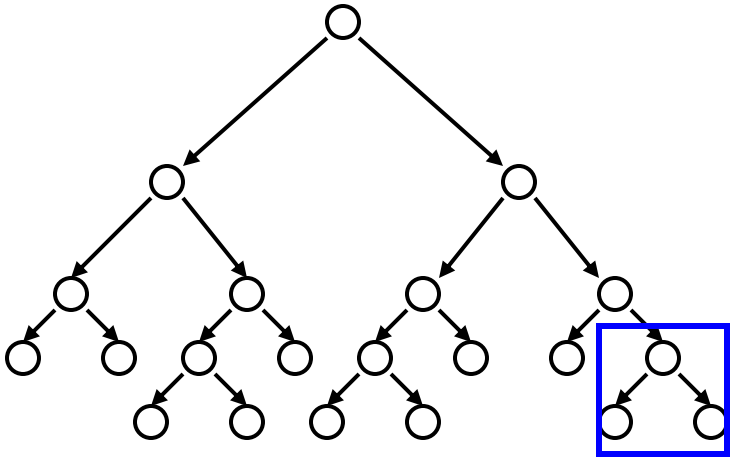

Em seguida, podemos voltar atrás e tentar a outra ramificação em cada nó visitado.

KNN com Kd-Tree

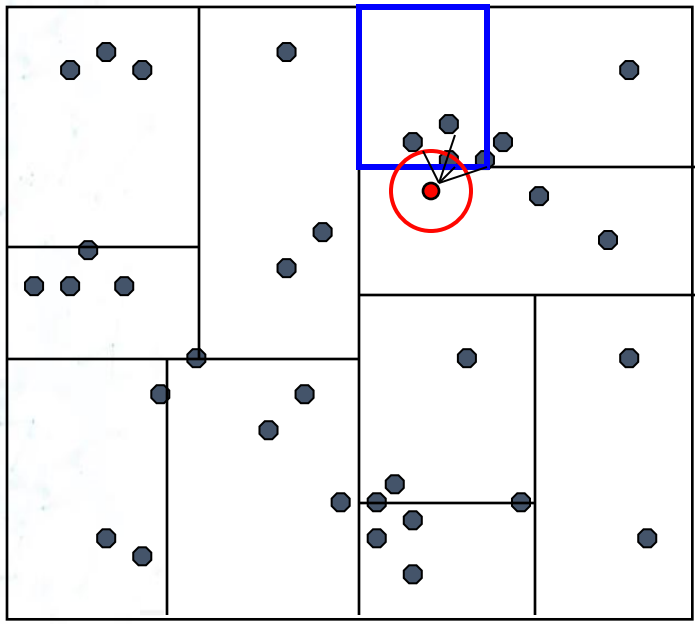

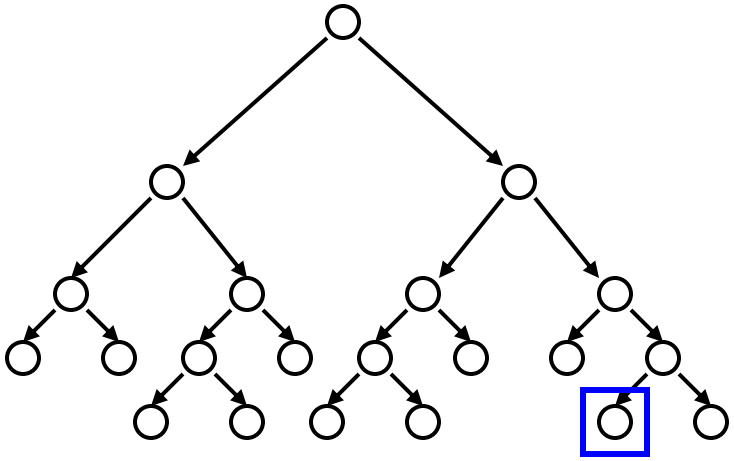

Cada vez que um novo nó mais próximo é encontrado, podemos atualizar os limites de distância.

KNN com Kd-Tree

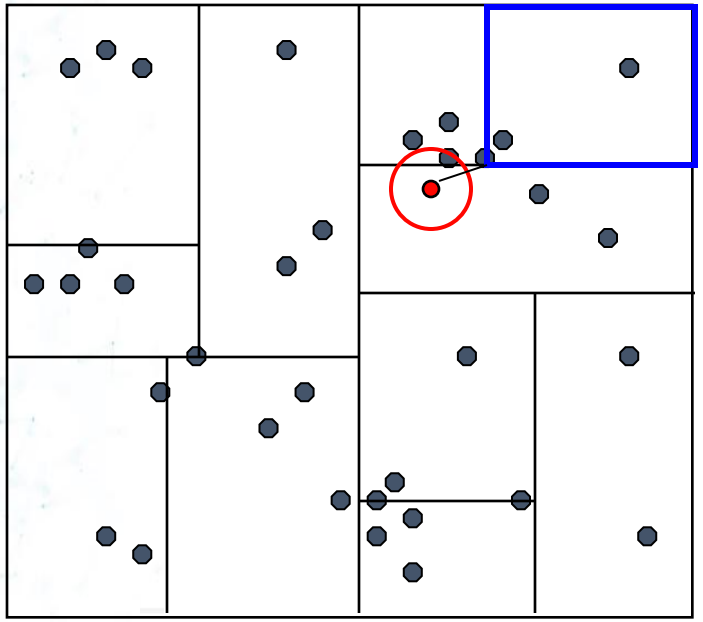

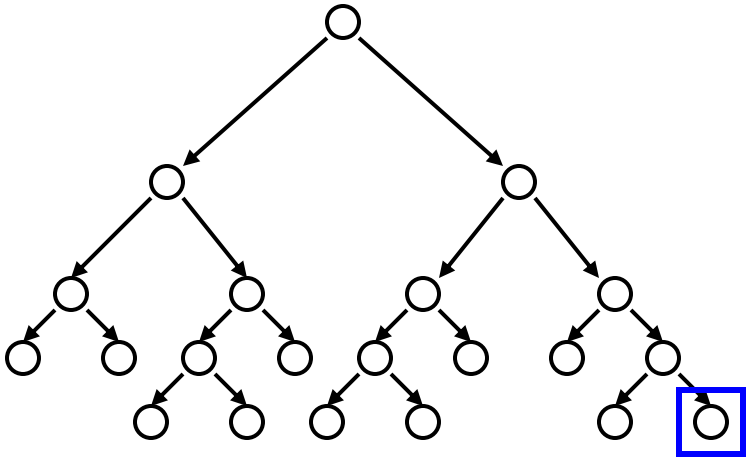

Usando os limites de distância e os limites dos dados abaixo de cada nó, podemos podar partes da árvore que NÃO poderiam incluir o vizinho mais próximo.

KNN com Kd-Tree

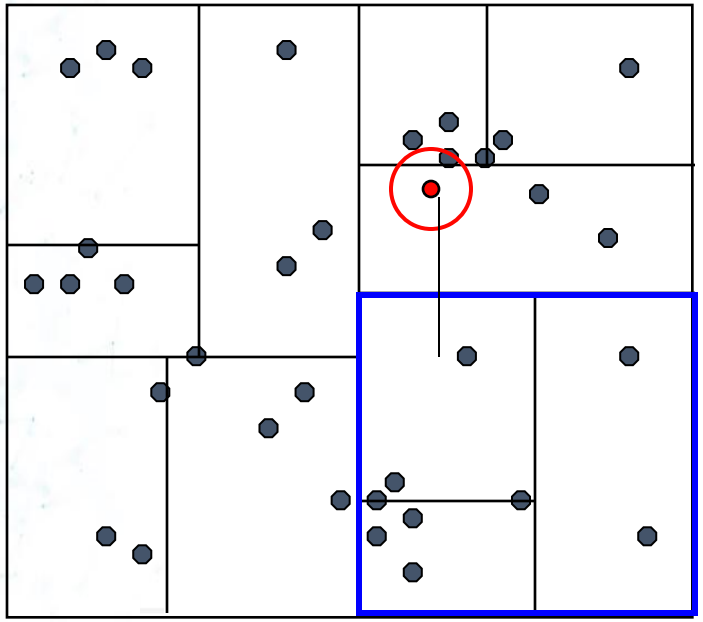

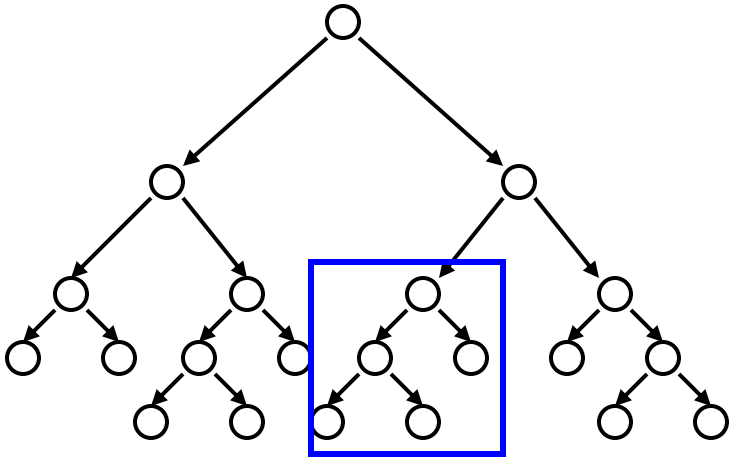

Usando os limites de distância e os limites dos dados abaixo de cada nó, podemos podar partes da árvore que NÃO poderiam incluir o vizinho mais próximo.

KNN com Kd-Tree

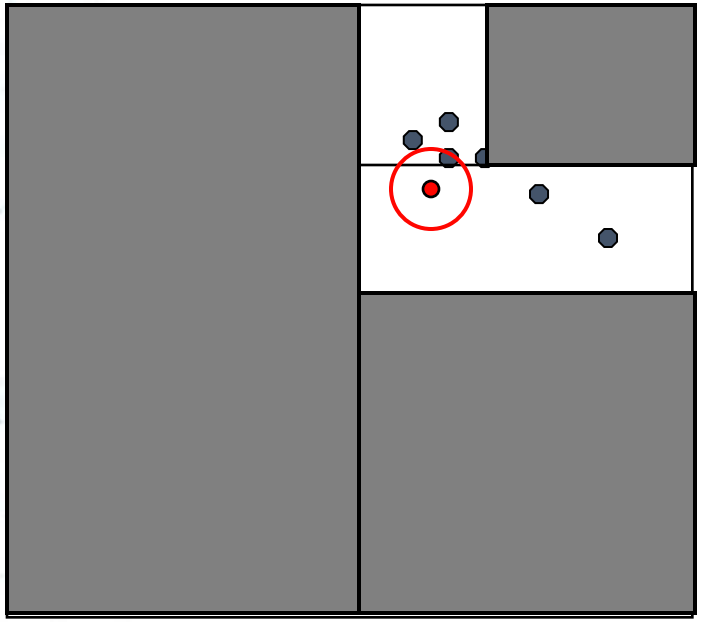

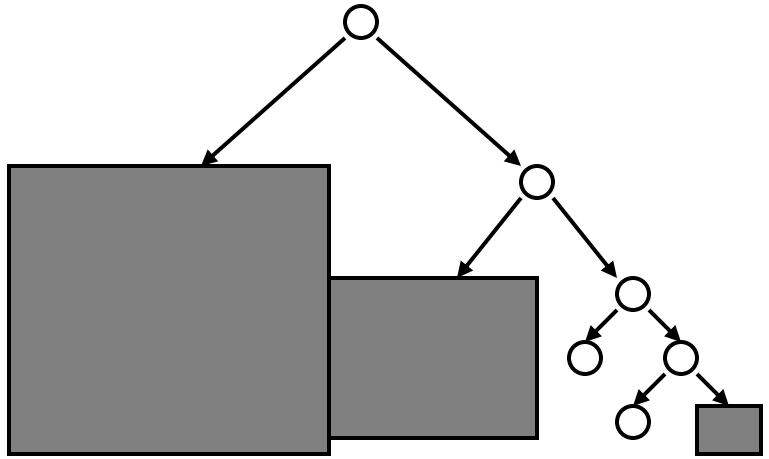

Usando os limites de distância e os limites dos dados abaixo de cada nó, podemos podar partes da árvore que NÃO poderiam incluir o vizinho mais próximo.

KNN com Kd-Tree

- O algoritmo pode fornecer o k-Vizinhos mais próximos a um ponto mantendo k melhores atuais em vez de apenas um.
- Os ramos só são eliminados quando não podem ter pontos mais perto do que qualquer um dos melhores k atuais.
- O tempo de consulta no pior caso pode ser alto, mas o tempo de consulta típico/esperado está em O(log n) para cada nova consulta.

Bibliografia desta Aula

Para aprofundamento nos assuntos desta aula, segue a seguinte referência bibliográfica

- Método dos Mínimos Quadrados Wikipedia
  - https://pt.wikipedia.org/wiki/Método_dos_mínimos_quadrados
- KNN Wikipedia
  - https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm
- Kd-Tree
- Data Structure & Algorithms – Lecture 12: KD-Trees – Jheronimus Academy of Data Science
- Livro referência: Russel & Norvig – Artificial Intelligence – A modern Approach – 4th edition (2022) – Capitulo 19

- Agradecimento ao prof. Dr. Danilo H. Perico (alguns exemplos foram baseados em suas aulas)